



Frankfurt University of Applied Sciences

Fachbereich 2: Informatik und Ingenieurwissenschaften

Untersuchung der Einsatzmöglichkeiten und Genauigkeit von auf Künstlicher Intelligenz basierenden Sprache-zu-Text-Systemen bei der Umsetzung von digitaler Barrierefreiheit.

Abschlussarbeit zur Erlangung des akademischen Grades
Bachelor of Science (B.Sc.)

Vorgelegt am 19.09.2024 von

Marlon Ringel

Matrikelnummer: 1314614

Referent: Prof. Dr. Jörg Schäfer


Korreferent: Miklos Weiszhaupt

Eidesstattliche Erklärung

Hiermit versichere ich, Marlon Ringel, dass ich die vorliegende Arbeit selbstständig und ohne Benutzung anderer als der angegebenen Hilfsmittel angefertigt habe. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten und nicht veröffentlichten Schriften entnommen sind, sind als solche kenntlich gemacht. Die Arbeit hat in gleicher Form noch keiner anderen Prüfbehörde vorgelegen. Die Korrektur der vorliegenden Arbeit wurde in Kooperation mit Pagemachine¹ durchgeführt.

Frankfurt am Main, den 18.09.2024

Unterschrift

A handwritten signature in black ink, appearing to be 'MR', is written over a horizontal line.

¹ <https://www.pagemachine.de/>

Inhaltsverzeichnis

I Abbildungsverzeichnis.....	5
II Tabellenverzeichnis.....	6
III Abkürzungsverzeichnis.....	6
1 Einleitung.....	8
2 Einführungen.....	9
2.1 Behinderung.....	9
2.1.1 Modelle von Behinderung.....	9
2.1.1.1 Das individuelle / medizinische Modell von Behinderung.....	9
2.1.1.2 Das soziale Modell von Behinderung.....	10
2.1.2 Definitionen von Behinderung.....	10
2.1.2.1 WHO-Klassifikation von Behinderung.....	10
2.1.2.2 Rechtliche Definitionen von Behinderung.....	11
2.1.3 Heutige Auffassung von Behinderung.....	12
2.2 Digitale Barrierefreiheit.....	13
2.2.1 Definition digitale Barrierefreiheit.....	13
2.2.2 Motivation für digitale Barrierefreiheit.....	14
2.2.3 Der aktuelle Stand von digitaler Barrierefreiheit im rechtlichen Kontext..	15
2.2.3.1 Barrierefreie-Informationstechnik-Verordnung.....	15
2.2.3.2 Barrierefreiheitsstärkungsgesetz.....	16
2.2.3.3 European Accessibility Act.....	16
2.2.3.4 Web Content Accessibility Guidelines.....	16
2.3 Künstliche Intelligenz.....	17
2.3.1 Wissensbasierte Künstliche Intelligenz.....	18
2.3.2 Datengetriebene Künstliche Intelligenz.....	18
2.3.3 Spekulative zukünftige Künstliche Intelligenz.....	19
2.4 Sprache-zu-Text Technologie.....	20
2.4.1 Entwicklung von Speech-to-Text.....	20
2.4.2 Funktionsweise moderner Speech-to-Text Systeme.....	21
2.4.3 Word Error Rate.....	22
3 Forschungsfragen.....	22
4 Methodik.....	23
5 Stand der Forschung zu Einsatzmöglichkeiten und Genauigkeit von Sprache-zu-Text-Technologie für die Umsetzung von digitaler Barrierefreiheit.....	24
5.1 Textalternativen von zeitbasierten Medien.....	24
5.2 Übersetzung von gesprochener Sprache in Gebärdensprache.....	27
5.3 Sprachsteuerung von digitalen Systemen.....	28
5.4 Genauigkeit von aktuellen Sprache-zu-Text-Systemen.....	31
5.5 Bewertung der Einsatzmöglichkeiten und Genauigkeit der vorgestellten Systeme zur Umsetzung von digitaler Barrierefreiheit.....	33

6 Prototype: STT Accuracy Analyzer.....	37
6.1 Planung.....	37
6.1.1 Anforderungen.....	37
6.1.2 Use Cases.....	38
6.1.3 Architektur.....	39
6.1.3.1 Anwendungsfunktionen.....	40
6.1.3.1.1 Datenbank-Dienst.....	40
6.1.3.1.2 Eingabe-Verifizierungsdienst.....	40
6.1.3.1.3 Transkriptions-Dienst.....	40
6.1.3.1.4 Auswertungs-Dienst.....	41
6.1.3.1.5 Datenbank.....	41
6.1.3.2 Externe Komponenten.....	42
6.1.3.3 Graphische Benutzeroberfläche.....	42
6.1.3.3.1 Eingabe-Seite.....	42
6.1.3.3.2 Testprozess-Fortschritt-Seite.....	44
6.1.3.3.3 Ergebnis-Seite.....	45
6.1.4 Auswertungsmetriken.....	46
6.1.4.1 Character Error Rate.....	46
6.1.4.2 Match Error Rate.....	46
6.1.4.3 Word Information Lost.....	47
6.1.4.4 Jaro Winkler Distance.....	47
6.1.5 Standardtestdatensatz.....	48
6.2 Implementierung.....	48
6.2.1 Initialisierung der Anwendung.....	49
6.2.2 Einlesen der Konfigurationsdaten.....	50
6.2.3 Ausführen des Transkriptionsprozesses.....	52
6.2.4 Ausführen des Auswertungsprozesses.....	54
6.2.5 Anzeigen und Exportieren der Testergebnisse.....	56
7 Prototype: TranscribeMyVideo.....	58
7.1 Planung.....	58
7.1.1 Anforderungen.....	58
7.1.2 Use Cases.....	59
7.1.3 Architektur.....	60
7.1.3.1 Anwendungsfunktionen.....	60
7.1.3.1.1 Upload-Dienst.....	60
7.1.3.1.2 Transkriptions-Dienst.....	61
7.1.3.1.3 Daten-Manager.....	61
7.1.3.2 Dateisystem.....	61
7.1.3.3 Webinterface.....	61
7.1.3.3.1 Upload-Seite.....	62
7.1.3.3.2 Transkript-Prozess-Seite.....	63

7.1.3.3.3 Korrektur-Seite.....	64
7.1.3.3.4 Download-Seite.....	65
7.1.3.4 Client-Server-Architektur.....	65
7.2 Implementierung.....	65
7.2.1 Hochladen einer Videodatei.....	66
7.2.2 Generierung des Transkripts.....	68
7.2.3 Korrektur des Transkripts.....	69
7.2.4 Herunterladen des Transkripts.....	70
8 Bewertung der Prototypen.....	71
8.1 Weiterentwicklungsmöglichkeiten STT Accuracy Analyzer.....	72
8.1.1 Vereinfachung der Eingabe des Startbefehls.....	72
8.1.2 Erweiterte Unterstützung von Dateiformaten für benutzerdefinierte Testdatensätze.....	72
8.1.3 Genauere Validierung der Konfigurationsdaten.....	73
8.1.4 Performanceverbesserung bei der Ausführung des Subprozess.....	73
8.1.5 Erweiterte Fehlerbehandlung.....	73
8.1.6 Erweiterung der Datenbank.....	74
8.2 Weiterentwicklungsmöglichkeiten TranscribeMyVideo.....	74
8.2.1 Ausweitung der unterstützten Videoformate.....	74
8.2.2 Validierung und Beschränkung der Dateigröße des hochzuladenden Videos.....	74
8.2.3 Anzeigen des Videos auf der Korrekturseite zur Unterstützung des Nutzers bei der Korrektur.....	75
8.2.4 Speichern der Transkripte für zukünftige Aufrufe.....	75
8.2.5 Parallele Nutzung der Anwendung durch mehrere Nutzer.....	75
8.2.6 Testen der Ausführbarkeit der Anwendung auf einem Webserver.....	75
8.3 Überprüfung der Genauigkeit von zwei STT-Systemen mittels STT Accuracy Analyzer.....	76
8.4 Abschließende Bewertung.....	77
9 Fazit und Ausblick.....	77
IV Literaturverzeichnis.....	82
Anhang 1: Use Cases STT Accuracy Analyzer.....	89
Anhang 2: Use Cases TranscribeMyVideo.....	99

I Abbildungsverzeichnis

Abbildung 1: Architekturdiagramm Prototyp STT Accuracy Analyzer	Seite 39
Abbildung 2: Datenbankdiagramm	Seite 41
Abbildung 3: Eingabe-Seite	Seite 43
Abbildung 4: Eingabe-Seite Fehlerzustand	Seite 43
Abbildung 5: Testprozess-Fortschritt-Seite	Seite 44
Abbildung 6: Testprozess-Fortschritt-Seite Fehlerzustand	Seite 44
Abbildung 7: Testprozess-Fortschritt-Seite Erfolgzustand	Seite 45
Abbildung 8: Ergebnis-Seite	Seite 45
Abbildung 9: Aktivitätsdiagramm Ablauf Prototyp STT Accuracy Analyzer	Seite 49
Abbildung 10: Sequenzdiagramm Initialisierung der Anwendung	Seite 50
Abbildung 11: Sequenzdiagramm Einlesen der Konfigurationsdaten	Seite 51
Abbildung 12: Sequenzdiagramm Ausführen des Transkriptionsprozesses	Seite 53
Abbildung 13: Sequenzdiagramm Ausführen des Auswertungsprozesses	Seite 55
Abbildung 14: Sequenzdiagramm Anzeigen und Exportieren der Ergebnisse	Seite 57
Abbildung 15: Architekturdiagramm Prototyp TranscribeMyVideo	Seite 60
Abbildung 16: Grundlegender Aufbau des Webinterfaces	Seite 62
Abbildung 17: Upload-Seite	Seite 63
Abbildung 18: Transkript-Prozess-Seite	Seite 63
Abbildung 19: Korrektur-Seite	Seite 64
Abbildung 20: Download-Seite	Seite 65
Abbildung 21: Aktivitätsdiagramm Ablauf Prototyp TranscribeMyVideo	Seite 66
Abbildung 22: Sequenzdiagramm Hochladen einer Videodatei	Seite 67
Abbildung 23: Sequenzdiagramm Generierung des Transkripts	Seite 69
Abbildung 24: Sequenzdiagramm Korrektur des Transkripts	Seite 70
Abbildung 25: Sequenzdiagramm Herunterladen des Transkripts	Seite 71

II Tabellenverzeichnis

Tabelle 1: Durchschnittlicher WER in Prozent nach STT-System und Datensatz	Seite 32
Tabelle 2: Use Cases STT Accuracy Analyzer	Seite 38
Tabelle 3: Use Cases TranscribeMyVideo	Seite 59
Tabelle 4: Durchschnittliche Ergebnisse der Auswertungsmetriken der Auswertung mittels STT Accuracy Analyzer in Prozent	Seite 76

III Abkürzungsverzeichnis

BFSG	Barrierefreiheitsstärkungsgesetz
BGG	Behindertengleichstellungsgesetzes
CER	Character Error Rate
BITV	Barrierefreie-Informationstechnik-Verordnung
EAA	European Accessibility Act
HTTP	Hypertext Transfer Protocol
ICIDH	International Classification of Impairments, Disabilities and Handicaps
ICF	International Classification of Functioning, Disability and Health
i. d. F. v.	in der Fassung von
JWD	Jaro Winkler Distance
KI	Künstliche Intelligenz
KNN	Künstliche Neuronale Netze
MER	Match Error Rate
ML	Maschinelles Lernen
NLP	Natural Language Processing
o. D.	ohne Datum
TTS	Text-to-Speech
UN-BRK	UN-Behindertenrechtskonvention

W3C	World Wide Web Consortium
WAI	Web Accessibility Initiative
WCAG	Web Content Accessibility Guidelines
WER	Word Error Rate
WHO	Weltgesundheitsorganisation
WIL	Word Information Lost

1 Einleitung

Nach Angaben der Weltgesundheitsorganisation sind weltweit 1,3 Milliarden Menschen (16 % der Weltbevölkerung) von erheblichen Behinderungen betroffen [1]. In Deutschland leben nach Angaben des Statistischen Bundesamts 7,8 Millionen Menschen (9,4 % der Gesamtbevölkerung) mit einer anerkannten Schwerbehinderung [2]. Behinderung beschreibt dabei die Wechselwirkung der individuellen Beeinträchtigung eines Menschen mit Barrieren in der Umwelt, die diese Menschen bei der gesellschaftlichen Partizipation behindern [3-4]. Dem wirkt Barrierefreiheit entgegen. Barrierefreiheit beschreibt den Prozess, Barrieren, die Menschen an der gesellschaftlichen Teilhabe hindern, zu identifizieren, abzubauen und deren Entstehung zu vermeiden, mit dem Ziel, Inklusion zu schaffen, was ein Menschenrecht darstellt [5]. Diese Barrieren treten dabei nicht nur im physischen Raum auf, sondern auch in digitalen Räumen [6]. Durch die steigende Bedeutung von digitalen Produkten im alltäglichen Leben gewinnt somit auch das Thema digitale Barrierefreiheit an immer größerer Relevanz [7]. Dies resultierte bereits in politischen Bestrebungen, gesetzliche Rahmenbedingungen zur Gewährleistung von (digitaler) Barrierefreiheit zu schaffen. Mit dem European Accessibility Act, der Barrierefreie-Informationstechnik-Verordnung und dem Barrierefreiheitsstärkungsgesetz wurden europäische und nationale gesetzliche Vorgaben geschaffen, die die Umsetzung von Barrierefreiheit und speziell digitaler Barrierefreiheit vorschreiben und regulieren. Nach diesen Gesetzen müssen zum jetzigen Stand alle digitalen Angebote öffentlicher Stellen innerhalb Deutschlands sowie alle digitalen Produkte und Dienstleistungen, die ab dem 28. Juni 2025 auf den europäischen Markt gebracht werden, barrierefrei gestaltet sein [8-10]. Im Bereich Sprache-zu-Text-Technologie, die die automatisierte Überführung von gesprochener Sprache in geschriebenen Text ermöglicht, wurden in den letzten Jahren durch den Einsatz von Künstlicher Intelligenz erhebliche Fortschritte erzielt. Moderne Sprache-zu-Text-Systeme erzielen nach Angaben der Hersteller dieser Systeme in der Spitze Genauigkeiten von 95,1 % und sind damit im Bereich der Genauigkeit, die Menschen bei der Transkription gesprochener Sprachen erreichen [11-13]. Aufgrund der Relevanz von digitaler Barrierefreiheit sowie den gesetzlichen Vorgaben, erwächst die Notwendigkeit, technische Möglichkeiten zur Umsetzung der Anforderungen von digitaler Barrierefreiheit zu erarbeiten. Die aktuellen Fortschritte im Bereich Sprache-zu-Text-Technologie erlauben die Überlegung, ob diese Technologie eine

Möglichkeit der Umsetzung von Teilen dieser Anforderungen von digitaler Barrierefreiheit darstellt. Deswegen sollen in der vorliegenden Arbeit die Einsatzmöglichkeiten von Sprache-zu-Text-Technologie zur Umsetzung von digitaler Barrierefreiheit erforscht werden. Außerdem sollen die erreichbaren Genauigkeiten moderner Sprache-zu-Text-Systeme bei der Transkription von deutscher Sprache untersucht werden, da eine ausreichend hohe Genauigkeit dieser Systeme die Grundvoraussetzung für deren erfolgreiche Anwendung darstellt.

2 Einführungen

Im Folgenden werden die Themengebiete, die Gegenstand der vorliegenden Arbeit sind, vorgestellt.

2.1 Behinderung

Behinderung ist ein Sammelbegriff, der unterschiedliche Formen körperlicher, psychischer oder kognitiver Beeinträchtigungen, die in Wechselwirkung mit räumlichen und gesellschaftlichen Barrieren in Behinderung der betroffenen Individuen resultieren, beschreibt [3-4]. Es existieren verschiedene Modelle und Definitionen von Behinderung. Diese werden im Folgenden genauer betrachtet.

2.1.1 Modelle von Behinderung

2.1.1.1 Das individuelle / medizinische Modell von Behinderung

Bis in die 1970er Jahre war das individuelle oder medizinische Modell von Behinderung vorherrschend. Es wurde erst im Nachhinein durch Kritiker als Modell beschrieben und fasst die vorherrschenden Sicht- und Denkweisen zu Behinderung in der damaligen Gesellschaft zusammen. In diesem Modell wird Behinderung als der Defekt des Individuums, der auf eine biologische Abweichung oder Erkrankung desselben zurückzuführen ist, verstanden [3]. Dabei wurden die negativen Folgen von Behinderung, wie schlechtere Bildungschancen, Benachteiligung auf dem Arbeitsmarkt oder reduzierte Mobilität als unausweichliche Folge des Defektes der von Behinderung betroffenen Individuen angesehen, den es aus medizinischer Sicht zu heilen bzw. normalisieren galt. Dadurch wurde den von Behinderung betroffenen Menschen durchweg die Botschaft gesendet, dass sie „falsch“ oder unzureichend seien und

angepasst bzw. normalisiert werden müssten. Auch resultierte aus dieser Anschauung, dass das Leben von als behindert angesehenen Menschen weitgehend durch Behinderungsexperten, wie Ärzte, Therapeuten oder Pädagogen, fremdbestimmt wurde und sich in großen Teilen in Sondereinrichtungen abspielte. Dies entzog behinderten Menschen die Möglichkeiten, gleichberechtigt an der Gesellschaft teilzuhaben oder sich politisch selbst zu vertreten [4].

2.1.1.2 Das soziale Modell von Behinderung

In den 1980er Jahren begann, maßgeblich begründet aus der Kritik der Behindertenbewegung am individuellen / medizinischen Modell, die Entwicklung des sozialen Modells von Behinderung [3]. In diesem Modell wird zwischen Beeinträchtigung und Behinderung unterschieden. Beeinträchtigung beschreibt dabei die funktionelle Einschränkung eines Menschen bezogen auf eine körperliche, geistige oder psychische Schädigung. Behinderung wiederum wird im sozialen Modell als der Verlust der Möglichkeiten, am gesellschaftlichen Leben gleichberechtigt teilzuhaben, resultierend aus räumlichen und / oder gesellschaftlichen Barrieren, aufgefasst [4]. Dadurch wurde das Problem der Behinderung nicht mehr im Individuum verortet, sondern als gesellschaftliches / politisches Problem aufgefasst, was wiederum dazu führte, dass Behinderung nicht mehr durch die Anpassung bzw. Normalisierung beeinträchtigter Menschen, sondern durch sozialen Wandel mit dem Ziel des Abbaus von Barrieren entgegengewirkt werden soll [3-4]. Nach der im sozialen Modell vertretenen Auffassung sind Menschen nicht behindert, sondern sie werden behindert [3].

2.1.2 Definitionen von Behinderung

2.1.2.1 WHO-Klassifikation von Behinderung

Die Weltgesundheitsorganisation (WHO) hat 1980 mit der International Classification of Impairments, Disabilities and Handicaps (ICIDH) erstmals eine Unterscheidung von Behinderung und Krankheit vorgenommen. In dieser Klassifikation wurde Behinderung und die damit verbundenen individuellen und gesellschaftlichen Benachteiligungen als Folge einer Normabweichung, die Resultat einer Erkrankung ist, definiert und entspricht damit den Ansichten, die im individuellen / medizinischen Modell von Behinderung vorherrschend waren. 1997 veröffentlichte die WHO eine erweiterte Fassung der

ICIDH, die 2001 als International Classification of Functioning, Disability and Health (ICF) verabschiedet wurde. In dieser Fassung wird Behinderung in den folgenden drei Dimensionen beschrieben:

- Die körperliche Dimension beschreibt die individuellen Beeinträchtigungen des Körpers, die als behindert angesehene Menschen infolge von medizinisch physischen Einschränkungen ihres Körpers erfahren.
- Die individuelle Dimension beschreibt die, aus der Beeinträchtigung des Körpers resultierenden, Einschränkungen der Aktivitätsmöglichkeiten von als behindert angesehenen Menschen.
- Die gesellschaftliche Dimension beschreibt die Beeinträchtigungen von als behindert angesehenen Menschen durch gesellschaftliche Barrieren und die damit verbundenen verminderten gesellschaftlichen Partizipationsmöglichkeiten.

In der Klassifikation von Behinderung in Form des IFC entsteht Behinderung damit einerseits aus einer körperlichen Schädigung und andererseits aus Barrieren in der Umwelt, wodurch das IFC einen Kompromiss zwischen dem individuellen / medizinischen und dem sozialen Modell von Behinderung darstellt [3].

2.1.2.2 Rechtliche Definitionen von Behinderung

Im rechtlichen Kontext ist ebenfalls ein Wandel der Definition von Behinderung zu erkennen. So wurde Behinderung in der Fassung des Behindertengleichstellungsgesetzes (BGG) von 2002 wie folgt definiert:

„Menschen sind behindert, wenn ihre körperliche Funktion, geistige Fähigkeit oder seelische Gesundheit mit hoher Wahrscheinlichkeit länger als sechs Monate von dem für das Lebensalter typischen Zustand abweichen und daher ihre Teilhabe am Leben in der Gesellschaft beeinträchtigt ist.“

- § 3 BGG i. d. F. v. 27.04.2002

Es wird Behinderung als Abweichung des vom Lebensalter typischen Zustandes oder Normalzustandes definiert. Durch diesen Normalitätsbezug wird die Ursache der Behinderung als die individuelle / medizinische Beeinträchtigung verortet, was den Anschauungen des individuellen / medizinischen Modells entspricht.

Eine Veränderung in den rechtlichen Definitionen wurde durch die Verabschiedung der UN-Behindertenrechtskonvention (UN-BRK) 2006 angestoßen. In der UN-BRK wird Behinderung wie folgt definiert:

„in der Erkenntnis, dass das Verständnis von Behinderung sich ständig weiterentwickelt und dass Behinderung aus der Wechselwirkung zwischen Menschen mit Beeinträchtigungen und einstellungs- und umweltbedingten Barrieren entsteht, die sie an der vollen, wirksamen und gleichberechtigten Teilhabe an der Gesellschaft hindern“

- Präambel der UN-BRK Buchstabe e

Im deutschen Recht erfolgte die Anpassung des BGG an die UN-BRK im Jahr 2016, in der Behinderung in § 3 BGG wie folgt neu definiert wurde:

„Menschen mit Behinderungen im Sinne dieses Gesetzes sind Menschen, die langfristige körperliche, seelische, geistige oder Sinnesbeeinträchtigungen haben, welche sie in Wechselwirkung mit einstellungs- und umweltbedingten Barrieren an der gleichberechtigten Teilhabe an der Gesellschaft hindern können. Als langfristig gilt ein Zeitraum, der mit hoher Wahrscheinlichkeit länger als sechs Monate andauert.“

- § 3 BGG i. d. F. v. 27.07.2016

In beiden Definition wird zwischen der Beeinträchtigung des Individuums und der aus der Wechselwirkung der Beeinträchtigung mit Barrieren entstehenden Behinderung unterschieden, womit sich die Definitionen von Behinderung der UN-BRK und des BGG am sozialen Modell von Behinderung orientieren.

2.1.3 Heutige Auffassung von Behinderung

Zusammengefasst zeigt sich, dass Behinderung nach heutiger Auffassung nicht die Beeinträchtigung des Individuums, sondern die Wechselwirkung von individueller Beeinträchtigung mit Barrieren in der Umwelt beschreibt. Daraus resultiert, dass mit Bemühungen, Behinderung entgegenzuwirken, nicht die Normalisierung der beeinträchtigten Menschen, sondern der Abbau von Barrieren bzw. das Herstellen von Barrierefreiheit angestrebt wird.

2.2 Digitale Barrierefreiheit

Das Ziel von Barrierefreiheit ist es, allen Menschen zu ermöglichen, gleichberechtigt am gesellschaftlichen Leben teilzuhaben. Dies wird auch als Inklusion bezeichnet und ist ein Menschenrecht. Dem entgegen stehen Hindernisse in der Umwelt, die Menschen die Teilhabe am gesellschaftlichen Leben erschweren, sogenannte Barrieren [5]. Barrieren treten dabei nicht nur im physischen Raum, sondern auch in digitalen Räumen auf. So ist das Fehlen einer Übersetzung eines Videos in Gebärdensprache für einen von Gehörlosigkeit betroffenen Menschen genauso eine Barriere wie das Fehlen eines Aufzugs für einen Rollstuhlfahrer [6]. Durch die immer größere Rolle, die digitale Technologien mittlerweile in vielen Aspekten des alltäglichen Lebens einnehmen, wie beispielsweise in Bildung, Arbeit, Politik, Wirtschaft oder Gesundheitswesen, gewinnt das Thema digitale Barrierefreiheit an immer mehr Relevanz [7].

2.2.1 Definition digitale Barrierefreiheit

In der allgemeinen Definition von Barrierefreiheit innerhalb des BGG findet sich ein expliziter Hinweis auf digitale Barrierefreiheit:

„Barrierefrei sind bauliche und sonstige Anlagen, Verkehrsmittel, technische Gebrauchsgegenstände, Systeme der Informationsverarbeitung, akustische und visuelle Informationsquellen und Kommunikationseinrichtungen sowie andere gestaltete Lebensbereiche, wenn sie für Menschen mit Behinderungen in der allgemein üblichen Weise, ohne besondere Erschwernis und grundsätzlich ohne fremde Hilfe auffindbar, zugänglich und nutzbar sind. Hierbei ist die Nutzung behinderungsbedingt notwendiger Hilfsmittel zulässig.“

- § 4 BGG

In der Auflistung wird der Begriff „Systeme der Informationsverarbeitung“ aufgezählt. Systeme der Informationsverarbeitung umfassen dabei alle Systeme, die elektronische Daten verarbeiten. Damit fallen unter diesen Begriff klassische Computer, Laptops, Smartphones und Tablets, Geld- und Fahrkartenautomaten, Info- und Bezahlterminals, E-Book-Reader, aber auch haushalts- und Unterhaltungselektronik sowie alle weiteren Systeme, sofern diese einen Mikroprozessor verbaut haben, über Software gesteuert oder über eine elektronische Benutzerschnittstelle bedient werden. Demzufolge ist auch das Internet ein System der Informationsverarbeitung. Für die barrierefreie Gestaltung

dieser Systeme ist es entscheidend, dass alle ihre Komponenten, maßgeblich Hardware, Software und die zu verarbeitenden Daten, barrierefrei gestaltet werden. Die Umsetzung von digitaler Barrierefreiheit umfasst das Identifizieren und Abbauen von bestehenden Barrieren sowie das Vermeiden der Entstehung von neuen Barrieren, mit dem Ziel einen Zustand zu erreichen, in dem beeinträchtigte Menschen Systeme der Informationsverarbeitung ohne besondere Erschwernis und fremde Hilfe auffinden, wahrnehmen, bedienen und verstehen können [14]. Angelehnt an die allgemeine Definition von Barrierefreiheit des BGG lässt sich digitale Barrierefreiheit wie folgt definieren:

„Digital barrierefrei sind technische Gebrauchsgegenstände, Systeme der Informationsverarbeitung, akustische und visuelle Informationsquellen und Kommunikationseinrichtungen, wenn sie für Menschen mit Behinderungen in der allgemein üblichen Weise, ohne besondere Erschwernis und grundsätzlich ohne fremde Hilfe auffindbar, zugänglich und nutzbar sind. Hierbei ist die Nutzung behinderungsbedingt notwendiger Hilfsmittel zulässig [14].“

2.2.2 Motivation für digitale Barrierefreiheit

Digitale Barrierefreiheit ist nicht nur für Menschen mit Beeinträchtigungen relevant. Denn Barrierefreiheit nutzt allen Menschen. Genauso wie ein Aufzug, der für Rollstuhlfahrer entwickelt wurde, auch von Menschen genutzt wird, die nicht auf einen Rollstuhl angewiesen sind, ist auch ein Text in leichter Sprache oft angenehmer zu lesen als beispielsweise in kompliziertem Amtsdeutsch [15]. Menschen können außerdem auch von vorübergehenden Beeinträchtigungen, wie einem gebrochenen Arm nach einem Unfall oder situativen Beeinträchtigungen, wie starker Sonneneinstrahlung, die das Erkennen der Inhalte eines Smartphone-Bildschirms erschwert, betroffen sein [16]. Auch sind nur 4 % aller dauerhaft beeinträchtigten Menschen mit ihrer Beeinträchtigung geboren worden; in den restlichen Fällen ist die Ursache der Beeinträchtigung meist eine Krankheit oder ein Unfall. Folglich wird jeder im Laufe seines Lebens von der ein oder anderen Form von Beeinträchtigung betroffen sein und kann damit von digitaler Barrierefreiheit profitieren [15]. Auch aus der geschäftlichen Perspektive ist die Umsetzung von digitaler Barrierefreiheit interessant. Laut Statistischem Bundesamt leben in Deutschland (Stand 2021) 7,8 Millionen Menschen (9,4 % der Gesamtbevölkerung) mit einer anerkannten Schwerbehinderung [2]. Dies ist

eine nicht zu verachtende Menge an potenziellen Kunden, die mit einem barrierefrei gestalteten Angebot erreicht werden können. Darüber hinaus ist ein barrierefrei gestaltetes Angebot, wie bereits erwähnt, für alle Menschen leichter bedienbar, was in einer allgemein höheren Kundenzufriedenheit resultieren kann [17].

2.2.3 Der aktuelle Stand von digitaler Barrierefreiheit im rechtlichen Kontext

In [Abschnitt 2.2.1](#) wurde bereits auf die Erwähnung von digitaler Barrierefreiheit innerhalb des BGG eingegangen. Diese Definition ist absichtlich sehr allgemein gehalten, da die digitalen Technologien kontinuierlich weiterentwickelt werden und sich somit im ständigen Wandel befinden. Deswegen sind konkrete Regelungen und Anforderungen an digitale Barrierefreiheit in separaten Rechtstexten ausgelagert, die im Folgenden genauer betrachtet werden [14].

2.2.3.1 Barrierefreie-Informationstechnik-Verordnung

Die Barrierefreie-Informationstechnik-Verordnung (BITV) trat 2004 in Kraft und wurde 2011 umfangreich als BITV 2.0 aktualisiert [14]. Diese Verordnung schreibt die barrierefreie Gestaltung von IT-Lösungen wie Webinhalte, mobile Anwendungen, elektronisch unterstützte Verwaltungsabläufe und graphische Programmoberflächen, die von öffentlichen Stellen angeboten werden, vor, mit dem Ziel diese für Menschen die von Beeinträchtigungen betroffen sind zugänglich zu machen. Die Anforderungen für die Umsetzung der digitalen Barrierefreiheit werden dabei nicht im Gesetz selbst geregelt, stattdessen wird auf die Harmonisierte Europäische Norm EN 301 549 verwiesen, die genaue Anforderungen an digitale Barrierefreiheit definiert. Darüber hinaus wird vorgeschrieben, dass Anforderungen, die von beeinträchtigten Nutzern benötigt, aber nicht durch die Harmonisierte Europäische Norm EN 301 549 abgedeckt werden, nach den Möglichkeiten des Stands der Technik dennoch umzusetzen sind. Außerdem schreibt das BITV 2.0 vor, dass Informationen in deutscher Gebärdensprache sowie in leichter Sprache bereitgestellt werden müssen und für alle IT-Lösungen eine Erklärung zur Barrierefreiheit, in der die konkreten Maßnahmen zur Umsetzung der Barrierefreiheit der IT-Lösung beschrieben werden, veröffentlicht werden muss [8].

2.2.3.2 Barrierefreiheitsstärkungsgesetz

Das Barrierefreiheitsstärkungsgesetz (BFSG) wurde am 15.06.2022 verabschiedet und ist die deutsche Umsetzung des European Accessibility Act (EU-Richtlinie 2019/882). Das BFSG regelt die barrierefreie Gestaltung von digitalen Produkten und Dienstleistungen, die durch Hersteller, Händler und Importeure ab dem 28. Juni 2025 in den Verkehr gebracht werden. Die Anforderungen an die Umsetzung der Barrierefreiheit im BFSG richten sich nach dem Stand der Technik sowie verschiedenen Standards und Normen, die durch die Bundesfachstelle Barrierefreiheit veröffentlicht und aktualisiert werden, darunter auch die Harmonisierten Europäischen Normen [9]. Für Produkte und Dienstleistungen, die vor dem 28. Juni 2025 in den Verkehr gebracht wurden, schreibt das BFSG vor, dass diese Produkte und Dienstleistungen die Vorgaben des BFSG erst ab dem 27. Juni 2030 erfüllen müssen (§ 38 Absatz 1-2 BFSG). Kleinunternehmen, also Unternehmen mit weniger als 10 Beschäftigten und einem Jahresumsatz von weniger als 2 Millionen Euro, sind von diesen Regelungen ausgenommen [9].

2.2.3.3 European Accessibility Act

Der European Accessibility Act (EAA) ist eine europäische Richtlinie, die die barrierefreie Gestaltung von Produkten und Dienstleistungen innerhalb des europäischen Binnenmarktes regelt. Ziel der Richtlinie ist es, einheitliche Regelungen zur Umsetzung von Barrierefreiheit innerhalb des europäischen Marktes zu schaffen und somit den Handel mit barrierefreien Produkten und Dienstleistungen innerhalb der Europäischen Union zu vereinfachen [10].

2.2.3.4 Web Content Accessibility Guidelines

Das BITV 2.0 bezieht sich bei den Anforderungen zur Umsetzung von digitaler Barrierefreiheit auf die Harmonisierte Europäische Norm EN 301 549. Nach dieser Norm sind bei der Umsetzung von digitaler Barrierefreiheit die Erfolgskriterien der Web Content Accessibility Guidelines (WCAG) Version 2.1 in den Konformitätsstufen A und AA verbindlich einzuhalten [18]. Die WCAG 2.1 ist ein internationaler Standard, der von der Web Accessibility Initiative (WAI), des World Wide Web Consortium (W3C) entwickelt wurde. Ziel ist es, einen einheitlichen Standard für die barrierefreie Gestaltung von Webinhalten bereitzustellen [19]. Die WCAG 2.1 sind aufgeteilt in

Prinzipien, Richtlinien, Erfolgskriterien und Techniken. Auf oberster Ebene stehen die Prinzipien Wahrnehmbarkeit, Bedienbarkeit, Verständlichkeit und Robustheit. Auf der darunterliegenden Ebene sind 13 Richtlinien zu finden, die jeweils einer der vier Prinzipien untergeordnet sind. Diese Richtlinien bilden Zielvorgaben für die barrierefreie Gestaltung von Inhalten. Auf der Ebene unter den Richtlinien werden für jede Richtlinie testbare Erfolgskriterien bereitgestellt. Diese sind wiederum in drei Konformitätsstufen A, AA und AAA eingeteilt, anhand derer das Maß der Barrierefreiheit beschrieben werden kann. Die Konformitätsstufen A und AA sind rechtlich verbindlich einzuhalten und beschreiben damit die Minimalanforderungen an die Umsetzung von Barrierefreiheit. Die Konformitätsstufe AAA beschreibt Maßnahmen, die darüber hinaus ein höheres Maß an Barrierefreiheit gewährleisten, aber nicht rechtlich bindend sind, da es nicht immer möglich ist, diese in allen Fällen anzuwenden. Auf der untersten Ebene der WCAG 2.1 finden sich konkrete technische Empfehlungen für die Umsetzung der Richtlinien [20].

2.3 Künstliche Intelligenz

Künstliche Intelligenz (KI) ist ein Oberbegriff, der verschiedene Methoden vereint, um Systeme zu schaffen, die intelligentes Verhalten simulieren können. Nach heutiger Auffassung kann KI wie folgt definiert werden [21]:

„Künstliche Intelligenz (KI) bezeichnet Systeme mit einem „intelligenten“ Verhalten, die ihre Umgebung analysieren und mit einem gewissen Grad an Autonomie handeln, um bestimmte Ziele zu erreichen [12].“

Im Gegensatz zu älteren Definitionen, die hauptsächlich auf dem Turing-Test basieren, und forderten, dass KIs in ihren Handlungen nicht von menschlichen Akteuren unterscheidbar sind, umfasst diese Definition eine deutliche größere Auswahl an Systemen und Techniken, mit der Gemeinsamkeit, dass diese in irgendeiner Form intelligentes Verhalten zeigen beziehungsweise nachahmen. Die unter dem Begriff KI zusammengefassten Systeme und Technologien lassen sich in drei Oberkategorien einteilen. Diese sind wissensbasierte KI, datengetriebene KI und spekulative zukünftige KI [21].

2.3.1 Wissensbasierte Künstliche Intelligenz

Wissensbasierte KI war das vorherrschende Vorgehen bei der Erstellung von KI-Systemen im Zeitraum der 1950er bis in die 1990er Jahre. Dabei wird das Wissen eines Experten der jeweiligen Disziplin als genauer Regelsatz codiert, anhand dessen ein Computer Entscheidungen treffen kann. Die Codierung erfolgte häufig in Form von if-then-else Code, bei dem dem Computer somit jede Entscheidung vorgegeben wurde. Vorteile dieses Vorgehens sind, dass die Entscheidungen, die ein solches System trifft, sehr nah an den Entscheidungen eines Menschen liegen, da diese direkt auf der Expertise eines Menschen basieren. Damit sind diese Systeme am besten für Aufgaben geeignet, in denen die Regeln eindeutig sind und sich die Rahmenbedingungen kaum bis gar nicht ändern. Denn ein Nachteil solcher Systeme ist es, dass jede Änderung dem System händisch beigebracht (einprogrammiert) werden muss. Die größere Limitierung ist, dass komplexere Probleme nur unter viel Aufwand oder schlichtweg nicht mit wissensbasierten KI-Systemen abgebildet werden können. Dennoch sind wissensbasierte KI-Systeme in vielen Bereichen, wie der Unterstützung von Menschen bei repetitiven Aufgaben oder der Steuerung von Maschinen, nützlich und werden bis heute verwendet [21].

2.3.2 Datengetriebene Künstliche Intelligenz

Datengetriebene KI, bekannter als Maschinelles Lernen (ML), beschreibt KI-Systeme, die selbstständig anhand von Daten lernen und darauf basierende Aussagen über ähnliche Daten generieren können. Im Bereich vom ML existieren verschiedene Methoden, um das selbstständige Lernen dieser Systeme zu realisieren, die großteils genauso alt sind wie die Methoden hinter wissensbasierter KI, aber erst durch die in den letzten Jahren steigende Verfügbarkeit von großen Datenmengen effizient eingesetzt werden konnten. Die wichtigste Vorgehensweise sind dabei Künstliche Neuronale Netze (KNN). KNNs sind in ihrer Funktionalität den elektrochemischen, neuronalen Netzwerken des (menschlichen) Gehirns nachempfunden. Die Funktionsweise des (menschlichen) Gehirns ist nicht abschließend erforscht. Bekannt ist, dass innerhalb des Gehirns Signale über ein komplexes Netzwerk von Neuronen transportiert und dass dabei die Signale sowie das unterliegende Netzwerk transformiert werden. Ein KNN besteht dabei aus einem Netzwerk von künstlichen Neuronen, das anstelle von Signalen Daten transportiert und diese währenddessen analog zu den Prozessen in einem Gehirn

transformiert. Das Netzwerk selbst wird ebenfalls transformiert, allerdings anders als im Gehirn, getrennt von der Verarbeitung der Daten in einer initialen Trainingsphase. In dieser wird das KNN basierend auf Trainingsdaten für den jeweiligen Einsatzzweck trainiert. Diese Trainingsdaten sind gelabelt, enthalten also die Eingabe und das dazugehörige angestrebte Ergebnis. Im Trainingsprozess erhält das KNN die Trainingsdaten als Eingabe, transportiert diese durch das Netzwerk aus künstlichen Neuronen und transformiert dabei diese Daten, was eine Ausgabe erzeugt. Diese wird mit dem Ergebnis der gelabelten Daten verglichen und aus der Unterschiedlichkeit beider wird ein Fehlerwert berechnet. Anschließend wird das KNN mittels Methoden aus dem Bereich der Analysis (die an dieser Stelle zu komplex sind, um ausreichend darauf einzugehen) transformiert, um diesen Fehler zu minimieren. Der gesamte Prozess wird mehrfach wiederholt, um auf einer möglichst großen Menge von Daten einen minimalen Fehlerwert zu erreichen. Nach dem Training erfolgt eine Testphase, bei der das KNN einen Datensatz von gelabelten Testdaten verarbeitet und wieder der Fehler aus den Ausgaben des KNN und den vorgegebenen Ergebnissen berechnet wird. Anhand dieser Fehlerwerte wird die Effizienz des KNN gemessen. Entscheidend ist dabei, dass andere Daten als die Trainingsdaten für die Testphase verwendet werden, da es vorkommen kann, dass ein KNN sich zu stark an die Testdaten anpasst, wodurch es nur in der Lage ist, diese Daten in der gewünschten Weise zu verarbeiten, aber bei der Verarbeitung von anderen Daten unbrauchbar ist. Wurde die Testphase erfolgreich abgeschlossen und ein ausreichend geringer Fehlerwert für die jeweilige Aufgabe erreicht, ist das KNN einsatzbereit und kann auf andere Daten effizient angewendet werden. Im Bereich des ML gibt es eine weite Reihe weiterer Techniken, die genutzt werden, um KI-Systeme für das Lösen einer bestimmten Aufgabe zu trainieren, wie beispielsweise Deep Learning, evolutionäre Algorithmen oder verstärkendes Lernen. Gemein haben diese Methoden, dass sie ein System erzeugen, dem die genauen Schritte zur Bearbeitung einer spezifischen Aufgabe nicht vorgegeben werden müssen, sondern diese aus Daten erlernt werden. Dies ist die bezeichnende Eigenschaft von datengetriebenen KIs [21].

2.3.3 Spekulative zukünftige Künstliche Intelligenz

Die in den beiden vorherigen Abschnitten beschriebenen Systeme haben die Limitierung, dass sie nur in bestimmten Einsatzfeldern intelligentes Verhalten

simulieren können. Man spricht deswegen auch von schwacher KI. Es gibt aber auch Überlegungen zur Schaffung von starken oder allgemeinen KIs. Eine solche KI könnte eine Intelligenz simulieren oder tatsächlich besitzen, die nicht auf einen spezifischen Bereich beziehungsweise Einsatzzweck beschränkt ist und die mit der Intelligenz von Menschen vergleichbar ist oder diese sogar übertrifft. Solche allgemeinen KI-Systeme sind nach dem heutigen Stand der Technik nicht realisierbar. Experten zufolge fehlt zur Umsetzung solcher Systeme mindestens eine Kerninnovation, wenn nicht mehrere. Konzepte, wie ein solches allgemeines KI-System geschaffen werden könnte, existieren, sind aber aufgrund von fehlender Rechenleistung und Technologie nur sehr begrenzt und meist gar nicht testbar [21].

2.4 Sprache-zu-Text Technologie

Sprache-zu-Text, bekannter als Speech-to-Text (STT) oder Automatic Speech Recognition (ASR), ist eine Technologie, die es ermöglicht, gesprochene Sprache in geschriebenen Text zu übersetzen [22].

2.4.1 Entwicklung von Speech-to-Text

Das erste STT-System wurde 1952 von Bell Laboratories entwickelt. Das sogenannte Audrey-System konnte einzelne Ziffern eines Sprechers erkennen [11]. Darauf basierend entwickelte IBM 1962 das sogenannte Shoebox-System, das in der Lage war, 16 verschiedene Worte zu erkennen [23]. In den folgenden Jahren wurde die Technologie kontinuierlich weiterentwickelt und Systeme wie das Harpy-System konnten Ende der 1970er Jahre bereits über 1000 Worte erkennen. Auch wurden in dieser Zeit, maßgeblich durch Bell Laboratories, erste Erfolge bei der Realisierung von Systemen, die mehr als nur eine einzige Stimme verstehen können, erzielt. Ein großer Fortschritt für STT in den 1980er Jahren war die Verwendung des statistischen Hidden Markov Model (HMM) in STT-Systemen. Im Gegensatz zu ihren Vorgängern, die hauptsächlich Muster in Audiosignalen anhand zuvor definierten Regeln Worten zuordneten, erlaubte die Verwendung von HMM für nicht erkannte Audiosignale die Wahrscheinlichkeit zu berechnen, welches Wort diese abbilden könnten. Mit dieser und weiteren statistischen Methoden konnte STT immer weiter verbessert werden und erreichte Anfang der 2000er Jahre bereits Genauigkeiten von annähernd 80 %. Ein weiterer bedeutender Schritt in der Entwicklung von STT war, als in den 2010er Jahren

durch Google Search und Siri diese Technologie erstmals einer breiten Masse an Menschen zugänglich gemacht wurde [11]. In den 2010er Jahren war es auch, dass die ersten auf ML basierenden Ansätze zur Realisierung von STT erforscht wurden. Diese lösten die zuvor verwendeten statistischen Modelle wie HMM bald ab und sind die Grundlage heutiger STT-Technologie [24]. Nach Angaben der Hersteller erreichen solche STT-Systeme in der Spitze bereits Genauigkeiten von 95,1 % und liegen damit im Bereich der Genauigkeit von Menschen bei der Transkription von gesprochener Sprache (Genauigkeit von 91,2 % bis 94,9 %) [11][13]. In folgenden Abschnitten dieser Arbeit bezieht sich die Erwähnung von STT auf solche auf ML basierende STT-Systeme.

2.4.2 Funktionsweise moderner Speech-to-Text Systeme

Die folgende Ausführung beschreibt nur das grundlegende Vorgehen bei der automatischen Transkription von gesprochener Sprache. Verschiedene Ansätze benutzen andere abgewandelte Vorgehensweisen.

Der Ablauf der automatischen Transkription von gesprochener Sprache durch STT-Systeme wird allgemein in 4 Schritten durchgeführt. Voraussetzung für die Durchführung ist das Trainieren eines akustischen und eines Sprachmodells mittels ML-Techniken. Das akustische Modell wird darauf trainiert, extrahierte Merkmale eines Audiosignals, sogenannten Phonemen, den kleinsten Lauteinheiten innerhalb einer Sprache, zuzuordnen. Das Sprachmodell wiederum wird darauf trainiert, zu bestimmen, wie Wörter und Ausdrücke in Relation zueinander in einer bestimmten Sprache vorkommen. Damit ermöglicht es zu bestimmen, wie wahrscheinlich ein Wort im Kontext des restlichen Satzes vorkommt. Der eigentliche Transkriptionsprozess beginnt mit der Vorverarbeitung (Pre-processing) der eingegebenen Audiodaten. Hier werden die Audiodaten für die Verarbeitung vorbereitet, indem beispielsweise Hintergrundrauschen oder Echos aus dem Audiosignal herausgefiltert werden. Der nächste Schritt ist das Extrahieren von signifikanten Merkmalen (Feature Extraction), in dem aus dem Audiosignal Merkmale wie Frequenz, Amplitude und Dauer extrahiert werden. Es folgt die Dekodierung (Decoding), wobei unter Zuhilfenahme der vorher trainierten akustischen und Sprachmodelle die Audiodaten in eine Sequenz von Worten übersetzt werden. Abschließend folgt die Nachbearbeitung (Post-processing), wobei

mittels Techniken aus der Computerlinguistik wie Grammatikregeln und Kontextanalyse Fehler im Transkript korrigiert werden [24].

2.4.3 Word Error Rate

Bei der Betrachtung von STT-Systemen wird als Maß für die Genauigkeit dieser Systeme häufig die Metrik „Word Error Rate“ (WER) verwendet, weswegen an dieser Stelle eine kurze Einführung in diese Metrik folgt. WER beschreibt das Verhältnis der Fehler in einem Transkript zu der Anzahl der Worte im originalen Text. WER wird wie folgt berechnet [25]:

$$\text{WER} = \frac{\text{Einfügungen} + \text{Ersetzungen} + \text{Löschungen}}{\text{Anzahl der Worte im originalen Text}}$$

Dabei sind:

- Ersetzungen: Die Anzahl der Worte, die im Transkript gegenüber dem Original durch andere Worte ersetzt wurden.
- Einfügungen: Die Worte, die in das Transkript eingefügt wurden, aber nicht im Original vorkommen.
- Löschungen: Die Anzahl der Worte, die im Original vorkommen, aber nicht in das Transkript aufgenommen wurden.

Damit beschreibt WER die Fehlerrate innerhalb eines Transkripts verglichen mit dem Original. Um die Genauigkeit eines Transkripts, basierend auf WER in Prozent, zu berechnen, wird diese Angabe von 100 % abgezogen. Somit bedeutet 20 % WER eine Genauigkeit von 80 % ($100 - 20 = 80$) [25]. Wenn in den folgenden Kapiteln der vorliegenden Arbeit von Genauigkeit gesprochen wird, bezieht sich dies auf diese auf WER basierende Definition von Genauigkeit, sofern nicht anders angegeben.

3 Forschungsfragen

In der vorliegenden Arbeit sollen folgende Forschungsfragen beantwortet werden:

Forschungsfrage 1: Wie können auf Künstlicher Intelligenz basierende Sprache-zu-Text-Systeme zur Umsetzung von digitaler Barrierefreiheit eingesetzt werden?

Forschungsfrage 2: Welche Genauigkeiten erreichen moderne, auf Künstlicher Intelligenz basierende Sprache-zu-Text-Systeme bei der Transkription von Inhalten in deutscher Sprache?

4 Methodik

Zur Beantwortung der in [Kapitel 3](#) aufgestellten Forschungsfragen wurde eine Recherche von für das Thema relevanter Fachliteratur durchgeführt. Diese erfolgte durch Webrecherche und der Nutzung von Google Scholar, wobei nur Fachartikel aus dem Zeitraum von 2014 bis 2024 berücksichtigt wurden. Anschließend wurden die Inhalte dieser Fachartikel aufgearbeitet und im Hinblick auf die Forschungsfragen ausgewertet.

Weiter wurden zwei Prototypen geplant und implementiert. Der erste Prototyp dient der automatischen Bestimmung der Genauigkeit von beliebigen STT-Systemen. Der zweite Prototyp erlaubt das STT-unterstützte Erstellen von Transkripten als Textalternative von Videoinhalten und soll als praktische Demonstration der Einsatzmöglichkeit von STT zur Umsetzung von digitaler Barrierefreiheit dienen. Für die Entwicklung der beiden Prototypen wurde zunächst eine ausführliche Planung unter Verwendung von Techniken aus dem Bereich des Software-Engineering durchgeführt [26]. Diese Planung diente anschließend jeweils als Grundlage der Implementierung der Prototypen, die in beiden Fällen in der Programmiersprache Python unter Verwendung der integrierten Entwicklungsumgebung Visual Studio Code und dem Versionskontrollsystem Git durchgeführt wurde [27-29]. Der Prototyp zur automatischen Bestimmung der Genauigkeit von beliebigen STT-Systemen wurde anschließend genutzt, um eine Auswertung der Genauigkeit von zwei ausgewählten STT-Systemen durchzuführen.

5 Stand der Forschung zu Einsatzmöglichkeiten und Genauigkeit von Sprache-zu-Text-Technologie für die Umsetzung von digitaler Barrierefreiheit

In den folgenden Abschnitten werden bekannte Einsatzmöglichkeiten von Sprache-zu-Text-Technologien basierend auf der Recherche von relevanter Fachliteratur vorgestellt. Im Anschluss werden potenzielle Einsatzmöglichkeiten dieser Technologien bei der Umsetzung von digitaler Barrierefreiheit untersucht sowie die Realisierbarkeit des Einsatzes dieser Technologien bewertet. Aufgrund der rasanten Entwicklung von STT Technologie wird nur Fachliteratur der letzten 10 Jahre, also ab einschließlich 2014, in die Betrachtung mit aufgenommen [11]. Es wird kein Anspruch auf Vollständigkeit erhoben.

5.1 Textalternativen von zeitbasierten Medien

Zeitbasierte Medien, wie Audio oder Video, sind für Menschen, die von Hörbeeinträchtigung und Gehörlosigkeit betroffen sind, nur schwer bis gar nicht nutzbar und damit eine Barriere [30]. STT-Technologie kann hier, wie in den folgenden Ausführungen gezeigt, theoretisch den Abbau von Barrieren unterstützen, indem mittels STT-Technologie Textalternativen aus diesen zeitbasierten Medien generiert werden. Die offensichtlichste Einsatzmöglichkeit von STT ist dabei auch die grundlegende Funktion von STT, nämlich das Erstellen von Transkripten für zeitbasierte Medien [31]. Darüber hinaus, und im Fokus der Forschung der letzten Jahre, ist die Nutzung dieser Transkripte zur Generierung von automatischen Untertiteln in Videos [32-34]. So haben César Domínguez et al. 2023 einen Prototyp entwickelt, der die automatisierte Generierung von Untertiteln für Videos ermöglicht, in dem die Audiospur eines Videos mit einem durch STT erstellten Transkript des Videos synchronisiert wird. Die Synchronisation von Audiospur und Transkript erfolgt dabei mittels eines „Connectionist Temporal Classification“ KNN. Nach ersten experimentellen Testläufen mit ihrem System kommen César Domínguez et al. zu der Einschätzung, dass ein solches System erst sinnvoll angewendet werden kann, wenn ein ausreichend akkurates STT-System verfügbar ist [32]. Das in dieser Arbeit angesprochene Problem der mangelnden Genauigkeit von STT-Systemen zeigt sich auch in der Studie von Larwan

Berke et al. aus 2017, in der von Hörbeeinträchtigung betroffene Personen befragt wurden und als Hauptproblem bei der Nutzung von mittels STT generierten Transkripten und Untertiteln die mangelnde Genauigkeit von STT und die damit verbundenen Probleme beim Verständnis der Inhalte dieser Transkripte und Untertitel identifizierten [35]. Dabei sind akkurate Transkripte für von Gehörlosigkeit betroffene Menschen besonders wichtig, da sie im Gegensatz zu hörenden Menschen nicht über die Möglichkeit verfügen, die Inhalte eines Transkriptes durch Anhören des originalen Materials zu verifizieren [36]. Das Problem der mangelnden Genauigkeit von STT-Systemen stellt damit die größte Hürde für den erfolgreichen Einsatz von STT zur Generierung von Textalternativen für zeitbasierte Medien dar und potenzielle Lösungen sind Gegenstand der Forschung der letzten Jahre. Solène Evain et al. haben in ihrer Arbeit von 2020 ein System zum automatischen Generieren von Untertiteln entwickelt, in dem das Problem der mangelnden Genauigkeit mittels eines themenspezifischen Vortrainings des Sprachmodells des eingesetzten STT-Systems gelöst werden soll. Das erstellte System ist dabei für den Einsatz innerhalb von Vorlesungen im akademischen Kontext ausgelegt. Die Implementierung des Systems nutzt STT zur Erzeugung eines Transkripts, das mittels aufgezeichneter Zeitstempel mit der Videoaufzeichnung der Vorlesung als Untertitel synchronisiert wird. Vor der Veröffentlichung der untertitelten Aufzeichnung erhält der Dozent der Veranstaltung die Möglichkeit, die generierten Untertitel manuell zu korrigieren. Das Vortraining des Systems ist dabei wie folgt implementiert. Der Dozent erstellt vor dem Einsatz des Systems eine Liste mit für das Thema der Veranstaltung relevanten Schlüsselwörtern, die an das System übergeben wird. Diese Schlüsselwörter nutzt das System, um automatisch Wikipedia-Artikel und verfügbare Vorlesungsmaterialien, in denen diese Schlüsselwörter vorkommen, zusammenzutragen, mit denen anschließend das Sprachmodell des STT-Systems trainiert wird, um die Erkennung von thematisch relevanten Fachbegriffen zu steigern. Mittels dieses Vorgehens konnten Solène Evain et al. eine Steigerung der Genauigkeit von durchschnittlich 59,91 % auf 66,71 % erzielen. Diese eher geringen Steigerungen der Genauigkeit wollen Solène Evain et al. zukünftig durch bessere Aufnahmequalität und erweitertes Training der Sprachmodelle steigern, um das manuelle Editieren der generierten Untertitel obsolet werden zu lassen [33]. Einen anderen Ansatz verfolgen Korbinian Kuhn et al. in ihrer Arbeit von 2023. Ziel innerhalb dieser Arbeit ist es, das automatische Untertiteln von Videostreams im Rahmen von Live-Veranstaltungen in Echtzeit zu realisieren. Der Lösungsansatz des Problems der mangelnden Genauigkeit

von STT-Systemen basiert in dieser Arbeit auf der Korrektur der erzeugten Untertitel durch Menschen in Echtzeit. Dazu wurde ein System implementiert, das es einer Gruppe von drei bis fünf Personen ermöglicht, die erzeugten Untertitel während der Live-Veranstaltung kollaborativ zu korrigieren. Während der Veranstaltung erhalten die Personen, die die Korrektur durchführen sollen, den Videostream und die zugehörigen mittels STT generierten Untertitel über die Benutzeroberfläche des Systems. Die generierten Untertitel werden diesen Personen dabei in einer Textbox angezeigt, in der auch die Korrektur durchgeführt wird. Die Auswertung von praktischen Versuchen mit diesem System ergab, dass durch das manuelle Korrigieren der Untertitel in Echtzeit eine durchschnittliche Genauigkeit der Untertitel von 87 % erzielt werden konnte. Es wurde beobachtet, dass die Personen, die die Korrekturen durchführten, besonders Fehler korrigierten, die die Bedeutung des Inhalts des präsentierten Videomaterials verzerren und kleinere grammatikalische Fehler eher ignorierten. Abschließend kamen Korbinian Kuhn et al. zu der Einschätzung, dass das Vorgehen, auf dem ihr System basiert, Potenzial hat, aber weiter angepasst werden muss und zum Stand der Veröffentlichung ihrer Arbeit nicht zum Einsatz unter realen Bedingungen geeignet ist [34]. Die Kombination von durch STT generierten Transkripten und anschließender Korrektur dieser durch Menschen ist auch der Fokus der Arbeit von Yashesh Gaur et al. aus 2016. In dieser untersuchen Yashesh Gaur et al. die Möglichkeiten, den Prozess des manuellen Erstellens von Transkripten für zeitbasierte Medien durch Menschen unter Zuhilfenahme von STT zu beschleunigen. Dazu wurden die Auswirkungen der Genauigkeit innerhalb von mittels STT erstellten Transkripten auf die Korrektur dieser durch Menschen untersucht. Es wurde eine Studie mit 160 Teilnehmern durchgeführt, in der diese mittels STT generierte Transkripte mit verschiedenen Genauigkeiten (in Abständen von 5 %) korrigierten, sowie ein Transkript ohne Unterstützung von STT erstellten, wobei jeweils die benötigte Bearbeitungszeit gemessen wurde. Die Auswertung zeigte, dass mittels STT generierte Transkripte mit einer Genauigkeit von mehr als 70 % den Prozess im Vergleich zur Erstellung eines Transkripts ohne STT-Unterstützung beschleunigen. Weiter wurde festgestellt, dass Transkripte, deren Genauigkeit unter 70 % liegt, den Prozess so weit verlangsamen können, dass die Erstellung eines Transkripts ohne STT-Unterstützung in diesem Fall effizienter ist [37].

5.2 Übersetzung von gesprochener Sprache in Gebärdensprache

Gebärdensprache ist eine visuelle Form von zwischenmenschlicher Kommunikation, die auf Gestik, Körpersprache und Mimik basiert [38]. Gebärdensprache ist die primäre Form der Kommunikation von Menschen, die von Gehörlosigkeit betroffen sind. Es existieren in verschiedenen Ländern und Regionen verschiedene Gebärdensprachen. Diese sind dabei nicht die Repräsentation der gesprochenen Sprache der jeweiligen Region, sondern eigenständige Sprachen, die sich begründet in der Art der Kommunikation fundamental von gesprochenen Sprachen unterscheiden [39]. Aufgrund des Umstandes, dass Menschen, die von Gehörlosigkeit betroffen sind, Gebärdensprache als primäre Form der Kommunikation nutzen, sind in den letzten Jahren verschieden Versuche unternommen worden, eine automatische Übersetzung von gesprochener Sprache in Gebärdensprache zu realisieren. Einige dieser Systeme nutzen dabei STT als Grundlage dieser Übersetzung und werden im Folgenden genauer betrachtet. Das Vorgehen beim Einsatz von STT-Technologie als Grundlage der automatischen Übersetzung von gesprochenen Sprachen in Gebärdensprachen, das in den hier behandelten Arbeiten vorgestellt wird, ist oberflächlich betrachtet in allen diesen Arbeiten sehr ähnlich. STT wird verwendet, um aus Aufnahmen von gesprochener Sprache ein Transkript zu erstellen, das unter Zuhilfenahme von Natural Language Processing (NLP) in seine einzelnen Worte zerlegt wird. Diese werden anschließend mit einem Datensatz von Worten, die in Gebärdensprache dargestellt sind, abgeglichen, und aus den Übereinstimmungen der extrahierten Worte mit den Gebärden wird ein Video generiert, das das Transkript in Gebärdensprache darstellt [40-44]. Hemang Monga et al., (2021, Indische Gebärdensprache) und Ritika Bharti et al. (2019, Indische Gebärdensprache) nutzen für die Repräsentation der Gebärden Videoaufzeichnungen von Menschen, die diese Gebärden sprechen [40-41]. Bhavinkumar Devendrabhai Patel et al. (2020, Malaysische Gebärdensprache) und Mahmoud M. El-Gayyar et al. (2016, Arabische Gebärdensprache) hingegen nutzen Videos von vorher generierten 3D-Avataren als Repräsentation der Gebärden [42-43]. Letztlich nutzen Bandi Rupendra Reddy et al. (2020, Indische Gebärdensprache) Aufzeichnungen von Händen im GIF-Format, um die Gebärden darzustellen [44]. Die Systeme haben außerdem gemein, dass Worte, für die keine Übereinstimmungen innerhalb der verwendeten Datensätze gefunden werden können, in ihre einzelnen

Buchstaben zerlegt werden und anhand von Gebärden, die die Buchstaben in der jeweiligen Gebärdensprache darstellen, buchstabiert werden [40-44]. Der Erfolg des Einsatzes solcher Systeme ist nach Angaben von Mahmoud M. El-Gayyar et al. vor allem von der Genauigkeit der verwendeten STT-Systeme und der Menge an Gebärden innerhalb der verwendeten Datensätze abhängig [43]. Diese Einschätzung deckt sich mit der Beurteilung von Ritika Bharti et al., die ebenfalls die Genauigkeit von STT als wichtigstes Kriterium für den erfolgreichen Einsatz ihres Systems identifizieren sowie der Bewertung von Hemang Monga et al., die als Voraussetzung für den Einsatz ihres Systems eine Vergrößerung des Datensatzes von Gebärden angeben [40-41]. Mahmoud M. El-Gayyar et al. haben außerdem mit ihrem System eine Nutzerstudie mit 68 von Hörbeeinträchtigung betroffenen Personen durchgeführt. In dieser haben die Probanden das System mit vorher definierten Sätzen verwendet und wurden anschließend gebeten, die Nutzbarkeit des Systems auf einer Skala von 0 bis 100 zu bewerten. Der Durchschnittswert dieser Bewertung liegt nach der Auswertung bei 79,8, woraus sich schließen lässt, dass die Probanden das System als nutzbar einstufen. Eine anschließende Befragung der Probanden ergab, dass diese einen Menschen für die Repräsentation der Gebärden dem innerhalb des Systems verwendeten 3D-Avatar vorziehen würden, da die Mimik und Gestik eines Menschen es den Probanden einfacher macht, die dargestellten Gebärden zu erkennen [43].

5.3 Sprachsteuerung von digitalen Systemen.

Das Bedienen von digitalen Systemen mittels der konventionellen Methoden, Tastatur / Maus und Bildschirm stellt für Menschen, die von Blindheit oder motorischen Einschränkungen betroffen sind, eine Barriere dar. Sprachsteuerung kann hier eingesetzt werden, um diesen Menschen den Zugang zu digitaler Technologie zu ermöglichen [45]. Dabei können durch STT generierte Transkripte als Grundlage für die Sprachsteuerung von digitalen Systemen genutzt werden. Dieses Vorgehen wird bereits von Sprachassistenten wie Alexa oder Siri verwendet, die STT nutzen, um aus Spracheingaben von Nutzern Befehle zu extrahieren, um entsprechende Funktionalitäten auszuführen [46]. In den vergangenen Jahren wurden verschiedene Anwendungsmöglichkeiten dieses Vorgehens in der Forschung weiter erkundet. So haben Jaspreet Kaur und Rohit Agnihotri 2023 einen E-Mail-Client-Prototyp zur Verwaltung und Bedienung von Gmail-Accounts mittels Sprachsteuerung entwickelt.

Das System nutzt STT, um gesprochene Nutzereingaben in Textform zu überführen und diese gegen vorher definierte Befehle abzugleichen, die bei einer Übereinstimmung ausgeführt werden. Die Funktionalität dieses Systems umfasst den sprachgesteuerten Login, das Verfassen und Senden von E-Mails mittels Spracheingabe sowie das Empfangen von E-Mails. Dabei nutzt das System außerdem Text-zu-Sprache (eng. Text-to-Speech, kurz TTS), um dem Nutzer eingegangene E-Mails und den Inhalt von durch den Nutzer verfassten E-Mails vor dem Absenden vorzulesen [47]. Weiter haben Yu Zhong et al. 2014 ein System zur Steuerung des Android-Betriebssystems mittels Spracheingaben entwickelt. In dem System wird STT verwendet, um Spracheingaben des Nutzers in Text zu übersetzen. Diese Texte werden mit den verfügbaren Befehlen des Systems abgeglichen und bei einem Treffer werden die entsprechenden Funktionen ausgeführt. Der Funktionsumfang umfasst dabei die grundlegenden Funktionen des Android-Betriebssystems, wie das Aufrufen von Apps oder das Ein-/Ausschalten von WLAN und Bluetooth. Weiter nutzt das System die Android-Accessibility-APIs, um Elemente (wie Buttons oder Textfelder) innerhalb von Apps auszulesen und mittels deren Beschreibungen Befehle für die Sprachsteuerung dieser Elemente dynamisch zu erzeugen. Das System wurde als Beta im Google Play Store veröffentlicht. Die Auswertung der Kommentare im Google Play Store durch Yu Zhong et al. ergab, dass Nutzer das System als ersten Schritt für die Entwicklung einer umfassenden Sprachsteuerung für Android ansehen. Laut Yu Zhong et al. sind die größten Probleme beim Einsatz ihres Systems die mangelnde Genauigkeit von STT und inkonsistente oder teilweise nicht vorhandene Beschreibungen von Elementen innerhalb von Apps durch deren Entwickler, die der Sprachsteuerung von Apps im vorgestellten System zugrunde liegen [45]. Vinayak Iyer et al. haben 2020 einen Prototyp zur Bedienung von Websites mittels Sprachsteuerung entwickelt und damit erste Schritte in Richtung eines sprachgesteuerten Internets unternommen. Der Prototyp ist modular aufgebaut, unterteilt in ein Hauptmenü und mehrere Website-Module. Das Hauptmenü implementiert STT, um Benutzereingaben in Textform zu übersetzen. Die Textform wird mit den vorhandenen Befehlen des Prototyps verglichen, und bei einem Treffer wird die entsprechende Funktion ausgeführt. Für das Hauptmenü sind die nötigen Funktionen implementiert, um eine Website mittels Sprachsteuerung im Standardbrowser des Nutzers aufzurufen. Die Website-Module wiederum implementieren jeweils die nötigen Funktionen zur Sprachsteuerung einer spezifischen Website. Analog zum Hauptmenü wird in den Website-Modulen ebenfalls STT

verwendet, um gesprochene Nutzerbefehle für die jeweilige Website auszuführen. Ergebnisse werden dem Nutzer mittels TTS ausgegeben. Außerdem werden alle Spracheingaben, die der Nutzer tätigt, ebenfalls mittels TTS an den Nutzer zurückgegeben, und der Nutzer muss die Korrektheit seiner Eingaben bestätigen, bevor eine Aktion ausgeführt wird. Zum Stand der Veröffentlichung der Arbeit von Vinayak Iyer et al. wurden Module für Google, Gmail und Wikipedia implementiert. Somit erlaubt das System das sprachgesteuerte Suchen über Google, Senden und Empfangen von E-Mails und das Suchen und Vorlesen von Wikipedia-Artikeln [48]. Die Umsetzung der Sprachsteuerung des Internets ist ebenfalls das Ziel von Julia Cambre et al. in ihrer Arbeit von 2021. Sie haben die Extension FirefoxVoice für den Firefox-Browser entwickelt, über die der Firefox-Browser, einschließlich Websites, per Sprache gesteuert werden kann. Es wurde ein weiterer Funktionsumfang implementiert, der es erlaubt Webseiten aufzurufen, Aktionen auf Webseiten auszuführen (wie das Abspielen eines Audiostreams), direkt nach Informationen zu fragen (wie die aktuelle Wettervorhersage), mittels der Standardsuchmaschine des Nutzers eine Websuche durchzuführen, Inhalte von Webseiten vorzulesen (mittels TTS) und Browser-Aktionen (wie Tabnavigation / Tabverwaltung oder das Löschen des Browserverlaufes) auszuführen. STT wird verwendet, um Spracheingaben des Nutzers in Text zu übersetzen. Dieser Text wird mit implementierten Intentionen abgeglichen und bei einer Übereinstimmung wird die entsprechende Intention ausgeführt. Im Falle, dass keine zur Spracheingabe des Nutzers passende Intention gefunden werden kann, wird eine Websuche mit der Standardsuchmaschine durchgeführt. Intentionen sind dabei Handler-Funktionen, die Funktionalität für eine spezifische Aufgabe ausführen. Um diese Funktionen auf möglichst vielen Webseiten anbieten zu können, wurde in FirefoxVoice Funktionalität implementiert, die relevante Elemente einer Webseite durch automatische Auswertung des Document Object Model erkennen und für die Nutzung durch Intentionen verfügbar machen kann. Julia Cambre et al. haben nach der Implementierung von FirefoxVoice eine geschlossene Beta mit anschließender Befragung der Nutzer zu ihren Eindrücken des Systems sowie eine offene Beta durchgeführt, in der das Nutzerverhalten aufgezeichnet und direkt in der Extension Nutzerfeedback gesammelt wurde. Die Auswertung der geschlossenen Beta ergab, dass die meisten Nutzer die Nutzungserfahrung von FirefoxVoice positiv bewerten. Dabei gefiel den Nutzern besonders die Möglichkeit, normale Browserfunktionen (wie Tabnavigation) per Sprachsteuerung durchführen zu können, und viele Nutzer gaben an,

das es ihnen einfacher fiel, bestimmte Aktionen über die Sprachsteuerung von FirefoxVoice auszuführen als mit konventionellen Methoden. Die Auswertung der in der offenen Beta gesammelten Daten zum Nutzerverhalten zeigte, dass Nutzer FirefoxVoice am häufigsten für Websuchen einsetzen (was aber auch darin begründet ist, dass die Websuche ausgeführt wird, wenn ein Nutzerbefehl mit keiner anderen Intention übereinstimmt), aber auch um spezifische Seiten aufzurufen, Musik abzuspielen, Inhalte von Webseiten vorlesen zu lassen oder zur Tabnavigation. Die Sammlung von Nutzerfeedback innerhalb der Extension bestand aus einer optionalen Befragung der Nutzer nach jedem Funktionsaufruf, bei dem die Nutzer gefragt wurden, ob die Extension die gewünschte Funktion ausgeführt hat („Did we get this right?“) und mittels eines Lachenden oder traurigen Smileys Feedback geben konnten. Die Auswertung hat hier ergeben, dass 67,8 % der Nutzeranfragen durch FirefoxVoice korrekt umgesetzt wurden. Außerdem wurde ein Feedbackmechanismus implementiert, der Nutzer, die FirefoxVoice deinstalliert haben, bei der Deinstallation nach den Gründen dieser Entscheidung gefragt hat. Die Auswertung ergab, dass Gründe für eine Deinstallation unter anderem die mangelhafte Geschwindigkeit, der Umstand, dass Nutzer eine andere Art der Browser-Interaktion der sprachgesteuerten Interaktion vorziehen, technische Probleme oder mangelnde Genauigkeit bei der Spracherkennung waren [49]. Das Projekt wurde mittlerweile eingestellt und ist nicht mehr im Add-on-Store von Firefox verfügbar [50].

5.4 Genauigkeit von aktuellen Sprache-zu-Text-Systemen

Aus den in den vorherigen Abschnitten vorgestellten Arbeiten ist zu erkennen, dass die Genauigkeit von STT-Systemen ein fundamentaler Faktor für den erfolgreichen Einsatz dieser Systeme darstellt. Deswegen ist eine Betrachtung der aktuell durch STT-Systeme erreichbaren Genauigkeit für die Bewertung der Einsatzmöglichkeiten von STT-Systemen unter realistischen Bedingungen unabdingbar. Dafür wird die Arbeit von Korbinian Kuhn et al. aus 2023 näher betrachtet, in der die Genauigkeit von 11 ausgewählten aktuellen STT-Systemen untersucht wurde. Korbinian Kuhn et al. haben dazu vier Datensätze verwendet, um Transkripte durch diese Systeme generieren zu lassen und diese Transkripte anschließend für die Untersuchung der Genauigkeit zu nutzen. Die Datensätze umfassen dabei drei durch Korbinian Kuhn et al. erstellte Datensätze, einer bestehend aus Aufnahmen von englischsprachigen Muttersprachlern

(English), ein weiterer, der Aufnahmen von Sprechern enthält, die Englisch als Zweitsprache sprechen (ESL) und letztlich ein Datensatz bestehend aus Aufnahmen von deutschsprachigen Muttersprachlern (German). Ergänzend dazu wurde der Test außerdem mit dem LibriSpeech Datensatz durchgeführt. Eine Auflistung der verwendeten Sprachmodelle und der erreichten Genauigkeiten bezogen auf die Metrik WER ist in Tabelle 1 aufgeführt [51].

Tabelle 1: Durchschnittlicher WER in Prozent nach STT-System und Datensatz

Vendor	English	LibriSpeech	ESL	German
Amazon	4.4	6.1	7.1	18.0
AssemblyAI	4.5	4.2	5.9	13.2
Deepgram	8.3	12.8	11.4	19.3
Google	20.1	23.6	28.1	18.1
IBM	11.2	13.2	17.3	20.6
Microsoft	4.4	5.9	6.7	10.1
Rev AI	4.4	7.0	6.7	19.2
SpeechText.AI	8.4	11.3	14.1	21.4
Speechmatics	3.3	3.6	4.6	8.0
Tencent	4.6	4.1	7.3	–
Whisper (large-v2)	2.9	3.3	3.3	5.0
Average	7.0	8.6	10.2	15.3

Quelle: Korbinian Kuhn et al., 2023, S.12 [51]

Die Angaben in Tabelle 1 sind auf Basis einer normalisierten Form der erstellten Transkripte berechnet worden. Alle Texte wurden in Kleinbuchstaben gewandelt und alle Satzzeichen wurden entfernt, bevor die WER für diese berechnet wurde. Korbinian Kuhn et al. geben an, dass dieses Vorgehen die berechnete WER deutlich verbessert hat. So lag die WER des Durchschnitts aller Datensätze über alle verwendeten STT-Systeme ohne Normalisierung bei 21,83 % und mit Normalisierung verbesserte sich die WER auf 10,16 %. Außerdem geben Korbinian Kuhn et al. zu bedenken, dass es sich bei diesen Angaben um Mittelwerte handelt und die Genauigkeit von STT-Systemen je nach eingegebenem Audio stark variiert. Auswertungen der einzelnen erstellten Transkripte zeigen, dass die Genauigkeit in den Extremen im Bereich zwischen 0 % WER und 53,8 % WER liegt. Weiter zeigt die Auswertung der Daten in Tabelle 1, dass die Sprache, die

mittels STT transkribiert wird, einen entscheidenden Einfluss auf die Genauigkeit der Systeme hat. So ist bereits eine Verschlechterung der Genauigkeit für Sprecher, die Englisch als Zweitsprache sprechen, im Vergleich zu Muttersprachlern zu erkennen. Bei der Transkription von deutschsprachigen Sprechern ist die Genauigkeit nochmals deutlich geringer. Korbinian Kuhn et al. gehen davon aus, dass die verfügbare Anzahl von Trainingsdaten einen direkten Einfluss auf die Genauigkeit von STT-Systemen bei der Transkription dieser Sprachen haben und dass die Genauigkeit für Sprachen, für die nur geringe Mengen an Trainingsdaten verfügbar sind, geringer ausfällt [51].

5.5 Bewertung der Einsatzmöglichkeiten und Genauigkeit der vorgestellten Systeme zur Umsetzung von digitaler Barrierefreiheit

Auf Basis der in den vorherigen Abschnitten vorgestellten Arbeiten können als Einsatzmöglichkeiten von STT-Systemen zur Umsetzung von digitaler Barrierefreiheit das Generieren von Textalternativen für zeitbasierte Medien (Transkripte und Untertitel), die automatische Übersetzung von gesprochener Sprache in Gebärdensprache sowie die Sprachsteuerung von digitalen Systemen identifiziert werden.

Die Generierung von Textalternativen für zeitbasierte Medien kommt dabei besonders Menschen, die von Hörbeeinträchtigungen betroffen sind, zugute und würde diesen Menschen den Zugang zu diesen Inhalten ermöglichen [30]. Die erfolgreiche Anwendung der Generierung von Transkripten und Untertiteln als Textalternative von zeitbasierten Medien ist dabei stark von der Genauigkeit der verwendeten STT-Systeme abhängig [32][35]. Die Auswertung der Genauigkeit zeigt, dass aktuelle STT-Systeme beim Einsatz für englische Sprache durchschnittlich eine Genauigkeit von 89,8 % bis 93 % erreichen und damit nur im oberen Bereich an die Genauigkeiten von durch Menschen erstellten Transkripten (durchschnittliche Genauigkeit von 91,2 % bis 94,9 %) heranreichen. Im Deutschen liegt die durchschnittlich erreichte Genauigkeit bei 84,7 % und damit unter der Genauigkeit von menschlichen Transkriptoren [13][51]. Auch wenn durch Menschen erstellte Transkripte nicht immer fehlerfrei sind, zeigt sich, dass die Fehler, die Menschen bei der Transkription machen, meist kleinere

grammatikalische Fehler darstellen und Menschen bestrebt sind, Fehler, die den Inhalt des Gesagten verzerren, zu vermeiden [13][34]. Bei STT-Technologie sind die Fehler aber mehr oder weniger zufällig, woraus sich schließen lässt, dass STT-Systeme für den vollautomatischen Einsatz höhere Genauigkeiten als Menschen erzielen müssten, um den Inhalt des Gesagten verständlich wiedergeben zu können. Dennoch sind die durchschnittlichen Genauigkeiten aktueller STT-Systeme ausreichend, um menschliche Transkriptoren bei der Erstellung von Transkripten und Untertiteln in der Form zu unterstützen, das Transkriptoren durch STT erstellte Transkripte korrigieren und dadurch der Prozess der Transkription beschleunigt wird, was den Prozess des Erstellens von Textalternativen für zeitbasierte Medien und damit die Umsetzung dieses Bereiches von digitaler Barrierefreiheit vereinfacht [37].

Die automatische Übersetzung von gesprochener Sprache in Gebärdensprache kann für Menschen, die von Gehörlosigkeit betroffen sind, eine weitere Möglichkeit (neben Transkription und Untertitelung) darstellen, um Zugang zu den Inhalten von zeitbasierten Medien zu erlangen. Damit kann die automatische Übersetzung von zeitbasierten Medien in Gebärdensprache den Abbau von Barrieren, die von Gehörlosigkeit betroffene Menschen bei der Benutzung von digitalen Technologien erfahren, unterstützen. Die Nutzung der in [Abschnitt 5.2](#) vorgestellten Systeme zur Umsetzung von digitaler Barrierefreiheit setzt eine ausreichend hohe Genauigkeit der verwendeten STT-Systeme sowie genügend große Datensätze von Repräsentationen von Worten als Gebärden in der jeweiligen Gebärdensprache voraus [43]. Die in den vorgestellten Arbeiten verwendeten Datensätze enthalten dabei über alle Arbeiten zwischen 50 und 3268 Gebärden [40-44]. Das aktuelle Standardwerk der Gebärden der deutschen Gebärdensprache enthält ca. 18.000 Gebärden, die zu ca. 250.000 Ausdrücken kombiniert werden können [52]. Basierend auf diesem Umstand kann die Größe der in den vorgestellten Arbeiten verwendeten Datensätzen von Gebärden als mangelhaft für einen praktischen Einsatz angesehen werden. Zwar wurde das System von Mahmoud M. El-Gayyar et al. von den Probanden innerhalb der durchgeführten Nutzerstudie als einsetzbar bewertet, doch wurde das System innerhalb der Studie nur mit vorgefertigten Sätzen genutzt, wodurch das Problem der zu geringen Größe von Datensätzen von Gebärden nicht zum Tragen kam [43]. Weiter besteht der Umstand, dass Gebärdensprachen nicht die Repräsentation der jeweiligen gesprochenen Sprachen darstellen, sondern eigene Sprachen sind, die sich fundamental von gesprochenen

Sprachen unterscheiden [39]. Darauf bezogen ist es fraglich, ob die Zuordnung von Gebärden zu Worten einer gesprochenen Sprache eine sinnvolle Vorgehensweise der Übersetzung von gesprochener Sprache in Gebärdensprache darstellt. Aufgrund dieser Probleme und der unzureichenden Genauigkeit der verfügbaren STT-Technologien sind die vorgestellten Systeme zur automatischen Übersetzung von gesprochener Sprache in Gebärdensprache nicht für den Einsatz zur Umsetzung von digitaler Barrierefreiheit geeignet, bilden aber eine Grundlage für die zukünftige Weiterentwicklung dieser Technologien.

Die Sprachsteuerung von digitalen Systemen (mit Rückmeldungen dieser Systeme mittels TTS) kann eingesetzt werden, um digitale Systeme für Menschen, die von Blindheit oder motorischen Einschränkungen betroffen sind, barrierefrei zu gestalten. Durch den Einsatz von Spracheingaben zur Steuerung von digitalen Systemen würde die Notwendigkeit der Verwendung von Tastatur und Maus oder Bildschirm zur Bedienung von digitalen Systemen entfallen und somit dazu beitragen Barrieren, die diese Menschen bei der Nutzung von digitalen Systemen behindern, abzubauen. [45].

Potenzielle Einsatzmöglichkeiten von STT als Grundlage der Sprachsteuerung von digitalen Systemen zur Steigerung von digitaler Barrierefreiheit sind basierend auf den in [Abschnitt 5.3](#) vorgestellten Systemen die Sprachsteuerung von einzelnen Anwendungen, Betriebssystemen sowie Internetseiten beziehungsweise Webbrowsern [45][47-49]. Dabei ist der Einsatz zur Sprachsteuerung von einzelnen Anwendungen im Verhältnis am einfachsten realisierbar, da hier im Gegensatz zu Betriebssystemen und Webbrowsern nur eine begrenzte vorher definierbare Anzahl an Funktionen gesteuert werden muss. Für die Steuerung von Betriebssystemen und Webseiten bzw. Browsern müssen Sprachbefehle entweder dynamisch erzeugt werden oder es müssen für jede Anwendung, die in einem Betriebssystem ausführbar ist beziehungsweise jede Website spezifische Sprachbefehle separat implementiert werden [45][48-49]. Deswegen kann aktuell ausschließlich die Sprachsteuerung von einzelnen Anwendungen als potenziell nutzbare Einsatzmöglichkeit von STT als Grundlage der Sprachsteuerung von digitalen Systemen angesehen werden, wohingegen die Sprachsteuerung von Betriebssystemen und Webseiten bzw. Webbrowsern weiterer Forschung bedarf, um neue Strategien zu entwickeln, um die Sprachsteuerung von bei der Entwicklung unbekannten Funktionen zu ermöglichen. Außerdem besteht bei allen diesen Anwendungen die Grundvoraussetzung, dass die eingesetzten STT Systeme eine ausreichend hohe

Genauigkeit erreichen müssen, damit die Nutzereingaben in allen Fällen korrekt erfasst werden können [45][49]. Aus der Auswertung der Nutzerdaten des Projekts FirefoxVoice geht hervor, dass 32,2 % aller Spracheingaben nicht korrekt erfasst wurden und dass ein Grund für die Deinstallation der Extension die mangelnde Genauigkeit des eingesetzten STT-Systems ist [49]. Deswegen wird die auf STT basierende Sprachsteuerung von digitalen Systemen aktuell nicht als real einsetzbare Möglichkeit der Umsetzung von digitaler Barrierefreiheit bewertet und es bedarf weiterer Forschung, um einen effizienten Einsatz dieser Technologien zu ermöglichen.

In Bezug auf die in [Kapitel 3](#) aufgestellte Forschungsfrage 1 lässt sich festhalten, dass STT aktuell bei der Umsetzung von digitaler Barrierefreiheit nur eine unterstützende Funktion bei der Erstellung von Transkripten und Untertiteln einnehmen kann. Die Anwendung als Grundlage der Übersetzung von gesprochener Sprache in Gebärdensprache und der Sprachsteuerung von digitalen Systemen ist aufgrund mangelnder Genauigkeit und weiterer Probleme bei der Umsetzung dieser Technologien aktuell nicht möglich. Dennoch haben diese Systeme Potenzial und bilden eine interessante Grundlage für weitere Forschung. In Bezug auf Forschungsfrage 2 hat die Auswertung der Arbeit von Korbinian Kuhn et al. ergeben, dass die aktuell von STT-Systemen erreichbare durchschnittliche Genauigkeit bei der Transkription von deutschsprachigen Inhalten mit 84,7 % unter der Genauigkeit von menschlichen Transkriptoren einzuordnen ist [13][51]. Auch die durch Hersteller angegebene Genauigkeit von 95,1 % (siehe [Kapitel 2.4.1](#)) wurde im Durchschnitt nicht erreicht [11]. Es darf aber nicht außer Acht gelassen werden, dass das STT-System Whisper in der Auswertung durch Korbinian Kuhn et al. eine Genauigkeit von 95 % bei der Transkription von deutschsprachigen Inhalten erreichte (siehe [Tabelle 1](#)), was einerseits im Bereich der Genauigkeit von menschlichen Transkriptoren liegt und weiter sehr nah an die durch Hersteller angegebene Genauigkeit heranreicht [13][11][51]. In der in [Kapitel 8.3](#) durchgeführten Überprüfung der Genauigkeit des Whisper STT-Systems konnte dieses Ergebnis allerdings nicht repliziert werden.

6 Prototype: STT Accuracy Analyzer

In [Kapitel 5](#) wurde als Grundlage für den automatisierten Einsatz von STT-Systemen im Bereich von digitaler Barrierefreiheit eine ausreichend hohe Genauigkeit dieser Systeme identifiziert. Es wurde weiter festgestellt, dass die von aktuellen Systemen erreichten Genauigkeiten nur für einen unterstützenden Einsatz ausreichend sind. Im Hinblick auf die Entwicklung dieser Systeme der vergangenen Jahre besteht die Möglichkeit, dass STT-Systeme in Zukunft Genauigkeiten erreichen, die für einen vollautomatischen Einsatz ausreichen [11]. Es wurde deswegen mit „STT Accuracy Analyzer“ der Prototyp einer Anwendung entwickelt, die es ermöglicht, die Genauigkeiten von beliebigen STT-Systemen anhand ausgewählter Metriken automatisch zu ermitteln, um die zukünftige Entwicklung der Genauigkeit von STT-Systemen einfach erfassen zu können. Im Folgenden wird die Planung und Implementierung dieses Prototyps betrachtet.

6.1 Planung

Bevor der Prototyp implementiert werden konnte, wurde zunächst eine genaue Planung und Untersuchung der Umsetzungsmöglichkeiten der einzelnen Funktionalitäten durchgeführt. Diese wird im Folgenden beschrieben.

6.1.1 Anforderungen

In einer ersten Anforderungsanalyse wurden die folgenden minimalen Anforderungen zur Umsetzung des Prototyps identifiziert. Diese sind:

- Umsetzung der Anwendung als Desktop-Anwendung.
- Steuerung der Anwendung über eine graphische Benutzeroberfläche.
- Möglichkeit, beliebige STT-Systeme unabhängig von der Programmiersprache, in der diese implementiert wurden, zu testen.
- Durchführung des Tests basierend auf einem Testdatensatz, der mit der Anwendung mitgeliefert wird (Standardtestdatensatz).
- Optional die Verwendung eines benutzerdefinierten Testdatensatzes anstelle des Standardtestdatensatzes.

- Automatische Generierung von Transkripten basierend auf dem Testdatensatz durch das zu testende STT-System.
- Automatische Berechnung von Metriken zur Bestimmung der Genauigkeit (wie beispielsweise WER) basierend auf den erstellten Transkripten und Testdaten.
- Möglichkeit, die Testergebnisse in einem Tabellenformat für die weitere Auswertung zu exportieren.
- Datenbanksystem zur effizienten Verwaltung der anfallenden Daten.

6.1.2 Use Cases

Basierend auf den identifizierten Anforderungen wurden die folgenden Use Cases erarbeitet (siehe Tabelle 2: Use Cases STT Accuracy Analyzer). Eine ausführliche Beschreibung der einzelnen Use Cases wird in Anhang 1 bereitgestellt (siehe [Anhang 1: Use Cases STT Accuracy Analyzer](#)).

Tabelle 2: Use Cases STT Accuracy Analyzer

Nr.	Use Case	Beschreibung
1	Initialisierung der Anwendung	Die Anwendung wird durch den Nutzer gestartet. Die graphische Benutzeroberfläche zeigt dem Nutzer die Eingabe-Seite an. Der Datenbank-Dienst initialisiert die Datenbank.
2	Einlesen der Konfigurationsdaten	Nach dem Start der Anwendung wird der Nutzer gebeten, Daten, die der Konfiguration der Anwendung dienen und zu ihrer Ausführung benötigt werden, bereitzustellen. Der Nutzer gibt die benötigten Daten über die graphische Benutzeroberfläche ein. Die Anwendung überprüft, dass die Daten valide sind und speichert diese in der Datenbank.
3	Initialisierung des Transkriptions-Dienstes	Der Transkriptions-Dienst wird initialisiert. Die Testdaten werden in die Datenbank eingelesen und dem Transkriptions-Dienst bereitgestellt.
4	Transkriptionsprozess	Der Transkriptions-Dienst generiert für alle Testdaten ein Transkript. Die Ergebnisse werden in der Datenbank gespeichert.
5	Initialisierung des Auswertungs-Dienst	Der Auswertungs-Dienst wird initialisiert und bekommt die Transkriptionsergebnisse durch den Datenbank-Dienst bereitgestellt.
6	Auswertungs-	Der Auswertungs-Dienst berechnet für alle Transkriptions-


	prozess	ergebnisse die Auswertungsmetriken. Die Ergebnisse werden in der Datenbank gespeichert.
7	Anzeigen der Ergebnisse	Die Mittelwerte der Auswertungsmetriken werden dem Nutzer über die graphische Benutzeroberfläche angezeigt.
8	Exportieren der Ergebnisse	Die Ergebnisse des Transkriptions- und Auswertungsprozesses werden an einen durch den Nutzer spezifizierten Speicherort als Tabelle exportiert.
9	Beenden der Anwendung	Der Nutzer beendet die Anwendung. Der Datenbank-Dienst bereinigt die Datenbank.

Quelle: Eigene Auflistung

6.1.3 Architektur

Auf Basis der Anforderungen und Use Cases wurde folgende Software-Architektur als Grundlage der Implementierung des Protoyps entworfen (siehe Abbildung 1). Im Folgenden werden die geplanten Komponenten der Software-Architektur sowie deren Interaktionen untereinander vorgestellt.

Abbildung 1: Architekturdiagramm Prototyp STT Accuracy Analyzer



Quelle: Eigene Darstellung

6.1.3.1 Anwendungsfunktionen

Die Anwendungsfunktionen umfassen die Kernfunktionalitäten der geplanten Anwendung. Diese sind:

6.1.3.1.1 Datenbank-Dienst

Der Datenbank-Dienst stellt die Schnittstelle zwischen den einzelnen Komponenten der Anwendung und der Datenbank dar und umfasst alle Funktionalitäten zum Speichern und Laden von Daten in und aus dieser.

6.1.3.1.2 Eingabe-Verifizierungsdienst

Der Eingabe-Verifizierungsdienst stellt die Funktionalitäten zum Überprüfen der Korrektheit der durch den Nutzer eingegebenen Konfigurationsdaten bereit. Die Konfigurationsdaten umfassen den Befehl zum Starten des zu testenden STT-Systems sowie optional die Pfade zu einem benutzerdefinierten Datensatz, den der Nutzer zur Überprüfung des STT-Systems verwenden möchte. Der Eingabe-Verifizierungsdienst erhält diese Daten von der graphischen Benutzeroberfläche und prüft, ob diese korrekt sind. Im Falle, dass die Konfigurationsdaten fehlerhaft sind, übermittelt der Eingabe-Verifizierungsdienst Fehlermeldungen, die genaue Beschreibungen der Fehler der Konfigurationsdaten enthalten, an die graphische Benutzeroberfläche, sodass der Nutzer über diese informiert wird und seine Eingaben gezielt korrigieren kann. Im Falle, dass die Konfigurationsdaten korrekt sind, werden diese zwecks Speicherung in der Datenbank an den Datenbank-Dienst übergeben.

6.1.3.1.3 Transkriptions-Dienst


Der Transkriptions-Dienst stellt die Funktionalitäten zur Generierung der für die Auswertung benötigten Transkripte bereit. Dazu bezieht der Transkriptions-Dienst die Testdaten vom Datenbank-Dienst. Diese nutzt der Transkriptions-Dienst, um mittels des zu testenden STT-Systems Transkripte zu generieren. Dabei sendet der Transkriptions-Dienst in jedem Schritt Fortschrittsberichte an die graphische Benutzeroberfläche, damit diese dem Nutzer Informationen über den Fortschritt des Transkriptionsprozesses anzeigen kann. Nach Abschluss des Transkriptionsprozesses übergibt der Transkriptions-Dienst die erstellten Transkripte an den Datenbank-Dienst.

6.1.3.1.4 Auswertungs-Dienst

Die Aufgabe des Auswertungs-Dienstes ist die Berechnung der Auswertungsmetriken, die der Bewertung der Genauigkeit des zu testenden STT-Systems dienen sollen. Dazu bezieht der Auswertungs-Dienst zunächst die durch den Transkriptions-Dienst generierten Transkripte sowie die fehlerfreien Transkripte aus dem Testdatensatz über den Datenbank-Dienst aus der Datenbank. Diese Daten nutzt der Auswertungs-Dienst zur Berechnung der Auswertungsmetriken (siehe [Abschnitt 6.1.4](#)). Während der Berechnung sendet der Auswertungs-Dienst in jedem Schritt Fortschrittsberichte an die graphische Benutzeroberfläche, damit diese dem Nutzer Informationen über den Fortschritt des Auswertungsprozesses anzeigen kann. Nach Abschluss des Auswertungsprozesses übergibt der Auswertungs-Dienst die Ergebnisse an den Datenbank-Dienst, der diese in der Datenbank speichert.

6.1.3.1.5 Datenbank

Abbildung 2: Datenbankdiagramm



Quelle: Eigene Darstellung

Die Datenbank wird zum Verwalten der Konfigurationsdaten, Testdaten, generierten Transkripte und berechneten Auswertungsmetriken verwendet. Die geplante Datenbankstruktur wurde als Datenbankdiagramm festgehalten (siehe Abbildung 2). Es sollen vier Tabellen verwaltet werden. Eine alleinstehende Tabelle zum Speichern der Konfigurationsdaten (Configuration) sowie drei in Relation stehende Tabellen zum Verwalten des Testdatensatzes (TestData), der erstellten Transkripte (TranscriptionResults) und berechneten Auswertungsmetriken (AnalysisResults). Dabei ist jedem Eintrag in der Tabelle der Testdaten genau ein Eintrag der Tabelle der erstellten Transkripte und diesen ist jeweils genau ein Eintrag aus der Tabelle der berechneten Auswertungsmetriken zugeordnet. Diese Relation soll später für den Export der Daten in einem Tabellenformat genutzt werden, da geplant ist, dass die Datenbank immer nur die Daten der aktuellen Ausführung der Anwendung enthält.

6.1.3.2 Externe Komponenten

Die externen Komponenten umfassen das eingebundene STT-System, dessen Genauigkeit untersucht werden soll. Dieses wird vom Transkriptions-Dienst ausgeführt, wofür dieser den in den Konfigurationsdaten enthaltenen Befehl zum Starten des STT-Systems nutzt. Das STT-System erhält dabei vom Transkriptions-Dienst eine Audiodatei, aus der es ein Transkript erstellt, das es anschließend an den Transkriptions-Dienst zurückgibt.

6.1.3.3 Graphische Benutzeroberfläche

Die graphische Benutzeroberfläche dient der Interaktion des Nutzers mit der Anwendung sowie der Ablaufsteuerung der Ausführung der einzelnen Komponenten. Innerhalb der Use Cases wurden bereits die drei benötigten Seiten der graphischen Benutzeroberfläche, nämlich Eingabe-Seite, Testprozess-Fortschritt-Seite und Ergebnis-Seite, identifiziert. Diese werden im Folgenden anhand von Mockups vorgestellt.

6.1.3.3.1 Eingabe-Seite

Die Eingabe-Seite dient der Eingabe von Konfigurationsdaten durch den Nutzer (siehe Abbildung 3). Für die Eingabe werden Textboxen verwendet. In die erste Textbox gibt der Nutzer den Befehl zum Starten des gewünschten STT-Systems ein. Diese Angabe ist

für die Ausführung der Anwendung zwingend erforderlich. Optional kann der Nutzer über die zweite und dritte Textbox die Pfade zu Audiodaten und einem Dokument, das die Label (fehlerfreie Transkripte) für diese enthält, eingeben. Dafür stehen zwei Buttons bereit, die einen Systemdialog zum Auswählen von Dateien öffnen, was dem Nutzer die Auswahl dieser Dateien vereinfachen soll.

Abbildung 3: Eingabe-Seite

Bitte den Terminal Befehl zum Starten des KI-Modell-Subprozesses als durch Kommata separierten Text eingeben (Benötigt).

Textbox

Bitte ein Verzeichnis mit MP3-Testdaten auswählen (Optional).

Textbox

Verzeichnis auswählen

Bitte eine TSV-Datei auswählen (Optional).

Textbox

TSV-Datei auswählen

Testprozess Starten

Quelle: Eigene Darstellung

Bei Eingabe der Pfade zu einem benutzerdefinierten Testdatensatz wird dieser anstelle des Standardtestdatensatzes für die Überprüfung des ausgewählten STT-Systems verwendet. Nachdem alle Konfigurationsdaten eingegeben wurden, kann der Nutzer die Ausführung des Testprozesses über den „Testprozess Starten“ Button ausführen. Dabei wird im ersten Schritt eine Überprüfung der Konfigurationsdaten ausgeführt. Im Falle, dass dabei ein Fehler der Eingabe gefunden wird, werden dem Nutzer entsprechende Fehlermeldungen unterhalb der jeweiligen Textbox angezeigt (siehe Abbildung 4).

Abbildung 4: Eingabe-Seite Fehlerzustand

Bitte den Terminal Befehl zum Starten des KI-Modell-Subprozesses als durch Kommata separierten Text eingeben (Benötigt).

Textbox

Fehlermeldung

Bitte ein Verzeichnis mit MP3-Testdaten auswählen (Optional).

Textbox

Verzeichnis auswählen

Fehlermeldung

Bitte eine TSV-Datei auswählen (Optional).

Textbox

TSV-Datei auswählen

Fehlermeldung

Testprozess Starten


Quelle: Eigene Darstellung

Ist die Überprüfung hingegen erfolgreich, wird dem Nutzer die Testprozess-Fortschritt-Seite angezeigt.

6.1.3.3.2 Testprozess-Fortschritt-Seite

Auf der Testprozess-Fortschritt-Seite werden dem Nutzer Informationen über den Fortschritt des Testprozesses angezeigt (siehe Abbildung 5).


Abbildung 5: Testprozess-Fortschritt-Seite



Quelle: Eigene Darstellung

Die Anzeige des Fortschritts erfolgt über zwei Fortschrittsbalken und zugehörige Texte. Der erste Fortschrittsbalken zeigt den Fortschritt des Transkriptions-Prozesses und der zugehörige Text zeigt die Anzahl der durchzuführenden Testschritte sowie den aktuellen Testschritt dynamisch an. Der zweite Fortschrittsbalken zeigt dieselben Informationen für den Auswertungsprozess. Mittels des unten stehenden Abbrechen-Buttons kann der Nutzer die Ausführung des Testprozesses jederzeit abbrechen, wodurch die Anwendung beendet wird.


Abbildung 6: Testprozess-Fortschritt-Seite Fehlerzustand



Quelle: Eigene Darstellung

Im Falle, dass während des Testprozesses ein Fehler auftritt, wird dem Nutzer über den Text des jeweiligen Fortschrittsbalkens eine entsprechende Fehlermeldung angezeigt (siehe Abbildung 6). In diesem Fall wird der Abbrechen-Button durch einen Beenden-Button ersetzt. Der Nutzer hat daraufhin nur die Möglichkeit, die Anwendung zu beenden. Im Falle, dass der Testprozess erfolgreich abgeschlossen wurde, wird der Abbrechen-Button durch einen „Ergebnisse anzeigen“ Button ersetzt (siehe Abbildung 7).

Abbildung 7: Testprozess-Fortschritt-Seite Erfolgszustand



Transkript Generierung: Fertig

Fortschrittsbalken

Auswertung: Fertig

Fortschrittsbalken

Ergebnisse Anzeigen


Quelle: Eigene Darstellung

Durch Drücken dieses Buttons kann der Nutzer sich die Ergebnisse des Testprozesses auf der Ergebnis-Seite anzeigen lassen.

6.1.3.3.3 Ergebnis-Seite

Die Ergebnis-Seite soll dem Nutzer einen groben Überblick über die Ergebnisse des Testprozesses ermöglichen und erlaubt es ihm darüber hinaus, die Testergebnisse zu exportieren (siehe Abbildung 8).

Abbildung 8: Ergebnis-Seite



Ergebnisse Mittelwerte:

Auflistung der Mittelwerte der berechneten Metriken

Ergebnisse exportieren

Fertigstellen

Quelle: Eigene Darstellung

Dazu werden dem Nutzer auf der Ergebnis-Seite die Mittelwerte der im Auswertungsprozess ermittelten Auswertungsmetriken angezeigt. Über den „Ergebnisse exportieren“ Button kann der Nutzer die einzelnen Ergebnisse als Tabellendokument exportieren. Dazu öffnet die Anwendung einen Systemdialog, über den der Nutzer den Speicherort sowie den Dateinamen für die Ergebnisse auswählen kann, worauf diese exportiert werden. Durch Drücken des Fertigstellen-Buttons kann der Nutzer die Ausführung der Anwendung beenden.

6.1.4 Auswertungsmetriken

Im Folgenden werden die Metriken vorgestellt, die im geplanten System zur Bewertung der Genauigkeit der zu testenden STT-Systeme verwendet werden sollen. Eine dieser Metriken ist Word Error Rate. Diese wurde bereits in [Kapitel 2.4.3](#) vorgestellt.

6.1.4.1 Character Error Rate

Character Error Rate (CER) ist das Verhältnis der Fehler auf Ebene der Buchstaben in einem Transkript zu allen Buchstaben des originalen Textes. CER ist damit sehr ähnlich zu WER, nur dass statt fehlerhaft transkribierten Worten fehlerhaft transkribierte Buchstaben betrachtet werden. CER wird folgendermaßen berechnet [53]:

$$\text{CER} = \frac{\text{Einfügungen} + \text{Ersetzungen} + \text{Löschungen}}{\text{Anzahl der Buchstaben im originalen Text}}$$

Dabei sind:

- Ersetzungen: Die Anzahl der Buchstaben, die im Transkript gegenüber dem Original durch andere Buchstaben ersetzt wurden.
- Einfügungen: Die Buchstaben, die in das Transkript eingefügt wurden, aber nicht im Original vorkommen.
- Löschungen: Die Anzahl der Buchstaben, die im Original vorkommen, aber nicht in das Transkript aufgenommen wurden [53].

6.1.4.2 Match Error Rate

Match Error Rate (MER) beschreibt, wie viele Worte prozentual in einem Transkript falsch erkannt oder eingefügt wurden. MER wird wie folgt berechnet [54]:

$$\text{MER} = \frac{\text{Ersetzungen} + \text{Löschungen} + \text{Einfügungen}}{\text{Anzahl der Worte im originalen Text} + \text{Einfügungen}}$$

Dabei sind:

- Ersetzungen: Die Anzahl der Worte, die im Transkript gegenüber dem Original durch andere Worte ersetzt wurden.
- Einfügungen: Die Worte, die in das Transkript eingefügt wurden, aber nicht im Original vorkommen.
- Löschungen: Die Anzahl der Worte, die im Original vorkommen, aber nicht in das Transkript aufgenommen wurden [54].

6.1.4.3 Word Information Lost

Word Information Lost (WIL) beschreibt prozentual die Menge der falsch erkannten Worte in einem Transkript gegenüber dem originalen Text. WIL berechnet sich wie folgt [55]:

$$WIL = 1 - \frac{\text{Anzahl der korrekt erkannten Worte}}{\text{Anzahl der Worte im originalen Text}} + \frac{\text{Anzahl der korrekt erkannten Worte}}{\text{Anzahl der Worte im Transkript}}$$

6.1.4.4 Jaro Winkler Distance

Jaro Winkler Distance (JWD) beschreibt, wie unterschiedlich ein Transkript im Vergleich zum originalen Text ist. Der berechnete Wert liegt im Bereich von 0 bis 1. 0 beschreibt, dass das Transkript exakt dem Original entspricht, wogegen ein Wert von 1 bedeutet, dass die beiden Texte keine Gemeinsamkeiten aufweisen. Die Berechnung der JWD basiert auf der Berechnung der Jaro-Ähnlichkeit (sim_j) [56]:

$$\text{sim}_j = \begin{cases} 0 & \text{wenn } m = 0 \\ \frac{1}{3} * \left(\frac{m}{L_t} + \frac{m}{L_o} + \frac{m - t}{m} \right) & \text{sonst} \end{cases} \quad JWD = 1 - (\text{sim}_j + i * p * (1 - \text{sim}_j))$$

Dabei sind:

- m: Die Anzahl der im Transkript und originalen Text übereinstimmenden Buchstaben.
- t: Die Anzahl der im Transkript gegenüber dem originalen Text vertauschten Buchstaben. Vertauscht bedeutet hier, dass zwei Buchstaben im Transkript vorkommen, die auch im originalen Text vorkommen, aber ihre Positionen vertauscht sind.
- L_t : Die Anzahl der Buchstaben im Transkript.
- L_o : Die Anzahl der Buchstaben im originalen Text.

- i: Die Anzahl von Buchstaben, die am Beginn des Textes im Transkript identisch zum originalen Text sind.
- p: Ein Faktor, der festlegt, wie stark der Einfluss von i auf das Ergebnis sein soll. Winkler empfiehlt hier einen Wert von 0,1 [56].

6.1.5 Standardtestdatensatz


Für den Standardtestdatensatz, der mit der Anwendung mitgeliefert werden soll, ist vorgesehen, den Open-Source-Datensatz Common Voice zu verwenden. Common Voice ist ein Projekt von Mozilla, mit dem Ziel, Sprachdatensätze zum Trainieren von ML-Anwendungen für verschiedene Sprachen frei verfügbar zu machen. Die Sammlung der Sprachdaten basiert im Common Voice Projekt auf Crowdsourcing [57]. Der deutsche Common Voice Datensatz ist aufgeteilt in einen Trainingsdatensatz und einen Testdatensatz. Da nicht auszuschließen ist, dass Common Voice für das Training von STT-Systemen, die potenziell mit der geplanten Anwendung getestet werden sollen, verwendet wurde, soll ausschließlich der Testdatensatz des Common Voice Datensatzes als Standardtestdatensatz der geplanten Anwendung eingesetzt werden. Dieser Datensatz besteht nach eigener Auswertung aus 16183 Audiodateien, die etwas über 27 Stunden gesprochenes deutsches Audiomaterial beinhalten. Dabei sind in den Labels dieses Datensatzes neben den Transkripten auch das Geschlecht der Sprecher festgehalten, allerdings nur für einen kleinen Teil der Daten. Nach diesen Angaben stammen 285 Audiodateien von weiblichen Sprechern, 1335 von männlichen. Zu den verbleibenden 14563 gibt es keine Angaben, es wird aber davon ausgegangen, dass auch in diesen die Anzahl der männlichen Sprecher überwiegt. Der Common Voice Datensatz soll trotz dieses Problems verwendet werden, da kein besserer frei verfügbarer Datensatz gefunden werden konnte und die zeitlichen Beschränkungen der Bearbeitung der vorliegenden Arbeit es nicht zulassen, einen eigenen Datensatz zu erstellen.

6.2 Implementierung

Auf Basis der im vorherigen Abschnitt vorgestellten Planung wurde die Anwendung erfolgreich implementiert. Die Implementierung der Anwendung wurde in Python umgesetzt [27]. Der implementierte Code steht auf GitHub zur Verfügung (https://github.com/Marlon-Ringel/STT_Accuracy_Analyzer). Die implementierten

Funktionalitäten lassen sich in fünf übergeordnete Schritte zusammenfassen, die im Aktivitätsdiagramm „Ablauf Prototyp STT Accuracy Analyzer“ aufgeführt sind (siehe Abbildung 9). Im Folgenden werden die implementierten Funktionalitäten der einzelnen Schritte anhand von Sequenzdiagrammen genauer erklärt.

Abbildung 9: Aktivitätsdiagramm Ablauf Prototyp STT Accuracy Analyzer




Quelle: Eigene Darstellung

6.2.1 Initialisierung der Anwendung

Nach dem Start der Anwendung durch den Nutzer wird diese zunächst initialisiert (siehe Abbildung 10). Der erste Schritt ist dabei die Initialisierung der graphischen Benutzeroberfläche. Es werden die drei Seiten der graphischen Benutzeroberfläche, Eingabe-Seite, Testprozess-Fortschritt-Seite sowie Ergebnis-Seite initialisiert. Die Implementierung dieser Seiten folgt dabei dem in [Abschnitt 6.1.3.3](#) vorgestellten Mockups (siehe Abbildungen 3 bis 8) und ist mit der Python Standard-Library „tkinter“ umgesetzt worden [58]. Im nächsten Schritt wird die Datenbank zunächst zurückgesetzt. Dies ist nötig, da die Datenbank aktuell nur für das Speichern der Daten der aktuellen Ausführung der Anwendung ausgelegt ist und das Zurücksetzen der Datenbank sicherstellt, dass diese keine Daten aus vorherigen Ausführungen enthält. Die Datenbank ist eine SQLite-Datenbank und wurde mit der Python Standard-Library „sqlite3“ implementiert [59]. Im Anschluss wird die Datenbank initialisiert. Dazu wird zunächst eine neue Datenbankdatei erzeugt und anschließend werden die nötigen Tabellen der Datenbank angelegt. Die implementierte Struktur der Datenbank folgt

dabei dem in [Abschnitt 6.1.3.1.5](#) vorgestellten Datenbankdiagramm (siehe Abbildung 2). Als Letztes zeigt die graphische Benutzeroberfläche die Eingabe-Seite an, womit die Initialisierung der Anwendung abgeschlossen ist.

Abbildung 10: Sequenzdiagramm Initialisierung der Anwendung




Quelle: Eigene Darstellung

6.2.2 Einlesen der Konfigurationsdaten

Bevor die Anwendung den Test eines STT-Systems ausführen kann, müssen die nötigen Konfigurationsdaten eingelesen werden (siehe Abbildung 11). Das erste Konfigurationsdatum ist der Befehl, der für die Ausführung des STT-Systems, das der Nutzer testen möchte, verwendet wird. Dabei handelt es sich um den Terminal-Befehl, mit dem der Nutzer das STT-System normalerweise starten würde. Enthält dieser Leerzeichen, müssen die einzelnen Teile durch Kommata getrennt werden, damit der Befehl später korrekt verarbeitet werden kann. Dieses Konfigurationsdatum wird zwingend für die Ausführung der Anwendung benötigt. Optional kann der Nutzer außerdem einen benutzerdefinierten Testdatensatz für den Test des STT-Systems auswählen. Dazu muss der Nutzer die Pfade zu einem Verzeichnis, mit den Audiodateien des Datensatzes, sowie zu einem Dokument, das die Labels (fehlerfreie Transkripte) für diese Audiodateien enthält, angeben. Hat der Nutzer die gewünschten Konfigurationsdaten über die graphische Benutzeroberfläche eingegeben, kann er den

„Testprozess Starten“ Button drücken, um den Testprozess zu beginnen. Bevor dieser jedoch ausgeführt wird, wird zunächst eine Validierung der eingegebenen Konfigurationsdaten durchgeführt, um sicherzustellen, dass die Anwendung korrekt ausgeführt werden kann. Dazu initialisiert die graphische Benutzeroberfläche zunächst den Eingabe-Verifizierungsdienst und übergibt die Konfigurationsdaten an diesen. Anschließend führt der Eingabe-Verifizierungsdienst die Validierung aus.

Abbildung 11: Sequenzdiagramm Einlesen der Konfigurationsdaten



Quelle: Eigene Darstellung


In diesem Prozess wird zunächst geprüft, ob der Befehl zum Starten des zu testen STT-System eingegeben wurde. Ist dies der Fall, wird das STT-System testweise ausgeführt und im Zuge dieser Ausführung wird geprüft, ob das STT-System mit dem eingegebenen Startbefehl ausgeführt werden kann und ob bei der Ausführung Fehler auftreten. Die Ergebnisse dieser Überprüfungen werden als Validierungsstatus in einem Array festgehalten. Anschließend prüft der Eingabe-Verifizierungsdienst, ob die Pfade für einen benutzerdefinierten Testdatensatz eingegeben wurden und wenn dies der Fall ist, ob diese Pfade innerhalb des Dateisystems des Systems, auf dem die Anwendung ausgeführt wird, existieren. Die Ergebnisse dieser Überprüfungen werden ebenfalls dem Validierungsstatus hinzugefügt. Dieser wird anschließend an die graphische Benutzeroberfläche zurückgegeben. Diese nutzt den Validierungsstatus, um das Ergebnis der Validierung zu erfassen. War dabei mindestens eine der Überprüfungen fehlerhaft, nutzt die graphische Benutzeroberfläche den Validierungsstatus, um dem Nutzer genaue Fehlermeldungen, die beschreiben, welche Konfigurationsdaten inwiefern fehlerhaft sind, auf der Eingabe-Seite anzuzeigen. Der Nutzer kann daraufhin die eingegebenen Konfigurationsdaten korrigieren und erneut versuchen, den Testprozess über den „Testprozess Starten“ Button zu starten. Ab hier wiederholt sich das beschriebene Vorgehen so lange, bis der Nutzer fehlerfreie Konfigurationsdaten eingibt. Ist dies der Fall, werden die Konfigurationsdaten durch den Eingabe-Verifizierungsdienst an den Datenbank-Dienst übergeben. Enthalten die Konfigurationsdaten dabei nicht die Pfade zu einem benutzerdefinierten Testdatensatz, so übergibt der Eingabe-Verifizierungsdienst dem Datenbank-Dienst anstelle dieser die Pfade zum Standardtestdatensatz. Als Standardtestdatensatz wird der in [Abschnitt 6.1.5](#) vorgestellte Datensatz Common Voice verwendet [57]. Der Datenbank-Dienst speichert die Konfigurationsdaten in der Datenbank. Damit ist das Einlesen der Konfigurationsdaten abgeschlossen und die graphische Benutzeroberfläche zeigt dem Nutzer die Testprozess-Fortschritts-Seite.

6.2.3 Ausführen des Transkriptionsprozesses

Nach der erfolgreichen Eingabe und Validierung der Konfigurationsdaten wird der Transkriptionsprozess gestartet (siehe Abbildung 12). Dazu initialisiert die graphische Benutzeroberfläche zunächst den Transkriptions-Dienst. Dieser bezieht über den Datenbank-Dienst die Konfigurationsdaten aus der Datenbank. Anschließend initiiert

der Transkriptions-Dienst das Einlesen des Testdatensatzes durch den Datenbank-Dienst. Der Datenbank-Dienst liest den Testdatensatz in die Datenbank ein und übergibt anschließend die Testdaten an den Transkriptions-Dienst. Zu Beginn und Ende dieses Prozesses sendet der Transkriptions-Dienst jeweils einen Fortschrittsbericht an die graphische Benutzeroberfläche, dass der Prozess des Einlesens des Testdatensatzes begonnen hat beziehungsweise abgeschlossen ist.

Abbildung 12: Sequenzdiagramm Ausführen des Transkriptionsprozesses



Quelle: Eigene Darstellung


Die graphische Benutzeroberfläche zeigt diese Fortschrittsberichte auf der Testprozess-Fortschritt-Seite an, um den Nutzer über den Status der Ausführung zu informieren. Anschließend kann der eigentliche Prozess der Generierung der Transkripte beginnen. Dazu berechnet der Transkriptions-Dienst zuerst anhand des eingelesenen Testdatensatzes die Anzahl der auszuführenden Transkriptionsschritte. Anschließend beginnt die Generierung der Transkripte. Im ersten Schritt sendet der Transkriptions-Dienst einen Fortschrittsbericht an die graphische Benutzeroberfläche, der die Nummer des aktuellen Transkriptionsschritts sowie die Anzahl aller nötigen Transkriptionsschritte enthält. Diese Informationen nutzt die graphische Benutzeroberfläche, um dem Nutzer anzuzeigen, welcher Transkriptionsschritt aktuell ausgeführt wird und um den Fortschrittsbalken zu aktualisieren. Der Transkriptions-Dienst startet das STT-System mittels des Startbefehls aus den Konfigurationsdaten. Das STT-System wird dabei mittels der Standard-Python-Library „subprocess“ als Subprozess ausgeführt [60]. Der Transkriptions-Dienst übergibt dem STT-System den Pfad der im aktuellen Testschritt zu transkribierenden Audiodatei über stdin. Das STT-System generiert ein Transkript für diese Audiodatei und gibt dieses über stdout an den Transkriptions-Dienst zurück [61]. Dieser Prozess wird für alle Einträge im Testdatensatz wiederholt. Anschließend übergibt der Transkriptions-Dienst die erzeugten Transkripte an den Datenbank-Dienst und dieser speichert diese in der Datenbank. Als Letztes sendet der Transkriptions-Dienst einen Fortschrittsbericht an die graphische Benutzeroberfläche, dass der Transkriptionsprozess abgeschlossen ist. Diese zeigt diese Information auf der Testprozess-Fortschritt-Seite an, um den Nutzer über den erfolgreichen Abschluss des Transkriptionsprozesses zu informieren.

6.2.4 Ausführen des Auswertungsprozesses

Nach erfolgreichem Abschluss des Transkriptionsprozesses wird der Auswertungsprozess ausgeführt (siehe Abbildung 13). Dazu initialisiert die graphische Benutzeroberfläche zunächst den Auswertungs-Dienst. Dieser bezieht die Auswertungsdaten (Transkripte, die im Transkriptionsprozess generiert wurden, sowie die Label des Testdatensatzes) über den Datenbank-Dienst aus der Datenbank. Anschließend kann der eigentliche Auswertungsprozess beginnen. Der

Auswertungs-Dienst berechnet zunächst die Anzahl der auszuführenden Auswertungsschritte anhand der Auswertungsdaten.

Abbildung 13: Sequenzdiagramm Ausführen des Auswertungsprozesses



Quelle: Eigene Darstellung

Danach sendet der Auswertungs-Dienst einen Fortschrittsbericht, der die Nummer des aktuellen Auswertungsschritts sowie die Anzahl aller Auswertungsschritte enthält, an die graphische Benutzeroberfläche, die diese Daten nutzt, um dem Nutzer den aktuellen


Fortschritt des Auswertungsprozesses anzuzeigen und den zugehörigen Fortschrittsbalken zu aktualisieren. Der Auswertungs-Dienst verwendete das Datenpaar des aktuellen Auswertungsschritts (generiertes Transkript aus dem Transkriptionsprozess und zugehöriges Label aus dem Testdatensatz), um die Auswertungsmetriken, WER, CER, MER, WIL und JWD (siehe [Abschnitt 6.1.4](#)) zu berechnen. Die Berechnung dieser Metriken wurde unter Verwendung der Python Libraries „jiwer“ (für WER, CER, MER, WIL) und „jaro-winkler“ (für JWD) implementiert [62-63]. Dieses Vorgehen wird für alle Auswertungsdaten wiederholt. Ist der Prozess abgeschlossen, übergibt der Auswertungs-Dienst die Auswertungsergebnisse an den Datenbank-Dienst, der diese in der Datenbank speichert. Der Auswertungs-Dienst sendet einen Fortschrittsbericht, dass der Auswertungsprozess abgeschlossen wurde, an die graphische Benutzeroberfläche, die diese Information auf der Testprozess-Fortschritts-Seite anzeigt. Damit ist der eigentliche Testprozess (bestehend aus Transkriptions- und Auswertungsprozess) abgeschlossen. Die graphische Benutzeroberfläche weist anschließend den Datenbank-Dienst an, die Ergebnisse des Testprozesses zu exportieren. Der Datenbank-Dienst lädt daraufhin alle Ergebnisse des Testprozesses sowie die Label des Testdatensatzes aus der Datenbank und formatiert diese als Excel-Tabelle. Dazu wird die Python Library „openpyxl“ verwendet [64]. Anschließend speichert der Datenbank-Dienst diese Excel-Tabelle im Anwendungsverzeichnis. Dies ist nötig, da die Datenbank am Ende der Ausführung der Anwendung zurückgesetzt wird. Deswegen werden die Testergebnisse exportiert, um diese dem Nutzer für weitere Auswertungen zur Verfügung zu stellen. Der Testprozess wird dadurch abgeschlossen, dass die graphische Nutzeroberfläche den Abbrechen-Button auf der Testprozess-Fortschritt-Seite ausblendet und diesen mit einem „Ergebnisse anzeigen“ Button ersetzt. Während des gesamten Testprozesses hat der Nutzer die Möglichkeit, diesen mittels des Abbrechen-Buttons auf der Testprozess-Fortschritt-Seite abzuberechnen. In diesem Fall werden alle eingelesen und erzeugten Dateien aus der Datenbank gelöscht und die Anwendung wird beendet.

6.2.5 Anzeigen und Exportieren der Testergebnisse

Nach der erfolgreichen Ausführung des Testprozesses wird dem Nutzer auf der Testprozess-Fortschritts-Seite der „Ergebnisse anzeigen“ Button angezeigt. Drückt der Nutzer diesen, wird er auf die Ergebnis-Seite weitergeleitet (siehe Abbildung 14). Dazu

bezieht die graphische Benutzeroberfläche zunächst die Testergebnisse über den Datenbank-Dienst aus der Datenbank.

Abbildung 14: Sequenzdiagramm Anzeigen und Exportieren der Ergebnisse



Quelle: Eigene Darstellung

Anschließend werden die Mittelwerte der Auswertungsmetriken berechnet und die graphische Benutzeroberfläche zeigt diese auf der Ergebnis-Seite an. Dies soll dem Nutzer einen Überblick über die Testergebnisse ermöglichen. Die detaillierten Testergebnisse wurden an diesem Punkt bereits als Excel-Tabelle in das

Anwendungsverzeichnis exportiert. Der Nutzer hat aber auch die Möglichkeit, die Testergebnisse in ein Verzeichnis seiner Wahl zu exportieren. Dazu betätigt er den „Ergebnisse exportieren“ Button und es wird ihm ein Systemdialog zum Auswählen des gewünschten Exportverzeichnisses angezeigt. Der Nutzer wählt das Verzeichnis seiner Wahl und optional einen Dateinamen für den Export aus. Der daraus resultierende Dateipfad wird anschließend an den Datenbank-Manager übergeben. Dieser lädt alle Testergebnisse aus der Datenbank, formatiert diese als Excel-Tabelle und speichert diese an den durch den erhaltenen Pfad ausgewiesenen Dateispeicherort. Damit stehen die Testergebnisse dem Nutzer zur weiteren Auswertung zur Verfügung. Der Nutzer kann die Anwendung über den Fertigstellen-Button der Ergebnis-Seite beenden. Wird dieser Button betätigt, wird zunächst die gesamte Datenbank gelöscht und anschließend wird die Anwendung beendet.

7 Prototype: TranscribeMyVideo

In [Kapitel 5.5](#) wurde als Einsatzmöglichkeit von STT zur Umsetzung von digitaler Barrierefreiheit die Unterstützung von Menschen bei der Erstellung von Transkripten von zeitbasierten Medien identifiziert. Als praktische Demonstration dieser Einsatzmöglichkeit wurde mit TranscribeMyVideo ein Prototyp als Webanwendung entwickelt, der es Nutzern erlaubt, automatisch ein Transkript für ein Video zu erstellen und anschließend zu korrigieren. Im Folgenden wird die Planung und Implementierung dieses Prototyps vorgestellt.

7.1 Planung

Bevor der Prototyp implementiert werden konnte, wurde zunächst, wie auch für Prototype: STT Accuracy Analyzer, eine genaue Planung und Untersuchung der Umsetzungsmöglichkeiten der einzelnen Funktionalitäten durchgeführt. Diese wird im Folgenden beschrieben.

7.1.1 Anforderungen

Als erster Schritt der Planung wurden zunächst die nötigen Minimalanforderungen zur Umsetzung des Prototyps identifiziert. Diese sind:

- Bereitstellen der Anwendung über das Internet.

- Interaktion des Nutzers mit der Anwendung über eine graphische Weboberfläche.
- Hochladen einer Videodatei, aus der ein Transkript erstellt werden soll.
- Automatische Generierung eines Transkripts mittels STT-Technologie.
- Korrektur des Transkripts durch den Nutzer.
- Formatierung des Transkripts als PDF-Dokument.
- Herunterladen der PDF-Datei, die das Transkript enthält.

7.1.2 Use Cases

Auf Basis der Anforderungen wurden die folgenden Use Cases erarbeitet (siehe Tabelle 3: Use Cases TranscribeMyVideo). Eine ausführliche Beschreibung der einzelnen Use Cases wird in Anhang 2 bereitgestellt (siehe [Anhang 2](#): Use Cases TranscribeMyVideo).

Tabelle 3: Use Cases TranscribeMyVideo


Nr.	Use Case	Beschreibung
1	Upload der Videodatei	Der Nutzer wählt über das Webinterface in seinem Webbrowser eine Videodatei aus, die mittels des Upload-Dienstes hochgeladen und verifiziert wird. Anschließend wird die Videodatei durch den Daten-Manager im Dateisystem des Servers gespeichert.
2	Generierung des Transkripts aus dem hochgeladenen Video	Der Transkriptionsdienst generiert aus einer Videodatei ein Transkript und übergibt es an den Daten-Manager. Der Daten-Manager speichert das Transkript im Dateisystem des Servers.
3	Korrektur des generierten Transkriptes	Der Nutzer korrigiert das generierte Transkript. Dieses wird anschließend durch den Daten-Manager als PDF-Datei formatiert und im Dateisystem des Servers gespeichert.
4	Download des Transkripts	Der Nutzer lädt die erstellte Transkript-PDF-Datei herunter.
5	Zurücksetzen der Anwendung	Alle eventuell vorhandenen Daten aus vorherigen Sitzungen werden entfernt, sodass neue Transkriptionsanfragen entgegengenommen werden können.

Quelle: Eigene Auflistung

7.1.3 Architektur

Basierend auf den Anforderungen und Use Cases wurde eine Software-Architektur entwickelt (siehe Abbildung 15). Deren Komponenten und die Interaktionen selbiger werden im Folgenden vorgestellt.

Abbildung 15: Architekturdiagramm Prototyp TranscribeMyVideo



Quelle: Eigene Darstellung

7.1.3.1 Anwendungsfunktionen

Die Anwendungsfunktionen umfassen die geplanten Kernfunktionalitäten der Anwendung. Diese sind:

7.1.3.1.1 Upload-Dienst

Der Upload-Dienst umfasst die geplanten Funktionalitäten für den Upload der Videodatei. Er erhält das hochgeladene Datenpaket vom Webinterface. Die erhaltenen Dateien überprüft der Upload-Dienst auf Korrektheit. Abhängig vom Ergebnis dieser Überprüfung übergibt der Upload-Dienst die hochgeladene Datei an den Daten-Manager zwecks Speicherung dieser im Dateisystem des Servers oder übermittelt

dem Webinterface eine Fehlermeldung, dass die hochgeladene Datei nicht den Anforderungen der Überprüfung entspricht.

7.1.3.1.2 Transkriptions-Dienst

Der Transkriptions-Dienst beinhaltet die geplanten Funktionen zum automatischen Generieren eines Transkripts aus der hochgeladenen Videodatei. Für diesen Prozess erhält der Transkriptions-Dienst die hochgeladene Videodatei vom Daten-Manager. Aus dieser extrahiert er zunächst das Audio und erzeugt daraus ein Transkript, das er im Anschluss an den Daten-Manager übergibt, der dieses im Dateisystem des Servers speichert.

7.1.3.1.3 Daten-Manager

Der Dateimanager stellt die Schnittstelle zwischen den Komponenten der Anwendung und dem Dateisystem des Servers dar. Die geplanten Funktionalitäten umfassen das Speichern und Laden von Dateien in und aus dem Dateisystem des Servers.

7.1.3.2 Dateisystem

Für die Anwendung ist aufgrund der geringen Menge von anfallenden Daten der Einsatz einer Datenbank nicht vorgesehen. Stattdessen wird das Dateisystem des Servers verwendet, um die anfallenden Daten zu speichern.

7.1.3.3 Webinterface

Das Webinterface stellt die Benutzeroberfläche dar, mit der Nutzer über ihren Webbrowser mit der Anwendung interagieren können. Es empfängt die Anfragen von Nutzern, bearbeitet diese unter Verwendung der Anwendungsfunktionen und gibt die Ergebnisse an den Webbrowser des Nutzers zurück. Damit ist das Webinterface auch für die Ablaufsteuerung der Anwendung zuständig. Es sind insgesamt vier Webseiten zur Interaktion des Nutzers mit den verschiedenen Funktionen der Anwendung vorgesehen. Dabei ist der grundlegende Aufbau aller Seiten identisch. Diese sind in zwei Bereiche eingeteilt, einen interaktiven und einen Bereich für Erklärungen (siehe Abbildung 16). Im interaktiven Bereich werden dem Nutzer die nötigen Steuerelemente für die Bedienung der Anwendung angezeigt.

Abbildung 16: Grundlegender Aufbau des Webinterfaces



Quelle: Eigene Darstellung

Im Bereich für Erklärungen werden Benutzeranweisungen zur Bedienung der aktuellen Seite angezeigt. Im Folgenden werden die geplanten Seiten mittels Mockups genauer erklärt.

7.1.3.3.1 Upload-Seite

Auf dieser Seite, die auch die Startseite der Anwendung darstellt, können Nutzer ein Video zur Transkription hochladen (siehe Abbildung 17). Dazu können sie mittels des Durchsuchen-Buttons einen Dialog zur Dateiauswahl öffnen und die gewünschte Datei auswählen. Der Uploadprozess kann über den Hochladen-Button gestartet werden. Drückt der Nutzer den Hochladen-Button, ohne vorher eine Datei auszuwählen oder ist die ausgewählte Datei im falschen Dateiformat, so werden dem Nutzer unterhalb des Hochladen-Buttons entsprechende Fehlermeldungen angezeigt und er wird gebeten, seine Eingabe zu korrigieren. Nach einem erfolgreichen Upload wird der Transkriptionsprozess gestartet und der Nutzer wird auf die Transkript-Prozess-Seite weitergeleitet.

Abbildung 17: Upload-Seite

Video-Transkription

Video hochladen

Bitte ein MP4-Video hochladen, für das Sie ein Transkript erstellen möchten.

Durchsuchen...

Dateiname

Hochladen

Fehlermeldungen

1. Klicken Sie auf „Durchsuchen“, um eine Video-Datei auszuwählen.
2. Klicken Sie auf „Hochladen“, um die Generierung des Transkriptes zu starten.
3. Warten Sie, bis das Transkript erstellt ist.

Quelle: Eigene Darstellung

7.1.3.3.2 Transkript-Prozess-Seite

Nach erfolgreichem Upload der Videodatei wird der Transkriptionsprozess gestartet. Während diesem wird dem Nutzer die Transkript-Prozess-Seite angezeigt (siehe Abbildung 18).

Abbildung 18: Transkript-Prozess-Seite

Video-Transkription

Transkript für „Dateiname“ wird erstellt.



Bitte Warten ...

Ihr Transkript des Videos „Dateiname“ wird erstellt.
Bitte warten Sie, bis der Prozess abgeschlossen ist.
Sie werden auf die Seite zum bearbeiten des Transkriptes weitergeleitet,
sobald dieses fertiggestellt ist.

Quelle: Eigene Darstellung

Auf dieser hat der Nutzer keine Interaktionsmöglichkeiten, sondern es wird ihm ein Indikator angezeigt, dass die Transkription aktuell ausgeführt wird. Außerdem wird dem Nutzer mitgeteilt, dass er warten muss, bis dieser Prozess abgeschlossen wurde. Ist die Transkription erfolgreich beendet, wird der Nutzer auf die Korrektur-Seite weitergeleitet.

7.1.3.3 Korrektur-Seite

Nach erfolgreichem Abschluss des Transkriptionsprozesses wird der Nutzer auf die Korrekturseite weitergeleitet (siehe Abbildung 19).

Abbildung 19: Korrektur-Seite

Video-Transkription

Transkript bearbeiten

Transkript für Video „Dateiname“:

Textbox zum Korrigieren des Transkriptes.

Bearbeitung abschließen

Das Transkript für Video „DeutscheZitate.mp4“ wurde erstellt. Sie haben auf dieser Seite die Möglichkeit, Änderungen oder Korrekturen am Transkript vorzunehmen.

Klicken Sie auf den „Bearbeitung abschließen“ Button, um die Bearbeitung fertigzustellen. Sie werden anschließend zur Download-Seite weitergeleitet, wo Sie das Transkript herunterladen können.


Quelle: Eigene Darstellung

Hier wird dem Nutzer das erstellte Transkript in einer Textbox angezeigt. Über diese kann der Nutzer das Transkript frei bearbeiten beziehungsweise korrigieren. Ist der Nutzer mit der Korrektur zufrieden, kann er diese durch Drücken des „Bearbeitung abschließen“ Buttons beenden. Daraufhin wird das korrigierte Transkript gespeichert und der Nutzer wird auf die Download-Seite weitergeleitet.

7.1.3.3.4 Download-Seite

Nach der erfolgreichen Korrektur des Transkriptes wird dem Nutzer die Download-Seite angezeigt (siehe Abbildung 20). Hier hat der Nutzer die Möglichkeit, das erstellte Transkript über den „Transkript als PDF herunterladen“ Button herunterzuladen. Außerdem kann der Nutzer durch Drücken des „Zurück zur Startseite“ Buttons zur Upload-Seite zurückkehren, um weitere Transkripte anzufertigen.

Abbildung 20: Download-Seite



Quelle: Eigene Darstellung

7.1.3.4 Client-Server-Architektur


Die geplante Anwendung soll als Webanwendung entwickelt werden und eine Client-Server-Architektur implementieren (siehe [Abbildung 15](#)). Der Client ist dabei das Endgerät des Nutzers, über das dieser mittels eines Webbrowsers mit der Anwendung auf dem Server interagiert. Das Webinterface, die Anwendungsfunktionen sowie das Dateisystem sind Teil des Servers. Dabei bildet das Webinterface das Frontend und die Anwendungsfunktionen sowie das Dateisystem bilden das Backend.

7.2 Implementierung

Die Anwendung wurde, basierend auf der im vorherigen Abschnitt vorgestellten Planung, in Python unter Verwendung der Python Library „Flask“ als Webanwendung

implementiert [27][65]. Die einzelnen Webseiten wurden mittels HTML, CSS und Bootstrap und der von Flask verwendeten Jinja Templating Engine implementiert [66-69]. Der Aufbau der Seiten folgt den in [Abschnitt 7.1.3.3](#) vorgestellten Mockups (siehe Abbildungen 16 bis 20). Die Kommunikation zwischen Client und Server erfolgt über das Hypertext Transfer Protocol (HTTP) [70]. Der implementierte Code steht auf GitHub zur Verfügung (<https://github.com/Marlon-Ringel/TranscribeMyVideo>). Der übergeordnete Ablauf der Ausführung der verschiedenen implementierten Funktionalitäten ist im Aktivitätsdiagramm „Ablauf Prototyp TranscribeMyVideo“ zusammengefasst (siehe Abbildung 21). Die einzelnen implementierten Schritte werden im Folgenden anhand von Sequenzdiagrammen genauer beschrieben.

Abbildung 21: Aktivitätsdiagramm Ablauf Prototyp TranscribeMyVideo




Quelle: Eigene Darstellung

7.2.1 Hochladen einer Videodatei

Nachdem der Nutzer die Anwendung über seinen Webbrowser aufgerufen hat, wird ihm zunächst die Startseite (Upload-Seite) angezeigt, auf der er die Möglichkeit hat, eine Videodatei hochzuladen (siehe Abbildung 22). Dazu wählt der Nutzer über den Dateiauswahl-Dialog, den er durch Drücken des Durchsuchen-Buttons aufrufen kann, eine Videodatei, für die ein Transkript erstellt werden soll, aus. Durch Drücken des Hochladen-Buttons wird die Datei an das Webinterface übermittelt. Dieses initiiert daraufhin den Upload-Dienst und übergibt diesem das empfangene Datenpaket. Der Upload-Dienst speichert die erhaltene Datei zur weiteren Bearbeitung. Anschließend wird die hochgeladene Datei validiert. Dabei prüft der Upload-Dienst zuerst, ob das erhaltene Datenpaket eine Datei enthält. Ist dies nicht der Fall, gibt der Upload-Dienst dem Webinterface diese Information zurück. Daraufhin zeigt das Webinterface dem Nutzer eine Fehlermeldung, dass keine Datei ausgewählt wurde und fordert den Nutzer zur Auswahl einer Datei auf.

Abbildung 22: Sequenzdiagramm Hochladen einer Videodatei



Quelle: Eigene Darstellung


Enthält das empfangene Datenpaket hingegen eine Datei, übergibt der Upload-Dienst diese an den Daten-Manager, der die Datei im Dateisystem des Servers speichert. Anschließend prüft der Upload-Dienst, ob die Datei eine MP4-Videodatei ist. Diese Funktionalität wurde mittels der Python Library „filetype“ implementiert, die es erlaubt, das Dateiformat einer Datei anhand der Struktur innerhalb der Datei und damit unabhängig von der Dateiendung zu bestimmen [71]. Im Falle, dass die Datei ein anderes Dateiformat als das MP4-Dateiformat hat, weist der Upload-Service den Daten-Manger an, die gespeicherte Datei wieder zu löschen. Nach der erfolgreichen Löschung der Datei gibt der Upload-Dienst die Information, dass die Datei das falsche Dateiformat hat, an das Webinterface zurück. Dieses zeigt dem Nutzer eine Fehlermeldung, dass die hochgeladene Datei das falsche Format hat und fordert den Nutzer auf, eine Datei im MP4-Videoformat hochzuladen. Ist die Datei hingegen im MP4-Dateiformat, so gibt der Upload-Dienst diese Information an das Webinterface zurück und dieses leitet den Nutzer auf die Transkription-Prozess-Seite weiter. Der oben beschriebene Validierungsprozess wird dabei so lange wiederholt, bis eine MP4-Videodatei erfolgreich hochgeladen wurde.

7.2.2 Generierung des Transkripts

Nachdem das Webinterface den Nutzer auf die Transkription-Prozess-Seite weitergeleitet hat, initialisiert es den Transkriptions-Dienst. Anschließend beginnt die Generierung des Transkripts (siehe Abbildung 23). Dazu bezieht der Transkriptions-Dienst zunächst vom Daten-Manger den Pfad, unter dem die Videodatei gespeichert wurde. Nach Erhalt dieser Information nutzt der Transkriptions-Dienst diesen Pfad zur Extraktion der Audiospur aus der Videodatei. Für die Implementierung dieser Funktionalität wird die „moviepy“ Python Library verwendet [72]. Die dabei generierte Audiodatei übergibt der Transkriptions-Dienst an den Daten-Manger, der die Audiodatei im Dateisystem des Servers speichert. Anschließend bezieht der Transkriptions-Dienst den Pfad, unter dem die Audiodatei gespeichert ist, vom Daten-Manager und nutzt diesen, um ein Transkript für die Audiodatei zu generieren. Aufgrund der erreichten Genauigkeiten in der Auswertung durch Korbinian Kuhn et al., die in [Kapitel 5.4](#) thematisiert wurde, wird für die Transkription das STT-System Whisper verwendet [51][73]. Das generierte Transkript übergibt der

Transkriptions-Dienst anschließend an den Daten-Manager, der es im Dateisystem des Servers speichert.

Abbildung 23: Sequenzdiagramm Generierung des Transkripts



Quelle: Eigene Darstellung


Nach Abschluss dieses Prozesses bezieht das Webinterface das Transkript vom Daten-Manger. Anschließend leitet das Webinterface den Nutzer auf die Korrektur-Seite weiter und zeigt dem Nutzer dort das Transkript an.

7.2.3 Korrektur des Transkripts

Nach dem erfolgreichen Abschluss des Transkriptionsprozesses wird dem Nutzer das generierte Transkript in einer Textbox auf der Korrektur-Seite angezeigt. Über diese Textbox hat der Nutzer die Möglichkeit, das Transkript nach Belieben zu bearbeiten beziehungsweise zu korrigieren (siehe Abbildung 24). Ist der Nutzer mit seiner Korrektur zufrieden, kann er den Korrekturprozess durch Drücken des Buttons

„Bearbeitung abschließen“ fertigstellen. Daraufhin bezieht das Webinterface das korrigierte Transkript vom Browser des Nutzers und übergibt dieses an den Daten-Manager. Dieser formatiert das Transkript als PDF-Dokument und speichert es anschließend im Dateisystem des Servers. Ist dies erfolgreich abgeschlossen, leitet das Webinterface den Nutzer auf die Download-Seite weiter.

Abbildung 24: Sequenzdiagramm Korrektur des Transkripts




Quelle: Eigene Darstellung

7.2.4 Herunterladen des Transkripts

Über die Download-Seite hat der Nutzer die Möglichkeit, das erstellte Transkript herunterzuladen (siehe Abbildung 25). Dazu drückt der Nutzer den „Transkript als PDF herunterladen“ Button. Das Webinterface bezieht daraufhin das PDF-Dokument, das das Transkript enthält, vom Daten-Manager und übermittelt es an den Webbrowser des Nutzers. Der Nutzer hat darüber hinaus auch die Möglichkeit, zur Startseite (Upload-Seite) zurückzukehren, indem er den „Zurück zur Startseite“ Button drückt. Daraufhin sendet das Webinterface dem Daten-Manager den Befehl, das Dateisystem zurückzusetzen. Dies geschieht, damit keine Dateien aus vorherigen Sitzungen in neue Sitzungen übernommen werden. Anschließend leitet das Webinterface den Nutzer zur Startseite (Upload-Seite) weiter, von wo aus der Nutzer weitere Transkripte anfertigen lassen kann.

Abbildung 25: Sequenzdiagramm Herunterladen des Transkript



Quelle: Eigene Darstellung

8 Bewertung der Prototypen

Die in [Kapitel 6](#) und [Kapitel 7](#) vorgestellten Prototypen wurden erfolgreich implementiert. Die testweise Ausführung beider Systeme zeigt, dass die aufgestellten Anforderungen erreicht wurden. Der Prototyp STT Accuracy Analyzer wurde verwendet, um die Genauigkeit eines Open-Source STT-Systems und eines STT-Systems aus dem kommerziellen Bereich zu prüfen (siehe [Abschnitt 8.3](#)). Die Ausführung dieser Tests konnte fehlerfrei abgeschlossen werden. Auch TranscribeMyVideo wurde mit mehreren Videodateien getestet, wobei keine Fehler festgestellt werden konnten. Dennoch handelt es sich bei diesen Systemen um Prototypen, für die aufgrund der zeitlichen Rahmenbedingungen bei der Erstellung der vorliegenden Arbeit nur ein minimaler Funktionsumfang implementiert werden konnte. Für den Einsatz unter realen Bedingungen existieren deswegen noch teils erhebliche Nachteile in der Implementierung, die im Folgenden zusammen mit potenziellen Weiterentwicklungsmöglichkeiten zur Behebung dieser Nachteile betrachtet werden.

8.1 Weiterentwicklungsmöglichkeiten STT Accuracy Analyzer

8.1.1 Vereinfachung der Eingabe des Startbefehls

Aktuell muss der Befehl zum Starten des STT-Systems, sofern dieser aus mehreren, durch Leerzeichen getrennten Teilen besteht, vor der Eingabe über die graphische Benutzeroberfläche mit Kommata separiert werden. Dies ist beispielsweise beim standardmäßigen Befehl zum Starten einer Python-Anwendung der Fall. Ein solcher Befehl, der unter Linux aus zwei Teilen aufgebaut ist („<Dateipfad zum Python Interpreter>python <Dateipfad zur auszuführenden Datei>Auszuführende_Datei.py“) müsste im implementierten System mit einem Komma geteilt werden („<Dateipfad zum Python Interpreter>python, <Dateipfad zur auszuführenden Datei> Auszuführende _Datei.py“), um korrekt verarbeitet werden zu können. Deswegen stellt die Implementierung von Funktionalität, die es erlaubt, den Startbefehl ohne diese Anpassung einzugeben und zu verarbeiten, eine Weiterentwicklungsmöglichkeit dar, die die Nutzung des Systems vereinfachen würde.

8.1.2 Erweiterte Unterstützung von Dateiformaten für benutzerdefinierte Testdatensätze

Beim Einlesen eines benutzerdefinierten Datensatzes wurde nur eine grundlegende Funktionalität implementiert, die es zwingend erfordert, dass die Datei mit den Labels der Audiodaten im TSV Dateiformat vorliegt und die ersten beiden Einträge einer Zeile aus dem Dateinamen der Audiodatei und dem Transkript, das als Label dieser fungiert, bestehen. Hier würde es die Nutzbarkeit des Systems erhöhen, wenn zumindest das Einlesen weiterer Dateiformate wie beispielsweise des Excel Tabellenformats unterstützt würde. Weiter würde eine Funktionalität, die dynamisch oder durch Nachfragen beim Nutzer ermittelt, welche Spalten der einzulesenden Datei die benötigten Informationen enthalten, dem Nutzer das manuelle Vorformatieren einer solchen Datei abnehmen.

8.1.3 Genauere Validierung der Konfigurationsdaten

Die Konfigurationsdaten werden zwar bereits vor Ausführung des Testprozesses validiert, dabei findet allerdings keine Überprüfung des benutzerdefinierten Testdatensatzes statt. Dies hat zur Folge, dass ein fehlerhafter Datensatz entweder nicht eingelesen werden kann oder aber Daten eingelesen werden, die während des Testprozesses einen Fehler verursachen, was beides zum Beenden der Anwendung führt. Hier könnte eine umfassendere Validierung implementiert werden, die diese Probleme vor der Ausführung des Testprozesses erkennt und den Nutzer darüber informiert, so dass der Nutzer diese Probleme vor der Ausführung des Testprozesses beheben kann und dadurch ein Fehler, der zum Ende der Anwendung führt, vermieden wird.

8.1.4 Performanceverbesserung bei der Ausführung des Subprozess

Das zu testende STT-System wird im Transkriptionsprozess als Subprozess ausgeführt. Dabei wird das STT-System für jeden Transkriptionsschritt neu gestartet. Das Starten eines Subprozesses nimmt Zeit in Anspruch. Außerdem erfordert das Ausführen von lokalen STT-Systemen eine Initialisierung, die ebenfalls zeitaufwändig ist. Bei der Verarbeitung von großen Datensätzen mit potenziell tausenden von Dateien kann dies die Performance des Systems negativ beeinflussen. Hier könnte die Performance der Anwendung durch eine Methodik verbessert werden, die es erlaubt, den Subprozess nur einmal starten zu müssen und anschließend für jeden Transkriptionsschritt aufzurufen.

8.1.5 Erweiterte Fehlerbehandlung

Tritt während des Testprozesses ein Fehler auf, so wird die Anwendung aktuell immer beendet. Ein besseres Vorgehen wäre es, dem Nutzer im Falle eines Fehlers nach der Anzeige der Fehlermeldung die Möglichkeit zu geben, auf die Startseite zurückzukehren, sodass der Nutzer einen neuen Testlauf starten kann.

Im Fehlerfall während des Testprozesses werden außerdem alle bis dahin erzeugten Ergebnisse verworfen, was bei der Nutzung von großen Datensätzen nicht optimal ist. Hier wäre es sinnvoll, einen Mechanismus zu implementieren, der es erlaubt, diese

Daten im laufenden Testprozess zu speichern, damit diese im Fehlerfall verfügbar bleiben und der Nutzer den gesamten Prozess nicht von Grund auf neu beginnen muss.

8.1.6 Erweiterung der Datenbank

Die Datenbank wird nach jedem Durchlauf der Anwendung gelöscht und erlaubt damit nur die Verwaltung der Daten der aktuellen Ausführung der Anwendung. Eine Erweiterung der Datenbankstruktur, die es erlaubt die Daten aus mehreren Ausführungen der Anwendung zu verwalten, würde es zum einen ermöglichen, Konfigurationen aus vorherigen Ausführungen wiederzuverwenden und weiter die Möglichkeit schaffen, Funktionalitäten zu implementieren, um die Ergebnissen aus verschiedenen Ausführungen der Anwendung zu vergleichen.

8.2 Weiterentwicklungsmöglichkeiten TranscribeMyVideo

8.2.1 Ausweitung der unterstützten Videoformate

Die Anwendung ist nur in der Lage, Videos im MP4-Dateiformat zu verarbeiten. Eine Ausweitung auf eine größere Auswahl an Videoformaten würde den Nutzen der Anwendung steigern.

8.2.2 Validierung und Beschränkung der Dateigröße des hochzuladenden Videos

Beim Hochladen einer Videodatei wird keine Überprüfung der Dateigröße des hochzuladenden Videos durchgeführt, noch wird diese beschränkt. Dies erlaubt es theoretisch, eine extrem große Videodatei hochzuladen, was dazu führen könnte, dass die Anwendung nicht genug Speicher zur Verfügung hat, um dieses Video zur weiteren Bearbeitung zu speichern. Auch könnte das Hochladen einer extrem großen Videodatei so lange dauern, dass der Prozess über einen Timeout abgebrochen wird. Diese Probleme könnten durch eine vorher definierte Beschränkung der Dateigröße des hochzuladenden Videos in Verbindung mit einer Validierung der Dateigröße während des Upload-Prozesses gelöst werden.

8.2.3 Anzeigen des Videos auf der Korrekturseite zur Unterstützung des Nutzers bei der Korrektur

Auf der Korrekturseite wird dem Nutzer momentan nur das Transkript angezeigt. Hier könnte die Möglichkeit, das Video während der Korrektur über einen Player mit Spulen- und Pausefunktion anzuzeigen, dem Nutzer die Durchführung der Korrektur erleichtern.

8.2.4 Speichern der Transkripte für zukünftige Aufrufe

Aktuell werden die erstellten Transkripte nur während der Bearbeitung der aktuellen Ausführung gespeichert und anschließend gelöscht. Eine Verwaltung der Transkripte, potenziell in Verbindung mit der Verwaltung von Nutzerkonten, über die aktuelle Ausführung hinaus, würde es erlauben, dem Nutzer diese Transkripte für spätere Anfragen zur Verfügung zu stellen.

8.2.5 Parallele Nutzung der Anwendung durch mehrere Nutzer

Die Anwendung kann nur von einem einzigen Nutzer auf einmal verwendet werden. Das Aufrufen der Anwendung, während sie von einem Nutzer verwendet wird, durch einen weiteren Nutzer, führt dazu, dass die Daten des ersten Nutzers (hochgeladenes Video, generiertes Transkript) gelöscht werden. Für den Einsatz als Webanwendung ist die parallele Nutzung der Anwendung zwingend erforderlich, weswegen entsprechende Funktionalität zum Verwalten von mehreren gleichzeitigen Nutzern und deren Daten für einen erfolgreichen Einsatz der Anwendung implementiert werden muss.

8.2.6 Testen der Ausführbarkeit der Anwendung auf einem Webserver

Die Anwendung wurde aktuell nur lokal getestet. Bevor die Anwendung als Webanwendung bereitgestellt werden kann, muss deswegen getestet werden, ob die Anwendung auf einem geeigneten Webserver ausführbar ist und eventuell nötige Anpassungen vorgenommen werden.

8.3 Überprüfung der Genauigkeit von zwei STT-Systemen mittels STT Accuracy Analyzer

Nach der erfolgreichen Implementierung wurde der Prototyp: STT Accuracy Analyzer genutzt, um die Genauigkeit eines Open-Source STT-Systems und eines STT-Systems aus dem kommerziellen Bereich bei der Transkription von deutschsprachigen Inhalten zu bestimmen. Dazu wurde das Open-Source STT-System Whisper ausgewählt, da es in der in [Kapitel 5.4](#) vorgestellten Arbeit von Korbinian Kuhn et al. die beste Genauigkeit erzielte (siehe [Tabelle 1](#)) [51]. Das kommerzielle System AssemblyAI wurde aufgrund der durch den Hersteller angegebenen überdurchschnittlich hohen Genauigkeit von 92,5 % bei der Transkription von deutschsprachigen Inhalten ausgewählt [74]. Der Test erfolgte dabei jeweils mit dem Standarddatensatz, der mit STT Accuracy Analyzer mitgeliefert wird und bereits in [Kapitel 6.1.5](#) vorgestellt wurde. Die Ergebnisse dieser Auswertung sind in Tabelle 4 aufgeführt.

Tabelle 4: Durchschnittliche Ergebnisse der Auswertungsmetriken der Auswertung mittels STT Accuracy Analyzer in Prozent.

Modell	WER	CER	MER	WIL	JWD
Whisper	10,37	3,14	9,95	15,77	15,25
AssemblyAi	12,06	6,93	11,02	16,47	17,79

Quelle: Eigene Auflistung

Die Ergebnisse zeigen für Whisper eine geringere Genauigkeit und für AssemblyAI eine geringfügig höhere Genauigkeit verglichen mit den Ergebnissen von Korbinian Kuhn et al. (siehe [Tabelle 1](#)). Mit 89,63 % (Whisper) und 87,94 % (AssemblyAI) liegen die erreichten Genauigkeiten (bezogen auf die Metrik WER) jedoch sehr nah an der durch Korbinian Kuhn et al. ermittelten durchschnittlichen Genauigkeit (84,7 %) von STT-Systemen bei der Transkription von deutscher Sprache. Die abweichenden individuellen Ergebnisse der beiden Systeme im Vergleich zu den Ergebnissen von Korbinian Kuhn et al. kann durch den Umstand erklärt werden, dass die Genauigkeit von STT-Systemen stark von den verwendeten Daten abhängig ist (siehe [Kapitel 5.4](#)) und in dem hier durchgeführten Test ein anderer Datensatz als in der Auswertung durch

Korbinian Kuhn et al. verwendet wurde [51]. Im direkten Vergleich ist die Genauigkeit von Whisper über alle Metriken geringfügig höher als die Genauigkeit von AssemblyAI. Dennoch erreichen beide Systeme Genauigkeiten, die sehr nah am unteren Bereich der Genauigkeit von Menschen bei der Transkription von gesprochener Sprache liegen (siehe [Kapitel 5.5](#)) [13]. Die Angabe durch den Hersteller von AssemblyAI, dass dieses System eine Genauigkeit von 92,5 % WER erreichen kann, konnte nicht bestätigt werden [74].

8.4 Abschließende Bewertung

Mit Prototyp TranscribeMyVideo wurde eine Anwendung geschaffen, die die automatische Bestimmung der Genauigkeit beliebiger STT-Systeme ermöglicht. Dabei ist die Implementierung dieses Prototyps nicht ohne Nachteile (siehe [Abschnitt 8.1](#)), kann aber, wie die Ergebnisse in [Abschnitt 8.3](#) belegen, in der aktuellen Form für den vorgesehenen Einsatzzweck genutzt werden. Mit Prototyp TranscribeMyVideo wird die Einsatzmöglichkeit von STT zur Unterstützung von Menschen bei der Erstellung von Textalternativen für Videos praktisch demonstriert. Die Kernfunktionalität der Transkription von Videos wurde dabei erfolgreich umgesetzt. Die Probleme der Implementierung, die in [Abschnitt 8.2](#) behandelt wurden, besonders die fehlende Unterstützung für die parallele Verwendung durch mehrere Nutzer, machen TranscribeMyVideo für den Einsatz als Webanwendung unbrauchbar, womit eine Weiterentwicklung des Prototyps für einen erfolgreichen Einsatz dessen erforderlich ist.

9 Fazit und Ausblick

In der vorliegenden Arbeit wurden die Einsatzmöglichkeiten von STT-Technologie zur Umsetzung von digitaler Barrierefreiheit sowie die Genauigkeit von modernen STT-Systemen untersucht. Zur Untersuchung der Einsatzmöglichkeiten von STT-Technologie zur Unterstützung des Abbaus von Barrieren im digitalen Raum wurde zunächst eine Literaturrecherche durchgeführt. Im Zuge dieser wurden drei Einsatzmöglichkeiten von STT-Technologie zur Umsetzung von digitaler Barrierefreiheit identifiziert. Das Generieren von Textalternativen für zeitbasierte Medien in Form von Transkripten und Untertiteln, das zum Abbau von Barrieren, die Menschen mit eingeschränktem Hörvermögen sowie gehörlose Menschen bei der

Interaktion mit zeitbasierten Medien behindern, eingesetzt werden könnte. Die automatisierte Übersetzung von gesprochener Sprache in Gebärdensprache, die gehörlosen Menschen den Zugang zu Medien mit gesprochenen Inhalten ermöglichen würde. Und die Sprachsteuerung von digitalen Systemen, die Blinden und motorisch eingeschränkten Menschen die Nutzung dieser Systeme vereinfachen könnte. Anschließend wurde eine Bewertung dieser Einsatzmöglichkeiten von STT-Technologie mit Fokus auf den realen Einsatz durchgeführt.

Diese ergab, dass die Generierung von Textalternativen für zeitbasierte Medien aktuell nur als Unterstützung von Menschen bei der Erstellung von Transkripten und Untertiteln dienen kann. Dabei kann die Erstellung dieser Inhalte durch die Nutzung von STT beschleunigt werden, indem Menschen die von STT erstellten Transkripte korrigieren, anstatt diese von Grund auf selbst zu verfassen. Die automatische Übersetzung von gesprochener Sprache in Gebärdensprache ist aktuell noch am Anfang Ihrer Entwicklung. Die gewählten Methoden der Übersetzung basieren dabei auf der Zuordnung von Gebärden zu Worten einer gesprochenen Sprache. Aufgrund der fundamentalen Unterschiede von gesprochenen Sprachen und Gebärdensprachen kann dieses Vorgehen als fragwürdig angesehen werden. Außerdem können die vorgestellten Systeme aktuell nur eine geringe Menge an Worten übersetzen. Aus diesen Gründen werden die vorgestellten Systeme für einen realen Einsatz als unzureichend bewertet. Dennoch bilden die behandelten Systeme eine interessante Grundlage für zukünftige Forschung. Die Einsatzmöglichkeit von STT-Technologie der Sprachsteuerung von digitalen Systemen ist in ihrer Umsetzbarkeit stark davon abhängig, wofür diese eingesetzt wird. Für einzelne Anwendungen ist der Einsatz dieser Technologie denkbar, da hierbei nur ein vorher definierbarer Funktionsumfang mit Sprachbefehlen abgedeckt werden muss. Die Sprachsteuerung von komplexeren Systemen, wie Betriebssystemen oder Webseiten beziehungsweise Webbrowsern, ist aktuell aufgrund des vorher nicht abschätzbaren Funktionsumfangs nicht möglich, da keine ausreichend soliden Systeme oder auch nur Konzepte zur dynamischen Generierung der nötigen Sprachbefehle vorhanden sind. Diese Systeme könnten dennoch als Ausgangspunkt für zukünftige Forschung dienen.

Basierend auf diesen Erkenntnissen wurde als praktische Demonstration der als umsetzbar bewerteten Einsatzmöglichkeit von STT-Technologie zur Unterstützung von

Menschen bei der Erstellung von Textalternativen für zeitbasierte Medien ein Prototyp implementiert, der es ermöglicht, STT-unterstützt Transkripte für Videos zu erstellen. Dabei erlaubt es der Prototyp mittels STT ein Transkript für ein Video zu erzeugen, das anschließend durch einen Menschen korrigiert werden kann. Es bleibt festzuhalten, dass die identifizierten Einsatzmöglichkeiten aktuell nur sehr begrenzt und in keinem Fall automatisiert für die Umsetzung von digitaler Barrierefreiheit genutzt werden können. Dies ist neben den bereits angesprochenen Problemen der einzelnen Anwendungen der unzureichenden Genauigkeit der jeweils eingesetzten STT-Systeme geschuldet.

Die Genauigkeit dieser Systeme stellte auch den zweiten Fokuspunkt der vorliegenden Arbeit dar. Es sollte untersucht werden, welche Genauigkeiten moderne STT-Systeme bei der Transkription von deutscher Sprache erreichen können. Dazu wurde ebenfalls Fachliteratur herangezogen und ausgewertet. Die Auswertung zeigt, dass aktuelle STT-Systeme durchschnittliche Genauigkeiten von 84,7 % bei der Transkription von deutscher Sprache erreichen, die damit geringer als die Genauigkeiten von Menschen bei der Transkription von gesprochener Sprache ausfallen. Auch wenn Menschen keine perfekte Genauigkeit bei der Transkription erreichen, zeigt sich, dass Menschen bei der Transkription bestrebt sind, Fehler zu vermeiden, die die Bedeutung des Gesagten verzerren und hauptsächlich grammatikalische Fehler machen. Dies ist bei STT-Systemen nicht der Fall, woraus geschlossen wurde, dass die Genauigkeit von STT-Systemen für einen erfolgreichen Einsatz höher als die Genauigkeit von Menschen sein muss.

Begründet durch den Umstand, dass die Genauigkeit von STT-Technologie in den letzten Jahren, besonders durch den Einsatz von ML-Techniken, stetig verbessert wurde, ist zu erwarten, dass diese Systeme in Zukunft Genauigkeiten erreichen, die für diesen Einsatz ausreichend sind. Deswegen wurde ein weiterer Prototyp entwickelt, der es erlaubt, die Genauigkeit von beliebigen STT-Systemen anhand ausgewählter Auswertungsmetriken zu bestimmen. Damit wird ein System bereitgestellt, das es ermöglicht, die Genauigkeit von zukünftigen STT-Systemen zu erfassen und damit die Entwicklung der Genauigkeit dieser Systeme mitzuverfolgen. Der Prototyp wurde nach der Implementierung genutzt, um die Genauigkeit zweier ausgewählter STT-Systeme zu bestimmen. Die Ergebnisse dieser Überprüfung zeigten, dass diese Systeme aktuell

Genauigkeiten erreichen, die knapp unter der Genauigkeit von menschlichen Transkriptoren liegen.

Damit konnten weder durch die Auswertung von Fachliteratur noch durch die eigene Untersuchung die Angaben der Hersteller bestätigt werden, dass moderne STT-Systeme bereits mit Menschen vergleichbare Genauigkeiten erreichen können. Deswegen und durch den Umstand, dass STT-Systeme aufgrund der Art der Fehler, die diese machen, für einen realen Einsatz mindestens Menschen gleichwertige, aber optimalerweise höhere Genauigkeiten als Menschen erreichen müssen, wurde die Genauigkeit aktueller STT-Systeme als mangelhaft für den automatisierten Einsatz zur Umsetzung von digitaler Barrierefreiheit bewertet.

Insgesamt zeigt sich, dass die STT-Technologie aktuell nur als Unterstützung bei der Erstellung von Textalternativen für zeitbasierte Medien eingesetzt werden kann. Die automatische Generierung dieser Textalternativen ebenso wie die automatische Übersetzung von gesprochener Sprache in Gebärdensprache und die verlässliche Sprachsteuerung von digitalen Systemen ist hauptsächlich aufgrund der mangelhaften Genauigkeit moderner STT-Systeme sowie weiteren spezifischen Problemen der einzelnen Technologien, zum aktuellen Zeitpunkt nicht umsetzbar.

Als wichtigster Gegenstand für zukünftige Forschung bezüglich der Einsatzmöglichkeiten von STT-Technologie zur Reduzierung von Barrieren im digitalen Raum, wird die Erforschung von Möglichkeiten der Steigerung der Genauigkeit von STT-Systemen angesehen, da diese die Grundlage für einen realen Einsatz von STT-Technologie zur Umsetzung von digitaler Barrierefreiheit darstellt. Durch eine Steigerung der Genauigkeit von STT-Systemen könnte die automatische Generierung von Textalternativen für zeitbasierte Medien ermöglicht werden. Darauf aufbauend könnte sich zukünftige Forschung mit der Schaffung von größeren Datensätzen von Repräsentationen von Worten in Gebärdensprache sowie der Erforschung von neuen Vorgehensweisen der Übersetzung von gesprochenen Sprachen in Gebärdensprachen, die die Unterschiede der jeweiligen Spracharten berücksichtigen und potenziell KI-Technologie einsetzen, befassen, um die automatisierte Übersetzung von gesprochener Sprache in Gebärdensprache zu realisieren. Auch die Entwicklung von neuen Konzepten und Standards zur dynamischen Generierung von Sprachbefehlen für

komplexe digitale Systeme als Grundlage der Sprachsteuerung dieser Systeme könnte ein interessantes Forschungsfeld darstellen. Die Bewertung der betriebswirtschaftlichen Aspekte der Verwendung von STT-Systemen ist ein signifikanter Teilaspekt der umfassenden Bewertung der Einsetzbarkeit von STT-Technologie zur Umsetzung von digitaler Barrierefreiheit unter realen Bedingungen. Eine derartige Bewertung konnte in der vorliegenden Arbeit aufgrund der zeitlichen Vorgaben bei der Bearbeitung dieser Arbeit nicht durchgeführt werden. Für den erfolgreichen Einsatz von STT-Technologie zur Umsetzung von digitaler Barrierefreiheit ist eine derartige Abschätzung aber unabdingbar, weswegen die Bewertung der Einsetzbarkeit von STT-Technologie unter betriebswirtschaftlichen Gesichtspunkten ein relevantes Themenfeld für zukünftige Forschung darstellen kann.

IV Literaturverzeichnis

- [1] World Health Organization, Disability, www.who.int, o.J., [Online; abgerufen 05.09.2024]. Verfügbar unter: https://www.who.int/health-topics/disability#tab=tab_1
- [2] Statistische Bundesamt, 7,8 Millionen schwerbehinderte Menschen leben in Deutschland, www.destatis.de, 22. Juni 2022, [Online; abgerufen 02.08.2024]. Verfügbar unter: https://www.destatis.de/DE/Presse/Pressemitteilungen/2022/06/PD22_259_227.html
- [3] Dr. Claudia Gottwald, Behinderung, www.socialnet.de, 24.06.2019, [Online; abgerufen 29.07.2024]. Verfügbar unter: <https://www.socialnet.de/lexikon/Behinderung>
- [4] Swantje Köbsell, Behinderung – was ist das eigentlich?, www.bpb.de, 16.05.2023, [Online; abgerufen 29.07.2024]. Verfügbar unter: <https://www.bpb.de/themen/inklusion-teilhabe/behinderungen/521026/behinderung-was-ist-das-eigentlich/>
- [5] Gerd Schneider, Christiane Toyka-Seid, Barrierefreiheit, www.bpb.de, 2024, [Online; abgerufen 02.08.2024]. Verfügbar unter: <https://www.bpb.de/kurz-knapp/lexika/das-junge-politik-lexikon/335538/barrierefreiheit>
- [6] Christina Kieslinger, Clara Strähle, Daniel Koch, Thomas Meyer, Barrierefreiheit, www.inklumat.de, o. D., [Online; abgerufen 02.08.2024]. Verfügbar unter: <https://inklumat.de/glossar/barrierefreiheit>
- [7] W3C Web Accessibility Initiative, Introduction to Web Accessibility, www.w3.org, 07.03.2024, [Online; abgerufen 02.08.2024]. Verfügbar unter: <https://www.w3.org/WAI/fundamentals/accessibility-intro/>
- [8] Portal Barrierefreiheit, Barrierefreie-Informationstechnik-Verordnung (BITV 2.0), www.barrierefreiheit-dienstekonsolidierung.bund.de, 17.04.2024, [Online; abgerufen 05.08.2024]. Verfügbar unter: <https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/gesetze-und-richtlinien/bitv2-0/bitv2-0-node.html>
- [9] Portal Barrierefreiheit, Barrierefreiheitsstärkungsgesetz (BFSG), www.barrierefreiheit-dienstekonsolidierung.bund.de, 19.12.2023, [Online; abgerufen 05.08.2024]. Verfügbar unter: <https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/gesetze-und-richtlinien/barrierefreiheitsstaerkungsgesetz/barrierefreiheitsstaerkungsgesetz-node.html>
- [10] Europäische Kommission, European accessibility act, www.ec.europa.eu, o. D., [Online; 05.08.2024]. Verfügbar unter: <https://ec.europa.eu/social/main.jsp?catId=1202>
- [11] Sonix, A short history of speech recognition, www.sonix.ai, o. D., [Online; abgerufen 07.08.2024]. Verfügbar unter: <https://sonix.ai/history-of-speech-recognition>
- [12] Europäische Kommission, Künstliche Intelligenz für Europa, Brüssel, 25.4.2018, S. 1

- [13] George Saon, Gakuto Kurata, Tom Sercu, Kartik Audhkhasi, Samuel Thomas, Dimitrios Dimitriadis, Xiaodong Cui, Bhuvana Ramabhadran, Michael Picheny, Lynn-Li Lim, Bergul Roomi, Phil Hall, English Conversational Telephone Speech Recognition by Humans and Machines, arXiv, Yorktown Heights, USA, 2017, S. 2.
- [14] Wiki Durchblick, Digitale Barrierefreiheit, www.wiki-durchblick.de, o. D., [Online; abgerufen 02.08.2024]. Verfügbar unter: https://www.wiki-durchblick.de/index.php?title=Digitale_Barrierefreiheit
- [15] Aktion Mensch, Barrierefreiheit – was heißt das?, www.aktion-mensch.de, o. D., [Online; abgerufen 02.08.2024]. Verfügbar unter: <https://www.aktion-mensch.de/dafuer-stehen-wir/was-ist-inklusion/barrierefreiheit-bedeutung>
- [16] Iwan Cuijpers, Inklusion: Jeder ist manchmal weniger in der Lage, www.keen.design, 2024, [Online; abgerufen 17.09.2024]. Verfügbar unter: <https://www.keen.design/de/keenpublic/blog/inklusion>
- [17] Aktion Mensch, Barrierefreie Website: Einfacher für alle Menschen, www.aktion-mensch.de, o. D., [Online; abgerufen 02.08.2024]. Verfügbar unter: <https://www.aktion-mensch.de/inklusion/barrierefreiheit/barrierefreie-website>
- [18] Portal Barrierefreiheit, Harmonisierte Europäische Norm (EN) 301 549, www.barrierefreiheit-dienstekonsolidierung.bund.de, 17.04.2024, [Online; abgerufen 05.08.2024]. Verfügbar unter: <https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/gesetze-und-richtlinien/en301549/en301549-artikel.html>
- [19] W3C Web Accessibility Initiative, WCAG 2 Overview, www.w3.org, 07.03.2024, [Online; abgerufen 05.08.2024]. Verfügbar unter: <https://www.w3.org/WAI/standards-guidelines/wcag/>
- [20] Portal Barrierefreiheit, Web Content Accessibility Guidelines 2.1 (WCAG 2.1), www.barrierefreiheit-dienstekonsolidierung.bund.de, 17.04.2024, [Online; abgerufen 05.08.2024]. Verfügbar unter: <https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/gesetze-und-richtlinien/wcag/wcag-artikel.html>
- [21] Philip Boucher, Artificial intelligence: How does it work, why does it matter, and what can we do about it?, Think Tank European Parliament, 2020, S. 1-17
- [22] Cedat85, Speech-to-Text: what is it, what is it for, who is it for?, www.cedat85.com, 27.08.2021, [Online; abgerufen 07.08.2024]. Verfügbar unter: <https://www.cedat85.com/speech-to-text-what-is-it-what-is-it-for-who-is-it-for/>
- [23] IBM, What is speech recognition?, www.ibm.com, o. D., [Online; abgerufen 07.08.2024]. Verfügbar unter: <https://www.ibm.com/topics/speech-recognition>

- [24] Gladia, Introduction to speech-to-text AI, www.gladia.io, 2024, [Online; abgerufen 07.08.2024]. Verfügbar unter: <https://www.gladia.io/blog/introduction-to-speech-to-text-ai>
- [25] Kushal Saini Kakkar, Understanding Word Error Rate in Automatic Speech Recognition, www.clari.com, 13.12.2021, [Online; abgerufen 20.08.2024]. Verfügbar unter: <https://www.clari.com/blog/word-error-rate>
- [26] netgo, Software Engineering, www.netgo.de, o. D. [Online; abgerufen 02.09.2024]. Verfügbar unter: <https://docs.google.com/document/d/1XudrYqyom0sT1DKk5OifME90N6d8xnsg0bCMV2vwURU/edit>
- [27] Python, Python, www.python.org, o. D. [Online; abgerufen 29.08.2024]. Verfügbar unter: <https://www.python.org/>
- [28] visualstudio, Visual Studio Code, www.visualstudio.com, o. D. [Online; abgerufen 02.09.2024]. Verfügbar unter: <https://code.visualstudio.com/>
- [29] Git-Scm, Git, www.git-scm.com o. D. [Online; abgerufen 02.09.2024]. Verfügbar unter: <https://git-scm.com/>
- [30] Brent Shiver, Rosalee Wolfe, Evaluating Alternatives for Better Deaf Accessibility to Selected Web-Based Multimedia, ASSETS '15: The 17th International ACM SIGACCESS Conference on Computers and Accessibility, Lissabon Portugal, 2015, S. 1.
- [31] Dave Rodriguez, Bryan J. Brown, Comparative analysis of automated speech recognition technologies for enhanced audiovisual accessibility, Code4Lib Journal, Ausgabe 58, 2023, S. 1.
- [32] César Domínguez, Jónathan Heras, Félix Lanas, Gadea Mata, Julio Rubio, Mirari San Martín., Improving Accessibility in Public Web Pages, Annual Conference of the Spanish Association for Natural Language Processing 2023: Projects and System Demonstrations, Jaén Spain, 2023, S. 2-3.
- [33] Solène Evain, Benjamin Lecouteux, François Portet, Isabelle Estève, Marion Fabre, Towards Automatic Captioning of University Lectures for French Students who are Deaf, Conference on Computers and Accessibility, Athen Griechenland, 2020, S. 2-4.
- [34] Korbinian Kuhn, Verena Kersken, Gottfried Zimmermann, Accuracy of AI-generated Captions With Collaborative Manual Corrections in Real-Time, CHI EA, Hamburg Deutschland, 2023, S. 2-6.
- [35] Larwan Berke, Christopher Caulfield, Matt Huenerfauth, Deaf and Hard-of-Hearing Perspectives on Imperfect Automatic Speech Recognition for Captioning One-on-One Meetings, ASSETS'17, Baltimore Maryland USA, 2017, S. 161.

- [36] B. Shiver, Utilizing automatic speech recognition to improve Deaf accessibility on the Web, DePaul CDM School of Computing, o.D. S. 2.
- [37] Yashesh Gaur, Walter S. Lasecki, Jeffrey P. Bigham, Florian Metze, The Effects of Automatic Speech Recognition Quality on Human Transcription Latency, W4A'16: International Web for All Conference, Montreal Canada, 2016, S. 3-6.
- [38] Elena Verdú Pérez, B. Cristina Pelayo G-Bustelo, M. Ángeles Martínez Sánchez, Rubén González Crespo, A System to Generate SignWriting for Video Tracks Enhancing Accessibility of Deaf People, International Journal of Interactive Multimedia and Artificial Intelligence, Band 4, Auflage 6, 2017, S. 110.
- [39] Michael Kipp, Alexis Heloir, Quan Nguyen, Sign Language Avatars: Animation and Comprehensibility, 11th International Conference Intelligent Virtual Agents 2011, Reykjavik Island, 2011, S. 2.
- [40] Hemang Monga, Jatin Bhutani, Muskan Ahuja, Nikita Maida, Himangi Pande, Speech to Indian Sign Language Translator, Recent Trends in Intensive Computing, Ausgabe 39, 2021, S. 11-15.
- [41] Ritika Bharti, Sarthak Yadav, Sourav Gupta, Rajitha Bakthula, Automated Speech to Sign language Conversion using Google API and NLP, ICAEEC-2019: International Conference on “Advances in Electronics, Electrical & Computational Intelligence”, Prayagraj, Indien, 2019, S. 3,4,6,7
- [42] Bhavinkumar Devendrabhai Patel, Harshit Balvantrai Patel, Manthan Ashok Khanvilkar, Nidhi Rajendrakumar Patel, Thangarajah Akilan, ES2ISL: An Advancement in Speech to Sign Language Translation using 3D Avatar Animator, 2020 IEEE Canadian Conference on Electrical and Computer Engineering (CCECE), London Ontario Kanada, 2020, S. 2-5.
- [43] Mahmoud M. El-Gayyar, Amira S. Ibrahim, M.E. Wahed, Translation from Arabic speech to Arabic Sign Language based on cloud computing, Egyptian Informatics Journal, Band 17, Ausgabe 3, 2016, S. 297-302.
- [44] Bandi Rupendra Reddy, Darukumalli Sai Tharun Reddy, Sandeep Preetham, Susmitha Vekkot, Creation of GIF dataset and implementation of a speech-to-sign language translator in Telugu, Vijaypur Indien, 2022, S. 2-7.
- [45] Yu Zhong, T.V. Raman, Casey Burkhardt, Fadi Biadsy, Jeffrey P. Bigham, JustSpeak: enabling universal voice control on Android, W4A '14: International Web for All Conference, Seoul Korea, 2014, S. 1, 3-5, 7.
- [46] Teddy Zhou, How do voice assistants like Alexa & Siri actually work?, [www.medium.com](https://medium.com/@zhouxiaogan0/how-do-voice-assistants-like-alexa-siri-actually-work-1885dce1f683), 21.09.2023, [Online; abgerufen 19.08.2024]. Verfügbar unter: <https://medium.com/@zhouxiaogan0/how-do-voice-assistants-like-alexa-siri-actually-work-1885dce1f683>

- [47] Jaspreet Kaur, Rohit Agnihotri, Enhancing Email Accessibility for Visually Impaired Individuals: A Voice-Based Email System using Artificial Intelligence, Journal of Computers, Mechanical and Management, Band 2, Ausgabe 4, 2023, S. 2-4.
- [48] Vinayak Iyer, Kshitij Shah, Sahil Sheth, Kailas Devadkar, Virtual assistant for the visually impaired, 5th International Conference on Communication and Electronics Systems (ICCES), Coimbatore Indien, 2020, S. 1059-1061.
- [49] Julia Cambre, Alex C. Williams, Afsaneh Razi, Ian Bicking, Abraham Wallin, Janice Tsai, Chinmay Kulkarni, Jofish Kaye, Firefox Voice: An Open and Extensible Voice Assistant Built Upon the Web, CHI '21: CHI Conference on Human Factors in Computing Systems, Yokohama Japan, 2021, S. 9-12.
- [50] Mozilla Extensions, firefox-voice, [www.github.com](https://github.com/mozilla-extensions/firefox-voice), o. D., [Online; abgerufen 19.08.2024]. Verfügbar unter: <https://github.com/mozilla-extensions/firefox-voice>
- [51] Korbinian Kuhn, Verena Kersken, Benedikt Reuter, Niklas Egger, Gottfried Zimmermann, Measuring the Accuracy of Automatic Speech Recognition Solutions, ACM Transactions on Accessible Computing, Band 16, Ausgabe 4, 2023, S. 7, 9, 10, 12, 13, 16, 17.
- [52] Katja Klammer, 7 Fakten zur Gebärdensprache, www.spracheninstitut-leipzig.de, o. D. [Online; abgerufen 16.09.2024]. Verfügbar unter: <https://www.spracheninstitut-leipzig.de/wissenswertes-gebaerdensprache/721-sprache-d-er-woche-gebaerdensprache-1>
- [53] LightningAi, Char Error Rate, www.lightning.ai, o. D., [Online; abgerufen 27.08.2024]. Verfügbar unter: https://lightning.ai/docs/torchmetrics/stable/text/char_error_rate.html
- [54] LightningAi, Match Error Rate, www.lightning.ai, o. D., [Online; abgerufen 27.08.2024]. Verfügbar unter: https://lightning.ai/docs/torchmetrics/stable/text/match_error_rate.html
- [55] LightningAi, Word Info. Lost, www.lightning.ai, o. D., [Online; abgerufen 27.08.2024]. Verfügbar unter: https://lightning.ai/docs/torchmetrics/stable/text/word_info_lost.html
- [56] Rosettacode, Jaro-Winkler distance, www.rosettacode.org, 26.08.2024, [Online; abgerufen 27.08.2024]. Verfügbar unter: https://rosettacode.org/wiki/Jaro-Winkler_distance
- [57] Mozilla, Warum Common Voice?, www.mozilla.org, o. D. [Online; abgerufen 28.09.2024]. Verfügbar unter: <https://commonvoice.mozilla.org/de/about>
- [58] Python Documentation, tkinter - Python interface to Tcl/Tk, docs.python.org, o. D. [Online; abgerufen 29.08.2024]. Verfügbar unter: <https://docs.python.org/3/library/tkinter.html>

- [59] Python Documentation, sqlite3 - DB-API 2.0 interface for SQLite databases, docs.python.org, o. D. [Online; abgerufen 29.08.2024]. Verfügbar unter: <https://docs.python.org/3/library/sqlite3.html>
- [60] Python Documentation, subprocess - Subprocess management, docs.python.org, o. D. [Online; abgerufen 29.08.2024]. Verfügbar unter: <https://docs.python.org/3/library/subprocess.html>
- [61] Tyler Whitney, Colin Robertson, Kent Sharkey, Next Turn, Martin Koudelka, Mike Jones, Gordon Hogenson, Saisang Cai, stdin stdout stderr, learn.microsoft.com, 12.10.2023, [Online; abgerufen 29.08.2024]. Verfügbar unter: <https://learn.microsoft.com/de-de/cpp/c-runtime-library/stdin-stdout-stderr?view=msvc-170>
- [62] Nik Vaessen, Bart van Andel, Bgrozev, Brendan Fahy, Alex Fortin, Neil Stoker, Pariente Manuel, jever, www.github.com, o. D. [Online; abgerufen 30.08.2024]. Verfügbar unter: <https://github.com/jitsi/jiwer>
- [63] Rmilne, jaro-winkler 2.0.3, www.pypi.org, 05.08.2022, [Online; abgerufen 30.08.2024]. Verfügbar unter: <https://pypi.org/project/jaro-winkler/>
- [64] Eric Gazoni, Charlie Clark, openpyxl - A Python library to read/write Excel 2010 xlsx/xlsm files, www.openpyxl.readthedocs.io, 29.05.2024, [Online; abgerufen 30.08.2024]. Verfügbar unter: <https://openpyxl.readthedocs.io/en/stable/>
- [65] Palletsprojects, Welcome to Flask, www.palletsprojects.com, o. D., [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://flask.palletsprojects.com/en/3.0.x/>
- [66] MDN Web Docs, HTML: HyperText Markup Language, www.mozilla.org, 08.08.2024, [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://developer.mozilla.org/en-US/docs/Web/HTML>
- [67] MDN Web Docs, CSS: Cascading Style Sheets, www.mozilla.org, 25.07.2024, [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://developer.mozilla.org/en-US/docs/Web/CSS>
- [68] Bootstrap, Build fast, responsive sites with Bootstrap, www.getbootstrap.com, o. D. [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://getbootstrap.com/>
- [69] Palletsprojects, Jinja, www.palletsprojects.com, o. D., [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://jinja.palletsprojects.com/en/3.1.x/>
- [70] MDN Web Docs, HTTP, www.mozilla.org, 04.07.2024, [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://developer.mozilla.org/en-US/docs/Web/HTTP>
- [71] h2non, filetype 1.2.0, www.pypi.org, 02.11.2022, [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://pypi.org/project/filetype/>
- [72] Mark Beacom, Tom Burrows, Zulko, moviepy 1.0.3, www.pypi.org, 05.10.2020, [Online; abgerufen 31.08.2024]. Verfügbar unter: <https://pypi.org/project/moviepy/>

[73] OpenAI, whisper, [www.github.com](https://github.com/openai/whisper), o. D. [Online; abgerufen 31.08.2024].
Verfügbar unter: <https://github.com/openai/whisper>

[74] AssemblyAI, Industry's most accurate Speech AI models, www.assemblyai.com,
o.J. [Online; abgerufen 07.09.2024]. Verfügbar unter:
<https://www.assemblyai.com/benchmarks>

Anhang 1: Use Cases STT Accuracy Analyzer

Use Case 1:	Initialisierung der Anwendung
Überblick:	Die Anwendung wird durch den Nutzer gestartet. Die graphische Benutzeroberfläche zeigt dem Nutzer die Eingabe-Seite an. Der Datenbank-Dienst initialisiert die Datenbank.
Akteure:	Datenbank, Datenbank-Dienst, Graphische Benutzeroberfläche, Nutzer.
Auslöser:	Der Nutzer startet die Anwendung.
Voraussetzung:	Die Anwendung ist auf dem System des Nutzers installiert.
Normaler Ablauf:	1 Der Nutzer startet die Anwendung. 2 Die graphische Benutzeroberfläche generiert die Seiten der Anwendung. 3 Die graphische Benutzeroberfläche zeigt dem Nutzer die Eingabe-Seite an. 4 Die graphische Benutzeroberfläche signalisiert dem Datenbank-Dienst, dass die Initialisierung der graphischen Benutzeroberfläche abgeschlossen ist. 5 Der Datenbank-Dienst geniert die nötigen Tabellen in der Datenbank.
Ergebnis:	Die Anwendung ist gestartet. Die graphische Benutzeroberfläche zeigt die Eingabe-Seite an. Die Datenbank ist initialisiert.
Endzustand:	Die Anwendung ist gestartet und wartet auf Eingaben durch den Nutzer.

Use Case 2:	Einlesen der Konfigurationsdaten
Überblick:	Nach dem Start der Anwendung wird der Nutzer gebeten, Daten, die der Konfiguration der Anwendung dienen und zu ihrer Ausführung benötigt werden, bereitzustellen. Der Nutzer gibt die benötigten Daten über die graphische Benutzeroberfläche ein. Die Anwendung überprüft, dass die Daten valide sind und speichert diese in der Datenbank.

Akteure:	Datenbank, Datenbank-Dienst, Eingabe-Verifizierungsdienst, Graphische Benutzeroberfläche, Nutzer.
Auslöser:	Die Initialisierung der Anwendung ist abgeschlossen.
Voraussetzung:	Die Anwendung wurde gestartet und die Initialisierung ist abgeschlossen.
Normaler Ablauf:	1 Der Nutzer wird über die Graphische Benutzeroberfläche aufgefordert, die für die Ausführung der Anwendung nötigen Konfigurationsdaten einzugeben. 2 Der Nutzer gibt die geforderten Daten über die graphische Benutzeroberfläche ein. 3 Der Nutzer drückt den Start-Button. 4 Die graphische Benutzeroberfläche übergibt die Konfigurationsdaten an den Eingabe-Verifizierungsdienst. 5 Der Eingabe-Verifizierungsdienst überprüft, dass die Konfigurationsdaten valide sind. 6 Der Eingabe-Verifizierungsdienst übergibt der graphischen Benutzeroberfläche die Information, dass die Konfigurationsdaten valide sind. 7 Die graphische Benutzeroberfläche übergibt die Konfigurationsdaten an den Datenbank-Dienst. 8 Der Datenbank-Dienst speichert die Konfigurationsdaten in der Datenbank. 9 Die graphische Benutzeroberfläche zeigt dem Nutzer die Testprozess-Fortschritt-Seite. Ergebnis: Die Konfigurationsdaten sind eingelesen und der Testprozess kann beginnen.
Alternativer Ablauf:	3a: Der Nutzer hat keine Konfigurationsdaten eingegeben. 3a1 Der Nutzer drückt den Start-Button, ohne vorher Konfigurationsdaten einzugeben. 3a2 Die graphische Benutzeroberfläche übergibt das leere Datenpaket, das eigentlich die Konfigurationsdaten enthalten sollte, aber in diesem Fall keinen Inhalt hat, an den Eingabe-Verifizierungsdienst. 3a3 Der Eingabe-Verifizierungsdienst erkennt, dass keine

	Konfigurationsdaten eingegeben wurden.
3a4	Der Eingabe-Verifizierungsdienst übergibt der graphischen Benutzeroberfläche die Information, dass keine Konfigurationsdaten eingegeben wurden.
3a5	Die graphische Benutzeroberfläche zeigt dem Nutzer eine Fehlermeldung und fordert den Nutzer auf, die benötigten Konfigurationsdaten einzugeben.
Ergebnis:	Der Nutzer wurde darauf hingewiesen, dass er die nötigen Konfigurationsdaten eingeben muss, um fortzufahren.
Alternativer Ablauf:	5a: Die eingegebenen Konfigurationsdaten sind nicht valide.
5a1	Der Eingabe-Verifizierungsdienst stellt fest, dass die Konfigurationsdaten nicht valide sind.
5a2	Der Eingabe-Verifizierungsdienst übergibt der graphischen Benutzeroberfläche Informationen, warum die eingegebenen Konfigurationsdaten nicht valide sind.
5a3	Die graphische Benutzeroberfläche gibt dem Nutzer Informationen, welche Konfigurationsdaten nicht valide sind und warum und fordert den Nutzer auf, eine valide Form dieser Konfigurationsdaten einzugeben.
5a4	Der Nutzer gibt eine valide Form der Konfigurationsdaten ein.
5a5	Der Nutzer drückt den Start-Button.
5a6	Die graphische Benutzeroberfläche übergibt die Konfigurationsdaten an den Eingabe-Verifizierungsdienst.
5a7	Der Eingabe-Verifizierungsdienst überprüft, dass die Konfigurationsdaten valide sind.
Ergebnis:	Die eingegebenen Konfigurationsdaten sind valide.
Endzustand:	Die Konfigurationsdaten sind in der Datenbank gespeichert und der Testprozess kann beginnen.

Use Case 3:	Initialisierung des Transkriptions-Dienstes
Überblick:	Der Transkriptions-Dienst wird initialisiert. Die Testdaten werden in die Datenbank eingelesen und dem Transkriptions-Dienst bereitgestellt.
Akteure:	Datenbank, Datenbank-Dienst, Graphische Benutzeroberfläche, Nutzer, Transkriptions-Dienst.

Auslöser:	Die Testprozess-Fortschritt-Seite wird durch die graphische Benutzeroberfläche aufgerufen.
Voraussetzung:	Die Konfigurationsdaten wurden erfolgreich in die Datenbank eingelesen.
Normaler Ablauf:	1 Der Transkriptions-Dienst wird gestartet. 2 Der Datenbank-Dienst lädt die Konfigurationsdaten aus der Datenbank und übergibt diese an den Transkriptions-Dienst. 3 Der Transkriptions-Dienst sendet einen Fortschrittsbericht an die graphische Benutzeroberfläche, dass das Einlesen der Testdaten begonnen hat. 4 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite an, dass die Testdaten eingelesen werden. 5 Der Datenbank-Dienst liest die Standard-Testdaten und speichert diese in der Datenbank. 6 Der Datenbank-Dienst liest die Testdaten aus der Datenbank. 7 Der Datenbank-Dienst übergibt die Testdaten an den Transkriptions-Dienst. 8 Der Transkriptions-Dienst sendet einen Fortschrittsbericht an die graphische Benutzeroberfläche, dass die Testdaten eingelesen wurden. 9 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite an, dass die Testdaten erfolgreich eingelesen wurden. Ergebnis: Der Transkriptions-Dienst wurde initialisiert und verfügt über die nötigen Konfigurations- sowie Testdaten, um den Transkriptionsprozess auszuführen.
Alternativer Ablauf:	5a: Die Konfigurationsdaten enthalten den Speicherort eines benutzerdefinierten Testdatensatzes. 5a1 Der Transkriptions-Dienst übergibt dem Datenbank-Dienst die Konfigurationsdaten, die den Speicherort des benutzerdefinierten Testdatensatzes enthalten. 5a2 Der Datenbank-Dienst liest die benutzerdefinierten Testdaten und speichert diese in der Datenbank. Ergebnis: Die benutzerdefinierten Testdaten wurden in die Datenbank

	eingelezen.
Ausnahme Ablauf:	5b: Fehler beim Einlesen der Testdaten.
	5b1 Der Datenbank-Dienst kann die Testdaten nicht lesen.
	5b2 Der Datenbank-Dienst sendet der graphischen Benutzeroberfläche einen Fortschrittsbericht, dass die Testdaten nicht gelesen werden können.
	5b3 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite eine Fehlermeldung, dass die Testdaten nicht gelesen werden können.
	5b4 Die graphische Benutzeroberfläche zeigt dem Nutzer einen Button zu beenden der Anwendung an.
	5b5 Der Nutzer drückt den Button zum Beenden der Anwendung.
	5b6 Die Anwendung terminiert.
Ergebnis:	Die Anwendung terminiert, da die Testdaten nicht gelesen werden konnten.
Endzustand:	Der Transkriptions-Dienst hat die Konfigurationsdaten erhalten. Die Testdaten wurden in die Datenbank eingelezen und dem Transkriptions-Dienst übergeben. Damit verfügt der Transkriptions-Dienst über alle zur Ausführung des Transkriptionsprozess nötigen Daten. Im Fall, dass die Testdaten nicht gelesen werden können, wird die Anwendung beendet.

Use Case 4:	Transkriptionsprozess
Überblick:	Der Transkriptions-Dienst generiert für alle Testdaten ein Transkript. Die Ergebnisse werden in der Datenbank gespeichert.
Akteure:	Datenbank, Datenbank-Dienst, Graphische Benutzeroberfläche, KI-Subprozess, Nutzer, Transkriptions-Dienst.
Auslöser:	Die Initialisierung des Transkriptions-Dienstes ist abgeschlossen.
Voraussetzung:	Der Transkriptions-Dienst wurde erfolgreich initialisiert und verfügt über die Konfigurations- und Testdaten.
Normaler Ablauf:	

- 1 Der Transkriptions-Dienst bestimmt anhand der Testdaten, wie viele Transkriptionsschritte durchgeführt werden müssen.
- 2 Der Transkriptions-Dienst sendet der graphischen Benutzeroberfläche einen Fortschrittsbericht, welchen Transkriptionsschritt er aktuell durchführt.
- 3 Die graphische Benutzeroberfläche zeigt dem Nutzer den Fortschrittsbericht auf der Testprozess-Fortschritt-Seite an.
- 4 Der Transkriptions-Dienst startet mit dem Startbefehl aus den Konfigurationsdaten den KI-Subprozess und übergibt die dem aktuellen Transkriptionsschritt entsprechende Audiodatei an den KI-Subprozess.
- 5 Der KI-Subprozess erstellt ein Transkript der Audiodatei und übergibt dieses an den Transkriptions-Dienst.
- 6 Der Transkriptions-Dienst wiederholt die Schritte 2 - 5 für alle Testdaten.
- 7 Der Transkriptions-Dienst übergibt die Transkriptionsergebnisse, bestehend aus den erstellten Transkripten und zugehörigen originalen Sätzen aus den Testdaten, an den Datenbank-Dienst.
- 8 Der Datenbank-Dienst speichert die Transkriptionsergebnisse in der Datenbank.
- 9 Der Transkriptions-Dienst sendet der graphischen Benutzeroberfläche einen Fortschrittsbericht, dass der Transkriptionsprozess abgeschlossen ist.
- 10 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite an, dass der Transkriptionsprozess abgeschlossen ist.

Ergebnis: Der Transkriptionsprozess ist abgeschlossen und die Transkriptionsergebnisse wurden in der Datenbank gespeichert.

Alternativer Ablauf: **6a:** Der Nutzer bricht den Transkriptionsprozess ab.

- 6a1** Der Nutzer drückt auf den Button zum Abbrechen des Transkriptionsprozesses.
- 6a2** Die Durchführung des Transkriptionsprozesses wird beendet.
- 6a3** Die Anwendung terminiert.

Ergebnis: Die Anwendung wurde terminiert, da der Nutzer den

	Transkriptionsprozess abgebrochen hat.
Ausnahme Ablauf:	5a: Der KI-Subprozess ist fehlerhaft.
	5a1 Im KI-Subprozess tritt ein Fehler auf.
	5a2 Der Transkriptions-Dienst sendet eine Statusmeldung an die graphische Benutzeroberfläche, dass ein Fehler im KI-Subprozess aufgetreten ist.
	5a3 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite eine Fehlermeldung, dass im KI-Subprozess ein Fehler aufgetreten ist.
	5a4 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite einen Button zum Beenden der Anwendung an.
	5a5 Der Nutzer drückt den Button zum Beenden der Anwendung.
	5a6 Die Anwendung terminiert.
Ergebnis:	Die Anwendung terminiert aufgrund eines Fehlers im KI-Subprozess.
Endzustand:	Der Transkriptionsprozess wurde erfolgreich abgeschlossen und die Transkriptionsergebnisse wurden in der Datenbank gespeichert. In den Fällen, dass der Nutzer die Ausführung des Transkriptionsprozesses abbricht oder während dieses Prozesses ein Fehler im KI-Subprozess auftritt, wird die Anwendung beendet.

Use Case 5:	Initialisierung des Auswertungs-Dienst
Überblick:	Der Auswertungs-Dienst wird initialisiert und bekommt die Transkriptionsergebnisse durch den Datenbank-Dienst bereitgestellt.
Akteure:	Auswertungs-Dienst, Datenbank, Datenbank-Dienst.
Auslöser:	Der Transkriptionsprozess wurde erfolgreich abgeschlossen.
Voraussetzung:	Die Transkriptionsergebnisse sind in der Datenbank hinterlegt.
Normaler Ablauf:	
	1 Der Auswertungs-Dienst wird gestartet.
	2 Der Datenbank-Dienst liest die Transkriptionsergebnisse aus

	der Datenbank.
3	Der Datenbank-Dienst übergibt die Transkriptionsergebnisse an den Auswertungs-Dienst.
Ergebnis:	Der Auswertungs-Dienst hat Zugriff auf die Transkriptionsergebnisse.
Endzustand:	Der Auswertungs-Dienst wurde initialisiert und verfügt über alle Daten, die für den Auswertungsprozess benötigt werden.

Use Case 6:	Auswertungsprozess
Überblick:	Der Auswertungs-Dienst berechnet für alle Transkriptionsergebnisse die Auswertungsmetriken. Die Ergebnisse werden in der Datenbank gespeichert.
Akteure:	Auswertungs-Dienst, Datenbank, Datenbank-Dienst, Graphische Benutzeroberfläche, Nutzer.
Auslöser:	Der Auswertungs-Dienst wurde erfolgreich initialisiert.
Voraussetzung:	Der Auswertungs-Dienst verfügt über die Transkriptionsergebnisse.
Normaler Ablauf:	1 Der Auswertungs-Dienst berechnet aus den Transkriptionsergebnissen die Anzahl der erforderlichen Auswertungsschritte. 2 Der Auswertungs-Dienst sendet der graphischen Benutzeroberfläche einen Fortschrittsbericht, welcher Auswertungsschritt aktuell ausgeführt wird. 3 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite den Fortschrittsbericht, welcher Auswertungsschritt aktuell ausgeführt wird. 4 Der Auswertungs-Dienst berechnet aus den Transkriptionsergebnissen des aktuellen Auswertungsschritts die Auswertungsmetriken. 5 Der Auswertungs-Dienst wiederholt die Schritte 2 - 4 für jeden Auswertungsschritt. 6 Der Auswertungs-Dienst übergibt die Auswertungsergebnisse, bestehend aus den berechneten Metriken, an den Datenbank-Dienst.

	7 Der Datenbank-Dienst speichert die Auswertungsergebnisse in der Datenbank. 8 Der Auswertungs-Dienst sendet einen Fortschrittsbericht an die graphische Benutzeroberfläche, dass der Auswertungsprozess abgeschlossen ist. 9 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite an, dass der Auswertungsprozess abgeschlossen ist. 10 Die graphische Benutzeroberfläche blendet den Abbrechen Button auf der Testprozess-Fortschritt-Seite aus. 11 Die graphische Benutzeroberfläche zeigt dem Nutzer auf der Testprozess-Fortschritt-Seite einen Button zum Anzeigen der Ergebnisse. Ergebnis: Der Auswertungsprozess ist abgeschlossen. Die Auswertungsergebnisse wurden in der Datenbank gespeichert. Alternativer Ablauf: 5a: Der Nutzer bricht den Auswertungsprozess ab. 5a1 Die graphische Benutzeroberfläche zeigt während des Auswertungsprozesses einen Button zum Abbrechen des Auswertungsprozesses an. 5a2 Der Nutzer drückt auf den Button zum Abbrechen des Auswertungsprozesses. 5a3 Die Durchführung des Auswertungsprozesses wird beendet. 5a4 Die Anwendung terminiert. Ergebnis: Die Anwendung wurde terminiert, da der Nutzer den Auswertungsprozess abgebrochen hat. Endzustand: Der Auswertungsprozess ist abgeschlossen und die Auswertungsergebnisse sind in der Datenbank hinterlegt. Im Fall, dass der Nutzer den Auswertungsprozess abbricht, wird die Anwendung beendet.
--	--

Use Case 7:	Anzeigen der Ergebnisse
Überblick:	Die Mittelwerte der Auswertungsmetriken werden dem Nutzer über die graphische Benutzeroberfläche angezeigt.
Akteure:	Datenbank, Datenbank-Dienst, Graphische Benutzeroberfläche, Nutzer.

Auslöser:	Der Nutzer drückt den Button zum Anzeigen der Ergebnisse auf der Testprozess-Fortschritt-Seite.
Voraussetzung:	Der Transkriptions- und Auswertungsprozess wurde erfolgreich abgeschlossen und die Ergebnisse sind in der Datenbank hinterlegt.
Normaler Ablauf:	1 Der Nutzer drückt den Button zum Anzeigen der Ergebnisse auf der Testprozess-Fortschritt-Seite. 2 Die graphische Benutzeroberfläche zeigt dem Nutzer die Ergebnis-Seite. 3 Der Datenbank-Dienst liest die Auswertungsergebnisse aus der Datenbank. 4 Der Datenbank-Dienst übergibt die Auswertungsergebnisse an die graphische Benutzeroberfläche. 5 Die graphische Benutzeroberfläche zeigt dem Nutzer die Mittelwerte der Auswertungsmetriken auf der Ergebnis-Seite an.
Endzustand:	Die Ergebnisse werden auf der Ergebnis-Seite angezeigt.

Use Case 8:	Exportieren der Ergebnisse
Überblick:	Die Ergebnisse des Transkriptions- und Auswertungsprozesses werden an einen durch den Nutzer spezifizierten Speicherort als Tabelle exportiert.
Akteure:	Datenbank, Datenbank-Dienst, Graphische Benutzeroberfläche, Nutzer.
Auslöser:	Der Nutzer drückt den Button zum Exportieren der Ergebnisse auf der Ergebnis-Seite.
Voraussetzung:	Die Ergebnisse werden auf der Ergebnis-Seite angezeigt. Die Transkriptions- und Auswertungsergebnisse sind in der Datenbank hinterlegt.
Normaler Ablauf:	1 Die graphische Benutzeroberfläche öffnet einen Dialog, in dem der Nutzer aufgefordert wird, einen Speicherort und Dateinamen für den Export der Ergebnisse auszuwählen. 2 Die graphische Benutzeroberfläche übergibt den Speicherort und Dateinamen an den Datenbank-Dienst.

- 3 Der Datenbank-Dienst liest die Transkriptions- und Auswertungsergebnisse aus der Datenbank.
- 4 Der Datenbank-Dienst formatiert die Ergebnisse als Tabelle.
- 5 Der Datenbank-Dienst speichert die Tabelle am spezifizierten Speicherort unter dem spezifizierten Dateinamen.

Ergebnis: Die Ergebnisse wurden exportiert.

Endzustand: Die Ergebnisse wurden exportiert und können unabhängig von der Ausführung der Anwendung weiterverwendet werden.

Use Case 9: Beenden der Anwendung

Überblick: Der Nutzer beendet die Anwendung. Der Datenbank-Dienst bereinigt die Datenbank.

Akteure: Datenbank, Datenbank-Dienst, Nutzer.

Auslöser: Der Nutzer drückt den Button zum Beenden der Anwendung.

Voraussetzung: Keine

Normaler Ablauf:

- 1 Der Nutzer drückt den Button zum Beenden der Anwendung.
- 2 Der Datenbank-Dienst löscht sämtliche Daten aus der Datenbank.
- 3 Die Anwendung terminiert.

Endzustand: Die Anwendung wurde beendet. Die Datenbank wurde bereinigt.

Anhang 2: Use Cases TranscribeMyVideo

Use Case 1:	Upload der Videodatei
Überblick:	Der Nutzer wählt über das Webinterface in seinem Webbrowser eine Videodatei aus, die mittels des Upload-Dienstes hochgeladen und verifiziert wird. Anschließend wird die Videodatei durch den Daten-Manager im Dateisystem des Servers gespeichert.
Akteure:	Daten-Manager, Nutzer, Server, Upload-Dienst, Webbrowser, Webinterface.
Auslöser:	Der Nutzer öffnet die Anwendung über den Webbrowser.
Voraussetzung:	Die Anwendung wird auf dem Server ausgeführt.
Normaler Ablauf:	1 Das Webinterface zeigt dem Nutzer die Upload-Seite. 2 Der Nutzer drückt den Button zum Hochladen einer Datei. 3 Das Webinterface zeigt dem Nutzer einen Dialog zum Auswählen einer Datei. 4 Der Nutzer wählt die gewünschte Datei aus und bestätigt die Auswahl. 5 Das Webinterface übergibt die ausgewählte Datei an den Upload-Dienst. 6 Der Upload-Dienst prüft, dass eine Datei hochgeladen wurde. 7 Der Upload-Dienst übergibt die Datei an den Daten-Manager. 8 Der Daten-Manager speichert die Datei im Dateisystem des Servers. 9 Der Upload-Dienst prüft, dass die Datei eine Videodatei ist. 10 Der Upload-Dienst signalisiert dem Webinterface, dass die Datei erfolgreich hochgeladen wurde.
Ergebnis:	Eine Videodatei wurde erfolgreich hochgeladen und im Dateisystem des Servers gespeichert.

Ausnahme Ablauf:	6a: Es wurde keine Datei hochgeladen.
	6a1 Der Upload-Dienst stellt fest, dass der Nutzer keine Datei hochgeladen hat. 6a2 Der Upload-Dienst signalisiert dem Webinterface, dass keine Datei ausgewählt wurde. 6a3 Das Webinterface zeigt dem Nutzer eine Fehlermeldung, dass keine Datei ausgewählt wurde und fordert den Nutzer auf, eine Datei auszuwählen.
Ergebnis:	Der Nutzer wurde darauf hingewiesen, dass keine Datei ausgewählt wurde und aufgefordert, eine Datei hochzuladen.
Ausnahme Ablauf:	9a: Die hochgeladene Datei ist keine Videodatei.
	9a1 Der Upload-Dienst erkennt, dass die hochgeladene Datei keine Videodatei ist. 9a2 Der Upload-Dienst signalisiert dem Daten-Manager, dass die hochgeladene Datei das falsche Dateiformat hat. 9a3 Der Daten-Manager löscht die hochgeladene Datei aus dem Dateisystem des Servers. 9a4 Der Upload-Dienst signalisiert dem Webinterface, dass die hochgeladene Datei das falsche Dateiformat hat. 9a5 Das Webinterface zeigt dem Nutzer eine Fehlermeldung, dass die hochgeladene Datei das falsche Dateiformat hat und fordert den Nutzer dazu auf, eine Videodatei hochzuladen.
Ergebnis:	Der Nutzer wurde darauf hingewiesen, dass die hochgeladene Datei das falsche Format hat und wurde aufgefordert, eine Datei im korrekten Format hochzuladen.
Endzustand:	Die Videodatei wurde hochgeladen, validiert und für die weitere Bearbeitung im Dateisystem des Servers gespeichert.

Use Case 2:	Generierung des Transkripts aus dem hochgeladenen Video
Überblick:	Der Transkriptionsdienst generiert aus einer Videodatei ein Transkript und übergibt es an den Daten-Manager. Der Daten-Manager speichert das Transkript im Dateisystem des Servers.
Akteure:	Daten-Manager, Server, Transkriptions-Dienst, Webinterface.

Auslöser:	Eine Videodatei wurde erfolgreich hochgeladen.
Voraussetzung:	Eine Videodatei ist im Dateisystem des Servers gespeichert.
Normaler Ablauf:	1 Das Webinterface leitet den Nutzer auf die Transkript-Prozess-Seite weiter. 2 Der Transkriptions-Dienst erfragt beim Daten-Manager den Speicherort der Videodatei. 3 Der Daten-Manager übergibt die Information über den Speicherort der Videodatei an den Transkriptions-Dienst. 4 Der Transkriptions-Dienst extrahiert das Audio aus der Videodatei und übergibt es an den Daten-Manger. 5 Der Daten-Manager speichert die Audiodatei im Dateisystem des Servers. 6 Der Transkriptions-Dienst generiert ein Transkript aus der Audiodatei. 7 Der Transkriptions-Dienst übergibt das Transkript an den Daten-Manger. 8 Der Daten-Manager speichert das Transkript im Dateisystem des Servers. 9 Der Transkriptions-Dienst sendet dem Webinterface einen Fortschrittsbericht, dass der Transkriptionsprozess erfolgreich abgeschlossen wurde. 10 Das Webinterface erfragt beim Daten-Manager den Speicherort des Transkripts. 11 Der Daten-Manager übergibt die Information über den Speicherort des Transkripts an das Webinterface. 12 Das Webinterface leitet den Nutzer auf die Korrektur-Seite weiter und zeigt das Transkript auf dieser an.
Endzustand:	Der Transkriptionsprozess wurde erfolgreich beendet. Dem Nutzer wird das Transkript auf der Korrektur-Seite angezeigt.

Use Case 3:	Korrektur des generierten Transkriptes
--------------------	--

Überblick:	Der Nutzer korrigiert das generierte Transkript. Dieses wird anschließend durch den Daten-Manager als PDF-Datei formatiert und im Dateisystem des Servers gespeichert.
Akteure:	Daten-Manager, Nutzer, Server, Webinterface.
Auslöser:	Dem Nutzer wird die Korrektur-Seite angezeigt.
Voraussetzung:	Der Transkriptionsprozess wurde erfolgreich abgeschlossen.
Normaler Ablauf:	1 Der Nutzer nimmt über die Korrektur-Seite die gewünschten Korrekturen am Transkript vor. 2 Der Nutzer drückt den Button zum Beenden der Korrektur. 3 Das Webinterface übergibt das korrigierte Transkript an den Daten-Manger. 4 Der Daten-Manger formatiert das Transkript als PDF-Datei. 5 Der Daten-Manager speichert die PDF-Datei im Dateisystem des Servers. 6 Das Webinterface leitet den Nutzer auf die Download-Seite weiter.
Endzustand:	Das Transkript wurde durch den Nutzer korrigiert und steht als PDF-Datei zum Download zur Verfügung. Dem Nutzer wird die Download-Seite angezeigt.

Use Case 4:	Download des Transkripts
Überblick:	Der Nutzer lädt die erstellte Transkript-PDF-Datei herunter.
Akteure:	Daten-Manager, Nutzer, Webbrowser, WebInterface.
Auslöser:	Die Download-Seite wird angezeigt.
Voraussetzung:	Ein Transkript ist als PDF-Datei im Dateisystem des Servers gespeichert.
Normaler Ablauf:	

	1 Der Nutzer drückt den Herunterladen-Button. 2 Das Webinterface erfragt beim Daten-Manager den Speicherort der Transkript-PDF-Datei. 3 Der Daten-Manager übergibt die Information über den angefragten Speicherort der Transkript-PDF-Datei an das Webinterface. 4 Das Webinterface sendet die Transkript-PDF-Datei an den Webbrowser des Nutzers.
Endzustand:	Die Transkript-PDF-Datei wurde heruntergeladen.

Use Case 5:	Zurücksetzen der Anwendung
Überblick:	Alle eventuell vorhandenen Daten aus vorherigen Sitzungen werden entfernt, sodass neue Transkriptionsanfragen entgegengenommen werden können.
Akteure:	Daten-Manager, Nutzer, Server, Webbrowser, WebInterface.
Auslöser:	Die Upload-Seite wird aufgerufen.
Voraussetzung:	Die Anwendung wird auf dem Server ausgeführt.
Normaler Ablauf:	1 Der Nutzer ruft über den Webbrowser oder über den „Zur Startseite“ Button die Upload-Seite der Anwendung auf. 2 Das Webinterface sendet dem Daten-Manager den Befehl, das Dateisystem des Servers zu bereinigen. 3 Der Daten-Manager löscht alle anwendungseigenen Dateien, die sich eventuell noch aus vorherigen Sitzungen im Dateisystem des Servers befinden. 4 Das Webinterface leitet den Nutzer auf die Upload-Seite weiter.
Endzustand:	Alle Daten aus vorherigen Sitzungen wurden aus dem Dateisystem des Servers gelöscht. Damit ist die Anwendung bereit, neue Transkriptions-Anfragen entgegenzunehmen. Dem Nutzer wird die Upload-Seite angezeigt.